OMNICIO

План развития сайта и PWA

Понятный портфель.
Персональный ИИ.
Контролируемые действия.

Qwen3-14B · Lenovo + Timeweb

Редакция основного плана от 04.10.2026: широкий диалог, публичный интернет, персональный контекст и поэтапная интеграция выбранной модели.

Бюджет эксплуатации: до 20 000 ₽/месяц.
Пилот: до 7 000 ₽/месяц. Два независимых аккаунта.
18 основных этапов: v0.18.2 → v1.0. Готовый Lenovo переиспользуется.

Редакция 2.1 | 4 октября 2026
Спецификация разработки. Подключение серверов и изменение кода не выполнялись. Границы проверки и условия выпуска указаны в документе.

Карта документа

01. Решение для владельца продукта 5

02. Проверенная база и границы аудита 6

03. Недостатки исходного плана: приоритет P0 7

04. Недостатки продукта и приоритетные улучшения 8

05. Пользовательские задачи и критерии успеха 9

06. Полномочия и режимы продукта 10

07. Навигация и карта экранов 11

08. Визуальная система: точные токены 12

09. Каталог компонентов и состояний 13

10. Подсказка при удержании: доступный вариант 14

11. Иконки, графические эффекты и анимация 15

12. Первый вход и активация 16

13. Главная: структура и все состояния 17

14. Предлагаемый макет Главной 18

15. Портфель, графики и распределение 19

16. Карточка актива и компании 20

17. Поиск активов и доступность пользователю 21

18. Стратегия и точная логика ползунков 22

19. Мобильный поиск и настройка 23

20. Выплаты, цели и достижения 24

21. Уведомления, PWA и ежедневный обзор 25

22. Личный ИИ: интерфейс и тон общения 26

23. Покупка, продажа и ручное решение 28

24. Финансовое ядро и точность денег 29

25. Порог ключевой ставки и валютные облигации 30

26. Диверсификация: методика и ограничения 31

27. Доходность, инфляция и прогнозы 32

28. Деньги и реинвестирование 33

29. Подбор активов и объяснение выбора 34

30. Источники данных и права использования 35

31. Свежесть, доказательства и Watchtower 36

32. Архитектура: Timeweb и Lenovo 37

32A. Существующая PostgreSQL в Timeweb 38

33. Сущности, API и события 39

34. Изоляция пользователей с первого дня 40

35. Состояния заявки и защита от дублей 41

36. Отказы, резервирование и восстановление 42

37. Модель угроз и защитные требования 43

38. Выбранная модель и фактический замер 44

39. Контекст, память и работа с данными 45

39A. Интернет: поиск, чтение и проверка 46

40. Интеграционный worker и режимы модели 48

40A. Протокол связи Lenovo с Timeweb 50

40B. Очередь, доступность и эксплуатация ИИ 52

41. Инструменты ИИ и подтверждение изменений 54

42. Качество ответов и приёмка интеграции 56

43. Бюджет эксплуатации до 20 000 ₽ 58

43A. Принятое решение о размещении 60

44. Стоимость поиска и вычислительная ёмкость 61

45. Платные функции и жизненный цикл подписки 62

46. Правки действующих юридических документов 63

47. Проекты формулировок и хранения 65

48. Контроль кода и выпуск изменений 67

48A. Как программировать каждое изменение 68

49. Производительность и проверка масштаба 69

50. Дорожная карта и зависимости 70

50A. Выпуск рабочей версии двум пользователям 71

51. R0 · v0.18.2 · Проверяемая основа 72

52. R1 · v0.19.0 · Понятный старт и интерфейс 73

53. R2 · v0.20.0 · Понятный портфель 74

54. R3 · v0.21.0 · Источники и разбор активов 75

55. R4 · v0.22.0 · Наблюдение и журнал 76

56. R5 · v0.23.0 · PWA и уведомления 77

57. R6 · v0.24.0 · Стратегия и каталог 78

58. R7 · v0.25.0 · Выплаты и риск 79

59. R8 · v0.26.0 · Qwen3-14B и интернет 80

60. R9 · v0.27.0 · Новые деньги и предложения 81

61. R10 · v0.28.0 · Настройка через диалог 82

62. R11 · v0.29.0 · Торговый симулятор 83

63. R12 · v0.30.0 · Реальные поручения 84

64. R13 · v0.31.0 · Цели и спокойная мотивация 85

65. R14 · v0.32.0 · Тарифы и платежи 86

66. R15 · v0.33.0 · Скорость и ёмкость при росте 87

67. R16 · v0.34.0 · Расширение доступа 88

68. R17 · v1.0.0 · Устойчивая продуктовая линия 89

69. Экономика подписки и пределы роста 90

70. Полное соответствие исходному плану 91

71. Сроки, приёмка и ответственность 93

72. Первый рабочий пакет и границы развития 94

73. Источники: продукт и финансовые контракты 95

74. Источники: данные и удобство интерфейса 96

75. Источники: выбранный ИИ и интеграция 97

76. Источники: безопасность и правовые вопросы 98

01. Решение для владельца продукта

Редакция 2.1: основной ИИ OmniCIO - Qwen3-14B Q4_K_M на уже работающем Lenovo владельца. Timeweb остаётся центром сайта, данных, прав доступа, расчётов и наблюдения.

Сохраняем существующий продукт, подробные требования к интерфейсу и 18 последовательных релизов. Обновлены архитектура ИИ, источники, чат, контракты, очередь, безопасность, бюджет, документы и зависимые этапы. Облачная LLM и выбор между моделями исключены из основной линии; замена модели не является задачей этой редакции.

Принятые решения

- Использовать установленную `qwen3:14b-q4_K_M` через Ollama. Lenovo подготовлен владельцем: постоянное питание, UPS и интернет 600 Мбит/с. Повторная настройка оборудования, установка Windows и аппаратные стресс-тесты не входят в план.
- Добавить только интеграционный сервис OmniCIO AI Worker. Он получает задания с Timeweb по исходящему защищённому соединению и обращается к локальному Ollama. Пользователь сайта не подключается к ноутбуку напрямую.
- Сохранить общие способности модели: русский диалог, объяснения, сравнение подходов, разбор текстов, помощь с сервисом и общие вопросы. Инвестиционная стратегия выбирается пользователем и не зашивается как единственная допустимая точка зрения.
- Дать ассистенту поиск и чтение публичного интернета через инструменты Timeweb: поиск, страницы, отчёты, источники и даты. Актуальность обеспечивают новые сведения, а не переобучение весов после каждого посещения сайта.
- Финансовые расчёты, принадлежность данных и допуски исполняются проверяемым кодом. ИИ может подготовить изменение; запись настроек и финансовое действие проходят отдельное подтверждение.
- С первого подключения два независимых обычных аккаунта получают разные историю, память, портфели и квоты. Увеличение числа пользователей требует проверки мощности, но не переделки изоляции.

Что означает текущая скорость

По последнему снимку владельца короткий ответ на уже загруженной модели занял 17,10 с, скорость генерации 4,09 токена/с. Это рабочая исходная точка для пилота. Замер не подтверждает скорость длинного исследования или нескольких одновременных бесед; интегрированные показатели описаны в §§38/42/49.

Плановый конверт пилота - до 7 000 ₽/мес., зрелой линии - до 19 000 ₽/мес. Абсолютный предел - 20 000 ₽. За локальные ответы не закладывается плата за токены; учитываются Timeweb, поиск, хранение, электричество и резерв. Это бюджетные лимиты, не тарифное предложение.

Границы работы

Документ задаёт реализацию и приёмку. Соединение Lenovo с Timeweb в ходе редактирования не создавалось, закрытый код не проверен. Реальные пути модулей, тариф аккаунта и уже выполненные релизы сверяются в R0. Интеграция ИИ может готовиться параллельно с интерфейсом после R0; пользовательское включение зависит от готовности данных и прав.

02. Проверенная база и границы аудита

Дата исследования: 04.10.2026. Проверка сайта была чтением публичных страниц, без входа в аккаунты, изменения настроек, сканирования уязвимостей и торговли.

Объект	Что установлено	Что не установлено
Исходный PDF	Прочитаны все 38 страниц. Зафиксированы версии 0.19-0.30, архитектурные заявления и ограничения.	Упомянутые старые V10 Presentation и Master Plan отдельно не предоставлены.
Публичная страница omnicio.ru	В браузере видны v0.18.1, сборка 0d9eb4694d65, VK ID, лимит двух аккаунтов, четыре отдельных подтверждения.	Полный UX кабинета, скорость его запросов, фактическая работа RLS и шифрования.
Юридические страницы	Прочитаны privacy.html, consent.html, terms.html версии 2026-10-02-v6.	Реальная конфигурация инфраструктуры, реестр оператора, договоры с поставщиками и правовой статус будущих рекомендаций.
Репозиторий	PDF на стр. 37 указывает MishaGameHacking/omni-cio-gateway и commit 0d9eb4694d657d56db2d19681be99bd32c2f69ba.	GitHub и raw-файл AGENTS.md не удалось получить доступным исследовательским инструментом. Причина приватности репозитория не установлена.
Внешние источники	Проверены официальные документы T-Bank, ЦБ, MOEX, W3C, WebKit, OWASP, Qwen, Timeweb, Ollama и Yandex Search API и др.	Не проводились собственные измерения Lenovo, аудит договорных тарифов и подтверждение лицензий на распространение данных. Присланные замеры разобраны отдельно.

Как читать утверждения

Наблюдение - факт из публичного интерфейса или прочитанного документа. **Риск** - потенциальная проблема, которую нужно проверить, а не обнаруженная эксплуатационная уязвимость. **Проектное решение** - предлагаемое новое поведение. **Условие допуска** - требование перед включением функции.

Обязательный аудит репозитория в R0

Сверить AGENTS.md, дерево web/backend, migrations и зависимости; найти все источники tenant_id, фоновые задачи, токены, договоры DTO, вычисление денег, записи согласий и путь исполнения. Проверить CI, историю миграций, фактический main, deployment manifest и соответствие production. Получить только read-only доступ либо ZIP исходников без секретов; ключи в отчёты не копировать.

Этот документ не выдаёт архитектурные заявления старого PDF за проверенные свойства кода. Признаки реализации из PDF используются как ориентир для переиспользования.

Дополнение редакции 2.1

Исходные сведения о публичном сайте, репозитории и юридических документах перенесены из исследования редакции 2.0; они не означают повторный аудит закрытого кода. При этой правке проверены официальные технические документы выбранной модели и интеграции. Страницу privacy.html повторно получить исследовательским web-инструментом не удалось; перед публикацией юридических изменений сверить её фактическую текущую версию.

Владелец подтвердил Lenovo с RTX 2060 6 GB, i5-9300H и 16 GB RAM, готовность работы сервером, 600 Мбит/с и UPS. Последние снимки подтверждают запуск Qwen3-14B и конкретные метрики (§38, [S41]); канал до Timeweb, Ollama version, полный digest и multiuser-нагрузка пока не проверены.

03. Недостатки исходного плана: приоритет P0

P0 здесь означает риск потери денег, утечки, неверных полномочий или юридически недопустимого запуска. Это приоритет проектной проверки, а не подтверждённый взлом.

Проблема / место исходника	Почему мешает	Конкретная правка
Безопасность и hardening завершают 0.30; журнал появляется в 0.29, стр. 29-30	Ранние релизы могут работать без доказуемой истории и восстановления.	Минимальный аудит, журнал, резервирование, RLS-тесты и отказобезопасность в R0; расширять в каждом релизе.
Legal gate на стр. 33 связан с расширением доступа	Два тестовых пользователя не создают автоматического исключения из регулирования.	Применять gate к каждой capability с первого реального пользователя; не ждать массового запуска.
«Одно лучшее решение», стр. 20	Создаёт ложную определённость и плохо подходит ручному поиску.	На Главной один следующий шаг; в поиске - полноценный каталог, сортировка и сравнение 2-3 вариантов.
Стратегия «Авто», классы ON, стр. 13	Пользователь может не понимать, на что согласился; портфель не равен предпочтениям.	Черновик профиля без скрытого согласия; анализ текущего состава разрешён, персональный подбор требует подтверждённых условий.
«Критический push всегда», стр. 17	Сайт не может гарантированно обойти режим ОС, Focus или запрет уведомлений.	Приоритет только в серверной очереди. Реальная доставка best effort; центр событий - постоянный источник состояния.
Internet-first, стр. 18	Публичность страницы не означает право массового скачивания, хранения и перепубликации.	Реестр лицензий до подключения каждого источника; без договора - допустимые ссылки и ограниченные сведения.
ИИ упомянут как future, стр. 25	Нет модели, маршрутизации, бюджета, памяти, проверок ответов и удаления.	Qwen3-14B на Lenovo, исходящий worker, серверный RAG/интернет, личные контексты, очередь и режим без модели; §§38-44.
Удаление аккаунта и будущие immutable-журналы	Нельзя одновременно обещать немедленно стереть всё и сохранять обязательные записи.	До новых функций согласовать сроки хранения по классам данных и восстановление backup с повторным удалением.

P0-критерии допуска

Ноль доступов A к данным B во всех пользовательских каналах; ноль повторных заявок при повторах событий; ни одного broker write из ИИ/сборщика; подтверждение привязано к счёту и версии; финансовые поля не используют float; все неизвестные состояния показываются как неизвестные.

04. Недостатки продукта и приоритетные улучшения

Пользователь должен понимать не архитектуру сервиса, а собственное положение и следующий доступный шаг.

Пробел	Новое требование	Проверка
Недостаточно подробный старт	Путь из 5 шагов, демонстрационный режим, восстановление прерванной настройки, объяснение прав.	Новый пользователь без помощи открывает свой портфель и понимает режим работы.
Термины Watchtower, Research, Decision	В интерфейсе «События», «Источники», «Предложение»; технические названия только для разработчика.	В пяти основных заданиях пользователи не спрашивают, что означает пункт меню.
Нет устойчивого объяснения показателей	У каждого сложного значения есть единицы, дата, источник и короткая справка.	Купон, доходность, стоимость, прибыль и пополнение не путаются.
Нет полной модели доступности	Доступность зависит от счёта, квалификации, тестов, режима торгов, API и операции buy/sell.	Нельзя показать «можно купить» только по признаку неквалифицированного инвестора.
Мало сценариев небольшого портфеля	Ограничение лотов, накопление остатка, постепенное расширение числа эмитентов.	Система честно объясняет, почему 3 000 ₽ не позволяют создать 20 позиций.
Цели и награды отсутствуют	Цели капитала/выплат, видимая методика прогресса; награды за настройку и обучение.	Нет наград за оборот, риск и ежедневную торговлю.
Нет расчёта стоимости сервиса	Лимиты LLM, общий кэш публичных фактов, ограниченное хранение, бюджетный выключатель.	Расходы прогнозируются по дням, а лимиты не отключают безопасность.

Наблюдение по доступному экрану входа

На desktop видны два крупно конкурирующих заголовка, длинная форма согласий и техническое объяснение двух пользовательских слотов. Большой левый заголовок визуально подходит близко к границе колонки. Это основание для проверки адаптивности, а не доказательство ошибки на всех экранах.

Проект: сохранить логотип и спокойную светлую стилистику; уменьшить H1 до адаптивных 32-44 px; сделать один главный заголовок и отдельный компактный блок входа. «Лимит 2» заменить пользовательским «Закрытое тестирование» с ясным состоянием набора. Версию оставить в подвале и диагностике. Согласия не объединять ради уменьшения формы.

Не добавлять в раннюю линию торговые сигналы без доказательств, рейтинги пользователей по прибыли, бесконечную ленту новостей и декоративный постоянно движущийся тикер.

05. Пользовательские задачи и критерии успеха

Основной пользователь - взрослый частный инвестор с собственным счётом, которому нужна ясность, контроль и экономия времени. Опыт, капитал и риск-профиль не предполагаются заранее.

Задача	Ответ продукта	Целевой критерий пилота
«Что у меня происходит?»	Капитал, результат без пополнений, выплаты, свежесть.	Ответ находится за 30 секунд в 4 из 5 наблюдаемых сессий.
«Что мне настроить?»	Короткий мастер + ясные черновики.	Завершение базового старта за 5-7 минут без времени ожидания брокера.
«Что означает эта новость?»	Факт, какие позиции связаны, известное влияние и неопределённость.	Не менее 4 из 5 пользователей верно пересказывают смысл.
«Почему актив не доступен?»	Точная причина и безопасный следующий шаг.	В каждом недоступном состоянии есть текст; нет бесконечно disabled-кнопки.
«Что изменится после покупки?»	До/после, сумма с НКД/комиссией, лимиты, риски.	Пользователь видит итог до финального подтверждения.
«Можно ли доверять ответу ИИ?»	Ссылки на факты, даты, ограниченные полномочия, отказ при нехватке данных.	Все финансовые числа в ответе связаны с вычислением или источником.

Исследование удобства

На двух текущих аккаунтах проводить сценарии с think-aloud, но не считать их статистически представительной выборкой. Для проверки понятности пригласить 5-8 новых людей в демонстрационный контур с синтетическими данными. Не выдавать им доступ к двум реальным портфелям. Задания: подключить демо, найти купон, узнать риск, открыть помощь, изменить черновик, отменить изменение.

Метрики, которые не оптимизируем

Частоту покупок, оборот, время нахождения в чате, число push и число нажатий на тревогу. Продукт успешен, когда пользователь быстрее понимает ситуацию и реже делает случайные действия.

Ограничения первой публичной линии

Российский брокерский контур T-Invest, рублёвые расчёты и понятные акции/обычные облигации/прозрачные фонды в рамках доступности. Маржинальная торговля, короткие позиции, опционы, фьючерсы, структурные ноты и ЦФА не включаются автоматически из-за присутствия в API. Их существующие позиции можно отображать с пометкой о неполном покрытии аналитикой.

Широкие возможности ассистента

Объяснение неподдержанного для покупки класса активов, общие вопросы и сравнение подходов доступны как беседа с Qwen. Умение обсудить тему не означает доступность покупки через OmniCIO. Для личного совета и действия применяются отдельные условия §06; общая беседа не принуждает пользователя выбрать доходную стратегию.

06. Полномочия и режимы продукта

Возможность видеть функцию, право на её использование и техническая готовность - разные проверки. Подписка не даёт торговых прав.

Возможность	Условие включения	Поведение при отсутствии условия
Просмотр собственного портфеля	Сессия, собственный счёт, read-only credential, актуальные необходимые документы.	Мастер подключения или безопасная последняя сводка с датой.
Персональные объяснения ИИ	AI privacy gate для Lenovo, разрешённый контекст, прикладной eval Qwen3-14B.	Детерминированные объяснения и справочник; портфель продолжает работать.
Публичный поиск и чтение	Допущенный search/fetch tool, источник доступен, квота и сетевые проверки пройдены.	Честный режим подключённых источников; общая беседа сохраняется.
Черновик настроек от ИИ	Разрешённый tool, валидатор, явное подтверждение diff.	Ответ с описанием пути настройки без изменения данных.
Индивидуальная buy/sell-рекомендация	Отдельное юридическое заключение, утверждённая методика профиля, необходимые статус/процедуры.	Общая аналитика и ручной поиск; рекомендации проверяются на синтетике.
Отправка конкретной заявки	Broker integration gate, trading credential, разрешённый режим, повторная проверка и одноразовое подтверждение.	Подготовка черновика / переход к брокеру без ложного сообщения об исполнении.
Автоматические сделки без каждого подтверждения	Отдельный будущий продукт, мандат, юридические и технические допуски.	В версии 1.0 не реализуются.

Серверная формула допуска

`allowed = authenticated AND owner_bound AND feature_enabled AND legal_gate AND entitlement AND data_ready AND policy_passed`. Для операций добавляются свежая доступность инструмента и подтверждение точной версии. Отсутствующее значение означает отказ для операции, но не отказ в просмотре объяснения.

Разрешения двух тестировщиков

Обычная роль user, собственные broker accounts, отдельные настройки, события, чаты, уведомления и квоты. Никаких специальных обходов для «первого пользователя». Доступ к релизу задаётся когортой rollout, а не повышением роли. Административная панель и сервисные учётные записи живут отдельно.

Персональный подбор под цель и риск может относиться к индивидуальным инвестиционным рекомендациям. Фраза «это не рекомендация» не отменяет фактическую сущность услуги. Проверка требуется до включения такой функции и для малого пилота. [S4, S5]

07. Навигация и карта экранов

Один источник навигации: постоянная левая панель на большом экране и выдвижное меню на телефоне. Это сохраняет направление исходного плана; действующий AGENTS.md ещё нужно прочитать.

Пункт / маршрут проекта	Содержимое	Основное действие
Главная `/home`	Капитал, статус наблюдения, важное, следующий шаг, краткий график.	Открыть важное или продолжить настройку.
Портфель `/portfolio`	Позиции, риск, распределение, выплаты и история результата.	Открыть актив.
События `/events`	Важные новости, изменения риска, качество данных и история.	Прочитать разбор.
Поиск `/assets`	Доступный каталог, фильтры, избранное и сравнение.	Изучить актив.
Стратегия `/strategy`	Подтверждённые предпочтения и сохранённые версии.	Посмотреть изменения.
Решения `/decisions`	Предложения после legal gate или аналитические сценарии.	Проверить влияние.
Сделки `/orders`	Активные заявки OmniCIO, результат и сверка.	Проверить статус / отменить, если разрешено.
Ассистент `/assistant`	Личный чат, контекст выбранного счёта, история и память.	Задать вопрос.
Цели `/goals`	Цели капитала/дохода, сценарии и достижения.	Создать цель.
Профиль и сервис `/settings`	Подключения, устройства, уведомления, тариф, данные, справка.	Управлять настройками.

Компоновка

Desktop от 1200 px: sidebar 240 px, рабочая область max-width 1200 px, отступы 24-32 px. 768-1199 px: меню по кнопке, 24 px по краям, максимум две колонки. До 767 px: одна колонка, поля 16 px; минимальная поддерживаемая ширина 320 px. Обычное меню не дублируется второй нижней навигацией. В торговом сценарии допустима закреплённая панель действия.

Первые 4 пункта раскрыты всегда. Группа «Управление» содержит Стратегию/Решения/Сделки; «Помощь» - Ассистент/Профиль. Активный пункт имеет текст, контрастную подложку и aria-current. Поиск доступен из topbar и из пустого портфеля. Ctrl/Cmd+K не перехватывать внутри ввода без явного режима.

Возврат браузером восстанавливает фильтры, scroll и выбранный период. Deep link после авторизации возвращает к исходному объекту только после проверки владельца. Старые маршруты получают безопасное отображение/redirect без потери пользовательских ссылок.

08. Визуальная система: точные токены

Сохранить логотип OmniCIO. Ввести семантические CSS-переменные, светлую и тёмную темы и единые размеры. Это проектные значения для внедрения и проверки контраста.

Токен	Светлая тема	Тёмная тема
`--bg` / `--surface`	#F4F7FB / #FFFFFF	#07111F / #0E1A2A
`--surface-raised` / `--border`	#E8EEF6 / #CBD5E1	#132338 / #3E526D
`--text` / `--text-muted`	#121B2B / #566275	#F4F8FF / #ADBACB
`--action-bg` / `--action-text`	#245EEA / #FFFFFF	#70B7FF / #07111F
`--success` / `--success-soft`	#107A57 / #E7F7EF	#63DDB0 / #12352C
`--warning` / `--warning-soft`	#92510A / #FFF2DA	#F3C56A / #392D15
`--danger` / `--danger-soft`	#B42318 / #FFEFEF	#FF969B / #3C1D26
`--info` / `--focus`	#075F87 / #245EEA	#43D7E6 / #8BC4FF

Типографика и сетка

Стек system-ui с качественной кириллицей; локальный шрифт добавлять только после проверки лицензии и веса. Body 16/24 px, вторичный 14/20, подпись 12/18, H1 32/40 desktop и 26/34 mobile, H2 22/30, число капитала 36/44 и 30/38. Денежные значения - tabular-nums; ₽ после числа, группировка разрядов локалью ru-RU. Не показывать больше точности, чем даёт источник.

Шаг отступов 4 px: 4/8/12/16/24/32/48. Радиус поля 10 px, кнопки 10 px, карточки 16 px, sheet 20 px сверху. Карточка: padding 20 desktop / 16 mobile, border 1 px; тень только у всплывающих элементов: 0 8 24 rgba(7,17,31,.12). Нет стеклянной прозрачности за финансовыми числами.

Контраст и семантика

Основной текст минимум 4.5:1, крупный - 3:1; контуры и состояния значимых controls - 3:1 относительно соседних цветов. Границы декоративных карточек не заменяют видимые границы полей. Любой риск обозначается ещё словом/значком. Для отрицательной доходности красный допустим, но «Продать» не красится в аварийный цвет по умолчанию: продажа может быть обычным действием.

Тема по умолчанию следует системе, затем сохраняет явный выбор. Смена темы не меняет финансовый смысл цветов, положение данных и выбранные фильтры.

09. Каталог компонентов и состояний

У каждого компонента должны существовать образцы default, focus, loading, empty, error, stale и disabled с объяснением, где это применимо.

Компонент	Спецификация	Поведение
PrimaryButton	Высота 44 px минимум; horizontal padding 16; текст 16/22.	Одно основное действие на блок. При отправке текст «Проверяем…», повторный submit блокируется сервером.
Secondary / LinkButton	Тот же hit area; фон нейтральный / прозрачный.	Для «Подробнее», «Отменить», «Источники». Важные действия не прятать в иконку.
IconButton / HelpButton	Видимый символ 20-24 px, зона 44×44.	Accessible name, focus-ring 2 px + offset 2. Tooltip не является единственным названием.
Input / NumberInput	Высота 44; label сверху; единица справа; текст 16 px.	Ошибка рядом с полем, значение сохраняется. Нет автоматической отправки при blur.
ToggleRow	Название, короткое пояснение, switch 44×24 внутри 44 px зоны.	В стратегии меняет черновик; в бытовой настройке допустимо автосохранение с статусом.
RangeWithNumber	Track 4 px; thumb 24 px; drag area 44 px; числовой дубль.	Arrow ±1 шага, Page ±10, Home/End; min/max и единица озвучиваются.
StatusChip	Иконка 14 px + короткий текст, высота 24-28 px.	«Свежие», «Устарели», «Не проверено» различаются словами.
DataCard	Заголовок, значение, объяснение, дата, максимум один главный CTA.	Без skeleton поверх ранее показанных данных при фоновом обновлении.
Dialog / Sheet	Desktop max 560 px; mobile max-height 85dvh; safe-area.	Focus trap для modal, Esc/крестик, возврат фокуса; предупреждение о несохранённом draft.
Toast / InlineAlert	Toast для обратимых бытовых действий, alert для блокирующих.	Финансовый результат остаётся в истории; не исчезает только через toast.

Ошибки и загрузка

До 300 мс не мигать skeleton. После - локальная загрузка с стабильной высотой. После 5 с показать объяснение ожидания и отмену для необязательных запросов. Ошибка сообщает, что произошло, что сохранено и что можно сделать. «Повторить» допустимо для чтения; при неопределённом статусе заявки только «Проверить статус».

Пустое состояние всегда отвечает «почему пусто» и даёт один CTA. Ноль, отсутствующее значение и неизвестное значение - разные состояния. Сумма не перескакивает на 0 при потере сети.

10. Подсказка при удержании: доступный вариант

Идею пользователя сохраняем как быстрый жест, но добавляем обычное нажатие и клавиатуру. Только удержание исключает часть людей и мешает прочитать длинную подсказку. [S15, S16]

Вид значка

Обычная справка: `circle-info`, круг 18 px, stroke 1.8, нейтральный серый; подложка #EEF2F7, hit area 44×44, gap от label 4 px. В тёмной теме подложка #132338, знак #ADBACB. Красный `circle-alert` используется только рядом с реальным риском/ошибкой; серо-красная справка для всех функций создаёт постоянное ощущение опасности.

Точная логика взаимодействия

- Touch: pointerdown запускает таймер 300 мс. Смещение пальца больше 10 px отменяет подсказку и сохраняет скролл. После 300 мс открывается временный popover; pointerup, pointercancel, потеря видимости страницы закрывают его.
- Короткий tap до 300 мс открывает закреплённую справку. Повторный tap, Esc, крестик или нажатие вне закрывают. После long press подавить синтетический click ровно для этого жеста, иначе подсказка откроется повторно.
- Mouse: hover через 350 мс показывает справку; указатель можно перевести на неё, не теряя текст. При уходе с обоих элементов закрытие через 150 мс. Клик закрепляет.
- Keyboard: focus показывает справку, Enter/Space закрепляет, Esc закрывает. Текст доступен через aria-describedby. Если внутри есть интерактивная ссылка, это popover/dialog с управлением фокусом, а не role=tooltip.

Геометрия и содержание

Ширина 240-320 px, max-width calc(100vw - 32px), padding 12, radius 12, border 1 px, лёгкая тень. Расположение над кнопкой с offset 8 px; если места нет - снизу; не закрывать редактируемое значение. 1-3 предложения, обычно 25-45 слов. Заголовок - название поля; текст отвечает «что означает» и «на что влияет». Ссылка «Подробнее» только в закреплённом варианте.

Поле	Текст готовой короткой подсказки
Акции	Разрешает учитывать акции при подборе. Их цена может заметно меняться. Сам переключатель ничего не покупает.
Реинвестирование	После подтверждённой выплаты система проверит варианты её использования. Покупка потребует отдельного подтверждения.
Доходность к погашению	Расчёт по текущей цене и известным выплатам при удержании до выбранной даты. Это не гарантия фактического дохода.
Рейтинг	Оценка кредитного риска от рейтингового агентства. Он не гарантирует возврат денег и может измениться.

11. Иконки, графические эффекты и анимация

Использовать существующий SVG-подход. Единый внутренний sprite, а не несколько библиотек и не иконки-шрифты.

ID SVG	Геометрическая метафора / назначение	Правило
home / wallet / chart-pie	Дом; кошелёк; круг с сектором - Главная, Портфель, распределение.	Один вариант каждого символа во всём приложении.
radar / search / sliders	Радар; лупа; три горизонтальных регулятора - События, Поиск, Стратегия.	Радар статичный, без постоянного вращения.
list-check / receipt / messages	Список с галкой; квитанция; два облачка - Решения, Сделки, Ассистент.	Значок ИИ не означает подтверждённый факт.
target / medal / bell	Мишень; медаль; колокол - Цели, Достижения, Уведомления.	Badge только для непросмотренного важного.
link / shield-check / refresh	Цепь; щит; круговая стрелка - Подключение, защита, обновление.	Щит не означает гарантию капитала.
circle-info / circle-alert	Буква i / восклицательный знак в окружности.	Справка нейтральная; проблема amber/red.
external-link / file-text / clock	Стрелка наружу; документ; часы - Источник, отчёт, время данных.	URL доступен по текстовой ссылке.
eye / eye-off / lock	Глаз; перечёркнутый глаз; замок - скрыть суммы, ограниченный доступ.	Не скрывать смысл ошибки за замком.
plus / minus / check / x / chevron	Изменить количество; подтверждение; закрыть; раскрыть.	aria-label у кнопок без видимого текста.

Создание и хранение

`web/assets/icons.svg` как предлагаемое место после проверки дерева. Каждый symbol имеет `viewBox="0 0 24 24"`, fill=none, stroke=currentColor, stroke-width=1.8, round cap/join. Минимум внутренней пустоты 2 px. Декоративные SVG имеют aria-hidden=true. Таблица `iconMap` связывает semantic name и symbol ID; менять метафору через один контракт. При использовании стороннего набора сохранить его лицензию и атрибуцию в THIRD_PARTY_NOTICES; выбор набора - отдельная задача дизайнера.

Motion tokens

Hover/focus 120 мс; раскрытие 180 мс; sheet 220 мс; easing cubic-bezier(.2,.8,.2,1). Только opacity/transform, сдвиг максимум 4 px у карточек. Уведомление один раз мягко подсвечивается 600 мс, затем статично. График при смене периода 150 мс без «бегущих денег». У prefers-reduced-motion все декоративные движения выключены; смысл состояния сохраняется. Ни салютов за сделки, ни мигающих котировок.

12. Первый вход и активация

Мастер должен показать, что уже работает, что ещё не настроено и какие действия сервис вправе выполнять.

Шаг	Экран / содержание	Результат и ошибка
1. Вход	VK ID, отдельные согласия и 18+, статус закрытого тестирования.	Сессия user. Если мест нет - объяснение без создания частичного аккаунта.
2. Выбор старта	«Подключить свой счёт» и «Посмотреть демо».	Демо имеет постоянную маркировку и отдельные синтетические данные.
3. Подключение	Инструкция получения минимального read-only токена; скрытое поле; проверка на сервере.	Список доступных собственных счетов. Неверный/отозванный credential не хранить.
4. Предпочтения	Цель, горизонт, необходимость вывода, отношение к колебаниям, разрешённые классы.	Сохранённый черновик; «Не знаю» разрешено. При пробелах - аналитика без персонального подбора.
5. Первый результат	Состав портфеля, время синхронизации, 1-2 понятных наблюдения.	CTA «Открыть портфель». Запрос push только после объяснения пользы.

Детали сценария

Вверху текст «Шаг 2 из 5», а не индикатор с неясной оценкой. Кнопки «Назад» и «Продолжить», прогресс хранится сервером. Выход не теряет уже принятые документы и успешно созданную связь. Если токен скопирован с пробелами - обрезать края, но не менять содержимое. Поле не попадает в аналитику, запись сессии, буфер истории форм и логи. После сохранения показывать только факт и дату подключения, не возможность раскрыть секрет.

Получение портфеля: состояния «Проверяем доступ», «Получаем позиции», «Проверяем выплаты»; не рисовать фиктивные проценты. После 15 секунд показать возможность продолжить позже. Пустой счёт - нормальный результат: «Активов пока нет. Можно изучить инструменты». Не создавать покупку ради активации.

Готовность профиля

Две независимые шкалы: «Подключение готово» и «Предпочтения заполнены». Отсутствие анкеты не блокирует просмотр собственных активов. «Портфель в 100% акциях» не означает согласие на высокий риск. Перед сохранением показать понятное резюме: «Вы выбираете доход, горизонт 3 года, резерв 50 000 ₽, без высокорисковых облигаций».

Обновления для существующих двух пользователей

Один экран «Что изменилось»: до 3 пунктов и кнопка продолжения. Не заставлять снова проходить мастер. Новые согласия запрашивать только для новой обработки/возможности. Финансовые параметры не переустанавливать значениями по умолчанию.

13. Главная: структура и все состояния

Главная отвечает на три вопроса: сколько сейчас средств, есть ли важное изменение, какой следующий шаг доступен.

Порядок блоков

1. Topbar: заголовок, поиск, скрыть суммы, профиль. Рынок/курс - компактный необязательный блок без marquee.
2. PortfolioHero: общая стоимость в выбранной валюте, результат дня с пояснением влияния пополнений, доступные средства. Рядом время данных.
3. Статус наблюдения: «Работает», «Есть важное событие», «Данные обновляются» или «Наблюдение прервано». «Всё спокойно» допустимо только при достаточном покрытии.
4. «Важно сейчас»: максимум 3 события, по тяжести и актуальности; остальные в центре событий.
5. Следующий шаг: завершить настройку, прочитать разбор, проверить предложение либо «Действий не требуется».
6. Краткий график и ближайшие подтверждённые выплаты. Ассистент открывается отдельной кнопкой, не перекрывает цифры плавающим виджетом.

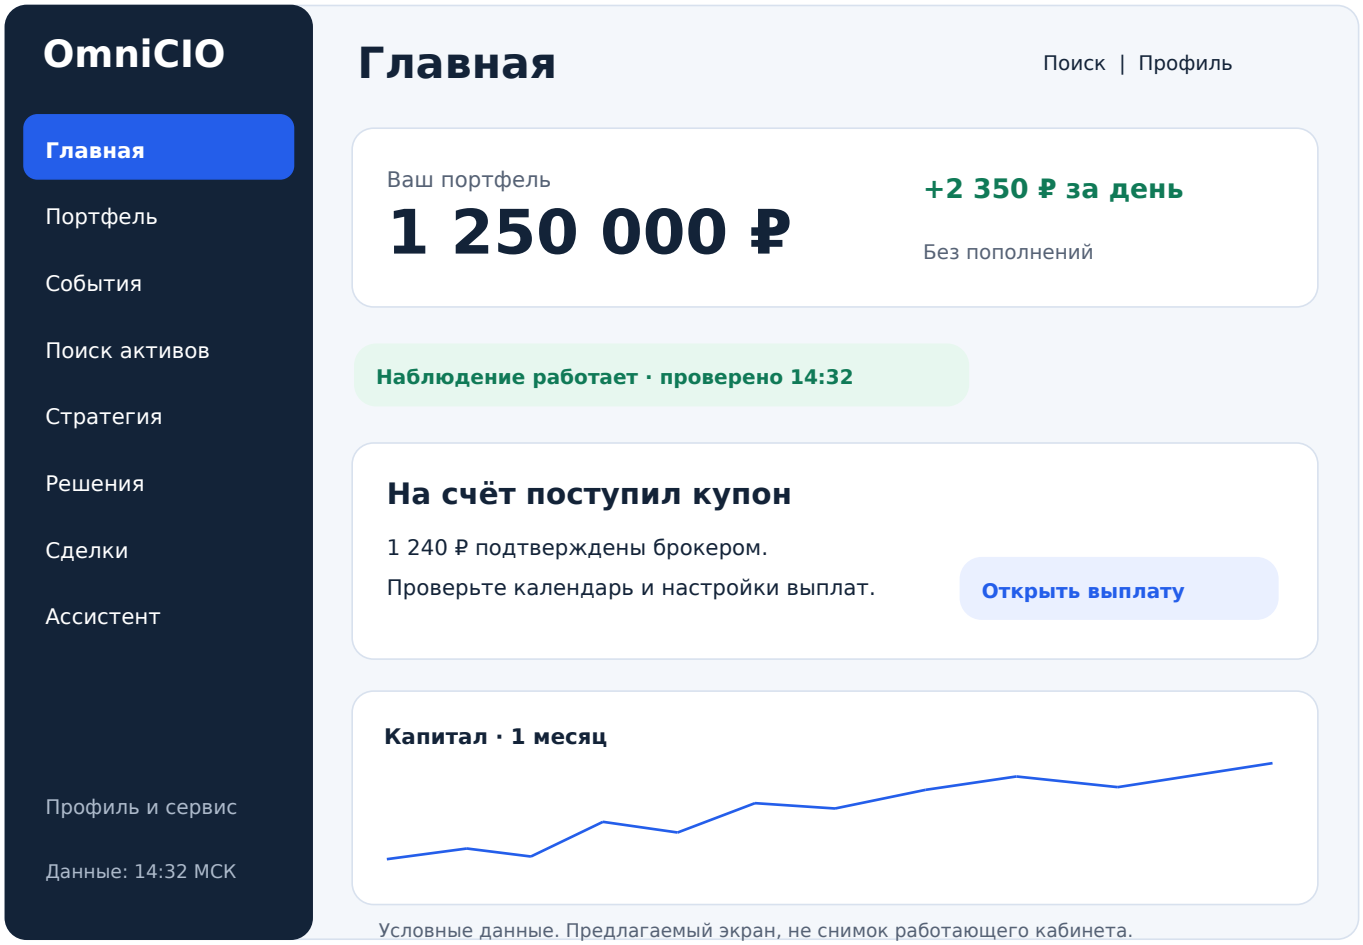
Состояние	Текст / отображение	Действие
Не подключён счёт	«Подключите счёт, чтобы увидеть свой портфель».	Подключить / демо.
Пустой портфель	0 ₽ только при подтверждённом нуле; не «нет данных».	Изучить активы.
Первичная загрузка	Skeleton только карточек, пояснение этапа.	Продолжить позже.
Частичная загрузка	Показать доступное и «Не все данные получены».	Проверить подключение.
Данные устарели	Сохранить цифры с датой и amber-статусом.	Обновить, торговые CTA ограничены.
Наблюдение без событий	«В проверенных источниках важных изменений нет».	Ничего не требуется.
Ожидает действия	Причина + один безопасный CTA.	Открыть предложение/событие.
Нет сети	«Показана последняя сводка от …».	Ждать сеть; финансовые действия недоступны.

Согласованность показателей

Все значения карточки относятся к одному snapshot_id. Если котировки новее позиций, API возвращает обе даты и признак mixed_freshness; UI не скрывает это. Скрытие сумм заменяет деньги на «••••», распространяется на графики/чат-превью и запоминается на устройстве. Серверные права от этого не меняются.

14. Предлагаемый макет Главной

Векторный эскиз фиксирует иерархию и плотность. Размеры интерфейса определяются токенами, а данные ниже являются демонстрационными.



Условные данные. Предлагаемый экран, не снимок работающего кабинета.

Детали реализации

Карточка капитала получает наибольший визуальный вес, статус наблюдения - второй. Новости и следующий шаг не конкурируют с крупными рыночными котировками. Если событий несколько, сначала безопасность/неопределённая заявка, затем существенный риск, после - выплаты.

На мобильном sidebar превращается в drawer. Два значения в PortfolioHero допускаются в одной строке только при отсутствии переполнения; иначе становятся вертикально. Валютные суммы с длинными дробями не уменьшают шрифт: точность сокращается по финансовому контракту, подробности открываются отдельно.

Условия приёмки

На 320 px нет горизонтального скролла страницы; при масштабе 200% все действия доступны. При изменении значения карточки layout shift не превышает установленный бюджет. Пользователь видит, что выплата подтверждена, и не принимает рост из-за пополнения за инвестиционную прибыль.

15. Портфель, графики и распределение

Вкладки внутри портфеля: «Активы», «Распределение», «Выплаты», «Результат». На телефоне - доступный горизонтальный tablist со скроллом, а не скрытая вторая навигация приложения.

Представление	Что рисовать	Методика и взаимодействие
Капитал	Линейный график стоимости, периоды 1М / 3М / 1Г / Всё.	Отдельный режим чистых внесённых средств. Пропуски не соединять как наблюдавшиеся данные.
Результат	TWR при достаточной истории; рублёвый результат отдельной строкой.	MWR/XIRR только при корректных потоках; если не вычисляется - объяснить причину.
Эмитенты / группы	Горизонтальные полосы: доля, сумма, лимит.	Объединять связанные компании; «Не классифицировано» отдельно.
Сектора / валютный риск	Stacked bar + таблица, максимум 6 цветов + «Прочее».	Валюта выплаты и экономическая валютная экспозиция переключаются раздельно.
Рейтинги	Полосы по согласованным категориям, доля без рейтинга.	Эмитент/выпуск, агентство и шкала видимы; нет среднего буквенного рейтинга.
Погашения / выплаты	Колонки по месяцам, купоны/дивиденды/номинал разными сериями.	«Объявлено» и «Сценарий» визуально различаются заливкой/штрихом.
Риск	Набор отдельных индикаторов, не один магический балл.	Концентрация, кредит, ставка, ликвидность, валюта, качество данных.

Правила отрисовки

Ось времени в timezone пользователя; расчёты событий хранятся UTC. Денежная ось подписана ₽/тыс. ₽/млн ₽, без неясного K. Не обрезать ось столбчатой диаграммы выше нуля. Для line chart масштаб можно адаптировать, но диапазон виден. Выбор точки показывает дату, стоимость и потоки; доступны клавиши Left/Right и текстовая таблица. Никаких 3D-кругов.

Список активов

По умолчанию сортировка по доле; поля: название, количество в бумагах и лотах, стоимость, доля, результат, доступность данных. Desktop - таблица с фиксированным заголовком; mobile - карточки. Сортировка не меняет неожиданно порядок при каждом тике: новое значение обновляется на месте, пересортировка по команде/смене фильтра.

Экспорт собственного состава - CSV с безопасным экранированием формул и датой. Публичный share-link портфеля в 1.0 не нужен. Не выдавать вложения пользователя в общий кэш графиков.

16. Карточка актива и компании

Один экран инструмента связывает позицию пользователя, сведения о выпуске, факты эмитента, источники и доступное действие.

Верхняя часть

Название + тикер + ISIN/UID в подробностях, тип инструмента, торговая валюта, актуальная цена с единицами и задержкой, доступность покупки/продажи. Если актив есть: количество, средняя цена с методикой, стоимость, доля портфеля и результат. Кнопки «Купить», «Продать» открывают проверку; до разрешения торговли - «Подготовить расчёт» или понятный переход в брокерское приложение.

Блок	Акция	Облигация / фонд
«Что это»	Компания, бизнес, сектор, откуда доходы.	Облигация: кому одалживаем, срок, вид купона. Фонд: что внутри и издержки.
Доход / выплаты	Решение о дивидендах, дата фиксации, статус.	Купон, номинал, НКД, амортизация, погашение; у фонда распределение по правилам.
Качество / риски	Отчётность, долг, денежный поток, корпоративные события.	Рейтинг выпуска и эмитента; субординация, оферта/call, ликвидность.
Новости	Связанные с конкретным эмитентом проверенные события.	Не переносить событие материнской компании без связи с обязательством.
Документы	Последние годовой/промежуточные отчёты и раскрытия.	Проспект/условия выпуска, решения по купону/оферте, документы фонда.

Разбор отчётности с ИИ

Показывать период, стандарт МСФО/РСБУ, консолидированность, валюту и единицы. «Что изменилось» строится по сопоставимым периодам, не квартал к годовому итогу. Числа извлекаются в проверяемую таблицу; текст ИИ ссылается на страницу/таблицу. Если OCR не уверен - значение не используется в сильном выводе. Нет отчёта - нет выдуманного коэффициента.

Раскрытие рейтинга

Пример: «AA(RU), АКРА, рейтинг выпуска, подтверждён 12.08.20XX, прогноз стабильный». Текст: «Агентство оценивает способность выполнить обязательства. Рейтинг может меняться». Национальную шкалу не считать международной; разные агентства связывать только утверждённой таблицей соответствий. [S13]

Связь с ассистентом

Кнопка «Объяснить этот актив» передаёт ссылку на instrument_id и разрешённую часть позиции, а не весь аккаунт. Под чатом виден выбранный контекст. Ссылки открываются с указанием источника и даты; ошибки источника не превращают старые данные в новые.

17. Поиск активов и доступность пользователю

Поиск должен быть полноценным каталогом. Персональная подборка - отдельный режим внутри каталога, который включается только после соответствующих допусков.

Интерфейс

Поле «Название, тикер или ISIN», debounce 250 мс, отмена устаревшего запроса. Быстрые chips: акции, облигации, фонды, избранное. По умолчанию включён «Доступно моему счёту». Результаты имеют cursor pagination по 30 строк; фильтры записываются в URL без персональных сумм и идентификаторов счёта. Пустой ответ перечисляет активные ограничения и предлагает снять конкретный фильтр, но не снимает его сам.

Статус	Условия	Что видит пользователь
BUY_AVAILABLE	Подтверждены требования счёта, инструмента и операции.	«Доступно для покупки». Повторная проверка перед заявкой.
NEED_TEST	Требуется тестирование соответствующей категории.	«Сначала пройдите тест у брокера». Ссылка на официальную помощь.
QUAL_ONLY	Выпуск только для квалифицированных, подтверждённого статуса нет.	Скрыт в default-поиске; по точному запросу виден с объяснением.
API_UNAVAILABLE	В приложении брокера операция может быть доступна, API её не разрешает.	«Через OmniCIO недоступно». Не путать с полным запретом владения.
SELL_ONLY / RESTRICTED	Покупка запрещена; продажа имеющейся позиции проверяется отдельно.	Сохранить позицию в портфеле и отдельно описать ограничения.
UNKNOWN	Ответ брокера неполный, устарел или не подтверждает право.	«Не удалось проверить доступность». Подбор покупки блокируется.

Серверная проверка

Учитывать GetInfo (`qual_status`, `qualified_for_work_with` по текущему контракту), свойства инструмента (`for_qual_investor_flag`, `api_trade_available_flag`, `buy_available_flag`, `sell_available_flag`, ограничения ИИС), тип/статус счёта, торговый режим, валюту, лот и свежесть. Эти сигналы не гарантируют принятия брокером; решающая проверка повторяется в preflight, отказ брокера остаётся допустимым результатом. [S6, S7, S8]

Фильтры облигаций

Доходность и дата расчёта, рейтинг/агентство, срок, дюрация, купон fixed/floating, валюта номинала и расчёта, отрасль, амортизация, оферта, ликвидность, цена лота с НКД. Сортировка по умолчанию - понятная стабильная «Сначала наиболее ликвидные» до появления юридически разрешённого персонального ranking. «Максимальная доходность» не ставится по умолчанию.

18. Стратегия и точная логика ползунков

Пользователь выбирает понятные цели, а система переводит их в проверяемые числовые ограничения. Слово «Авто» заменяем «Помочь настроить», чтобы оно не означало автоматическую торговлю.

Поле	UI / диапазон проекта	Сохранение и проверка
Цель	Доход / накопление / сочетание; короткое пояснение.	Подтверждённый выбор; не выводить молча из активов.
Горизонт	До 1 года / 1-3 / 3-5 / 5+ / не знаю.	Диапазон, а не выдуманная точная дата.
Плановый вывод	Сумма + дата; optional.	Сумма ≥0, дата в будущем; резерв учитывает срок.
Резерв	Числовой ввод ₽ + подсказка.	Не считать все деньги инвестируемыми. «Не знаю» не равно 0.
Разрешённые классы	Switches; облигации, акции, фонды.	Разрешение анализа не является согласием на покупку.
Доля класса	0-100%, шаг 1%; точный числовой дубль.	Ползунки в draft; суммы целей + резерв =100%.
Валютная экспозиция	Целевой диапазон 0-100%, шаг 5%; пояснение риска.	Не складывать с классами: это другая ось классификации.
Порог доходности	«Не ниже ключевой», либо пользовательский минимум.	Применимость по типу доходности/валюте на следующей странице методики.
Риск	Понятные сценарии потерь вместо обещания «надёжность 90%».	Окончательная методика профиля утверждается отдельно; анкета не гарантирует просадку.

Связанные ползунки

Режим «Распределять оставшееся»: пользователь закрепляет долю класса замком; оставшаяся доля распределяется между незакреплёнными пропорционально текущим значениям. Если все остальные закреплены, изменение ограничивается допустимым остатком с пояснением. Запрещённый класс получает target=0. Денежный резерв показывать отдельным остатком. Нельзя скрыто включать запрещённый класс ради суммы 100%.

Изменение ползунка немедленно меняет локальный draft и preview, но не сохранённый профиль. Серверный пересчёт after debounce 400 мс; ответ содержит draft_hash, чтобы устаревшая оценка не перерисовала новый draft. Кнопка «Посмотреть изменения» показывает diff: значения, влияние, неразрешимые ограничения. Затем «Сохранить стратегию». Undo возвращает новую версию, а не переписывает историю.

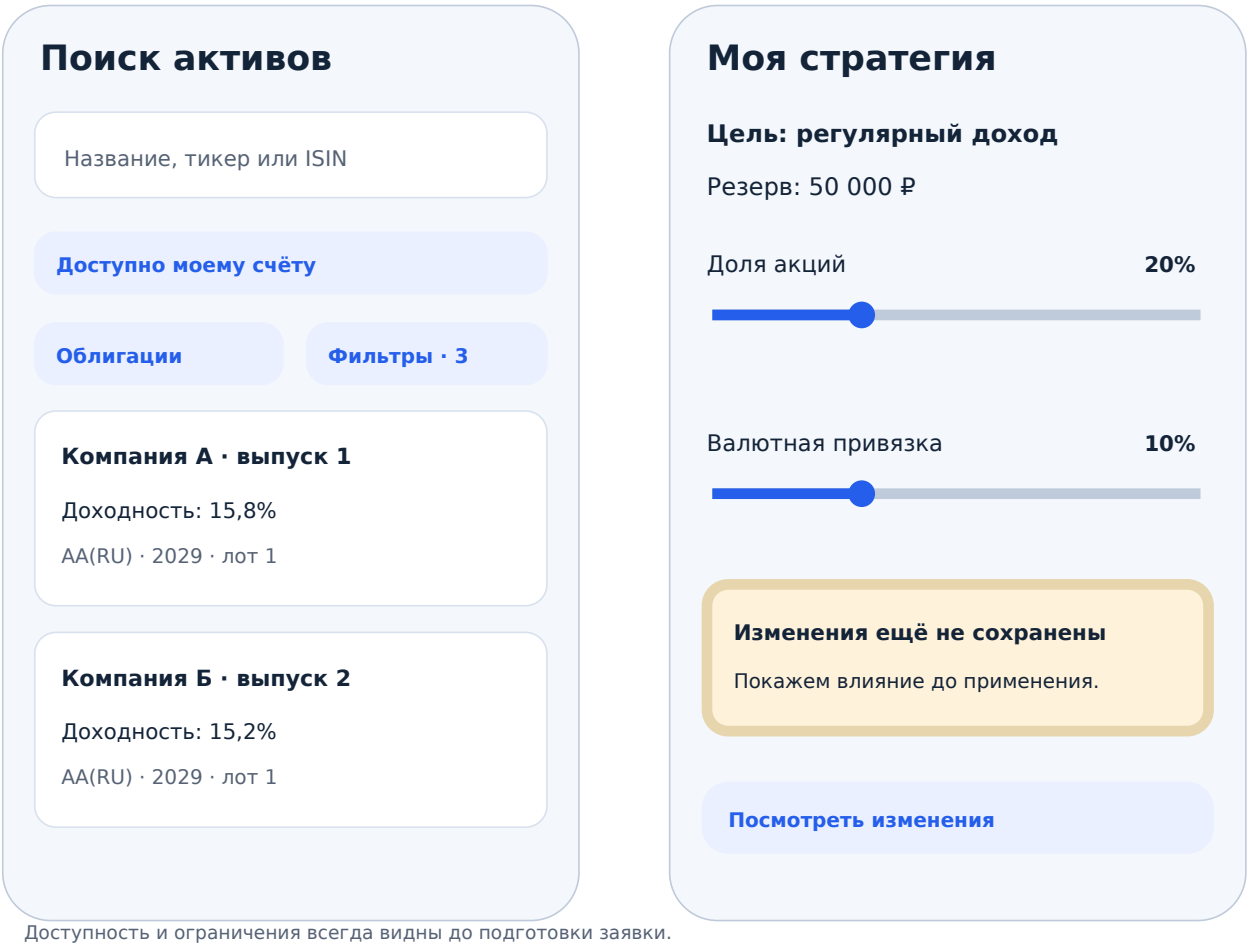
Сохранение создаёт strategy_version и событие StrategyChanged. Зависимые неподтверждённые планы инвалидируются. Уже отправленная брокеру заявка не исчезает: система отдельно проверяет необходимость отмены и не считает изменение профиля командой на отмену.

Несколько подходов, одна система правил

Профиль хранит цель и ограничения конкретного человека; presets «Доход», «Накопление» и «Сочетание» создают только редактируемый черновик. Параметры, включая порог ключевой ставки, имеют origin=explicit/preset/imported и версию. Переход между подходами не меняет уже подтверждённые условия молча. Qwen объясняет альтернативы и последствия, но не навязывает один preset всем пользователям.

19. Мобильный поиск и настройка

Два соседних эскиза показывают разные экраны. Примеры рейтингов и доходностей вымышлены и не являются рекомендациями.



Доступность и ограничения всегда видны до подготовки заявки.

Поведение на телефоне

Поиск всегда остаётся выше результатов; фильтры открываются в sheet с кнопками «Сбросить» и «Показать N инструментов». Изменение draft фильтров не перезагружает весь экран до применения. Для длинного названия максимум 2 строки, далее раскрытие. На карточке сразу видны основные параметры и ограничение доступа, не только красивый процент.

Ползунок сопровождается числом, которое можно изменить нажатием. У вертикального скролла приоритет, пока жест не начал горизонтальное перетаскивание; помощь находится отдельно от thumb. При открытии клавиатуры sticky action поднимается над ней либо входит в поток, не закрывая поле. Tap targets не перекрывают соседние значения.

Обязательные сценарии

Ширина 320/360/390/768, крупный системный шрифт, landscape, iOS safe area, Android back, внешняя клавиатура и screen reader. На медленной сети карточки сохраняют высоту, а активные фильтры остаются доступны. Закрытие меню возвращает focus на кнопку открытия.

20. Выплаты, цели и достижения

Доход от владения активами, возврат вложенного капитала и изменение рыночной стоимости всегда показаны раздельно.

Календарь выплат

Переключение месяц/год; summary «Объявленные выплаты», «Оценочные выплаты», «Возврат номинала». У события: инструмент, количество на дату entitlement, купон/дивиденд/амортизация/погашение, gross, оценка net при наличии налоговых данных, валюта, источник и статус. Дата выплаты эмитентом, дата фиксации прав и ожидаемое зачисление брокером не смешиваются.

Статусы: ожидается решение → объявлено → дата прошла, ожидаем подтверждение → подтверждено брокером → скорректировано / отменено. Если денег ещё нет, не предлагать тратить их как свободный остаток. Повторно загруженное событие не удваивает календарь.

Цель капитала

Поля: название, сумма, дата, валюта, текущая привязка к портфелю, планируемые пополнения. Выбор «в текущих ценах» задаёт сценарий инфляции; номинальная цель по умолчанию явно обозначена. Прогресс = текущая относимая стоимость / цель; отдельная линия показывает внесённые пользователем средства. Одна и та же сумма не распределяется между двумя целями без явного выбора долей.

Цель ежемесячного дохода показывает средний прогноз за 12 месяцев и фактическую сезонность. Среднее 10 000 ₽/мес. не означает платёж 10 000 ₽ каждый месяц. Достижение цели по рынку помечается датой; падение капитала не стирает историю достижения, но текущий прогресс меняется.

Достижение	Условие выдачи	Визуальное поведение
«Первый порядок»	Завершён профиль и понятны ограничения.	Нейтральная медаль, дата, короткое объяснение.
«Контроль настроен»	Проверено подключение и каналы уведомлений.	Небольшое сообщение один раз.
«Разобрался в выплатах»	Завершён короткий обучающий сценарий.	Значок книги; не оценка компетентности для допуска к торговле.
«Цель достигнута»	Подтверждён порог цели и дата snapshot.	Статичная карточка, анимация только opt-in.

Подарки в первой линии - цифровые отметки или ограниченный тест расширенной аналитики с прозрачным сроком. Никаких призов за частые покупки, использование плеча, увеличение суммы риска или приглашение людей ради инвестиционной активности.

21. Уведомления, PWA и ежедневный обзор

Фоновое наблюдение выполняется сервером, push только сообщает о событии. Закрытый PWA не останавливает фоновые задачи. Доставка на устройство не гарантируется. [S17, S18]

Тип	Доставка по умолчанию	Содержание
Безопасность / статус заявки UNKNOWN	Немедленно в центр; push при разрешении.	«Проверяем статус заявки. Не отправляйте её повторно».
Существенный риск	Центр + push; ночью согласно настройкам важности.	Что подтверждено и где открыть разбор. Без панического «срочно продавайте».
Купон / дивиденд	Центр; обычно общий дневной обзор.	Поступление подтверждено или пока ожидается.
Новость без влияния	Только карточка актива / дневная подборка.	Не создаёт badge важности.
Ежедневный обзор	В приложении ежедневно; push только opt-in.	Результат дня, выплаты, 1-3 факта, нужен ли шаг.

Расписание и ограничения

Обзор по умолчанию в 20:30 Europe/Moscow, пользователь меняет время и timezone. Если источники ещё не закрыли день, написать «по данным на ...», а не «итоги торгов». Тихие часы 22:00-09:00 как предлагаемый default. Пользователь отдельно выбирает, какие критические события допускают попытку доставки ночью; настройки ОС всегда имеют приоритет.

Не более 3 обычных push в день по умолчанию; критические инциденты не теряются и группируются по причине. Fingerprint = тип факта + субъект + эффективная дата + версия существенного изменения. Повтор разрешён при повышении важности, новых доказательствах или явном напоминании пользователя. Нет счётчика непрочитанных из сотни однотипных статей.

Privacy и техническое исполнение

Lock screen: «OmniCIO: есть обновление по вашему портфелю». Суммы и названия активов только opt-in. В payload opaque event_id без user_id, токенов и финансовых данных. Endpoint подписки - чувствительный capability; проверять домен провайдера, запрещать внутренние IP, ограничивать размер/частоту, защищать CSRF. 404/410 от push-сервиса отключают subscription; 429/5xx получают bounded backoff.

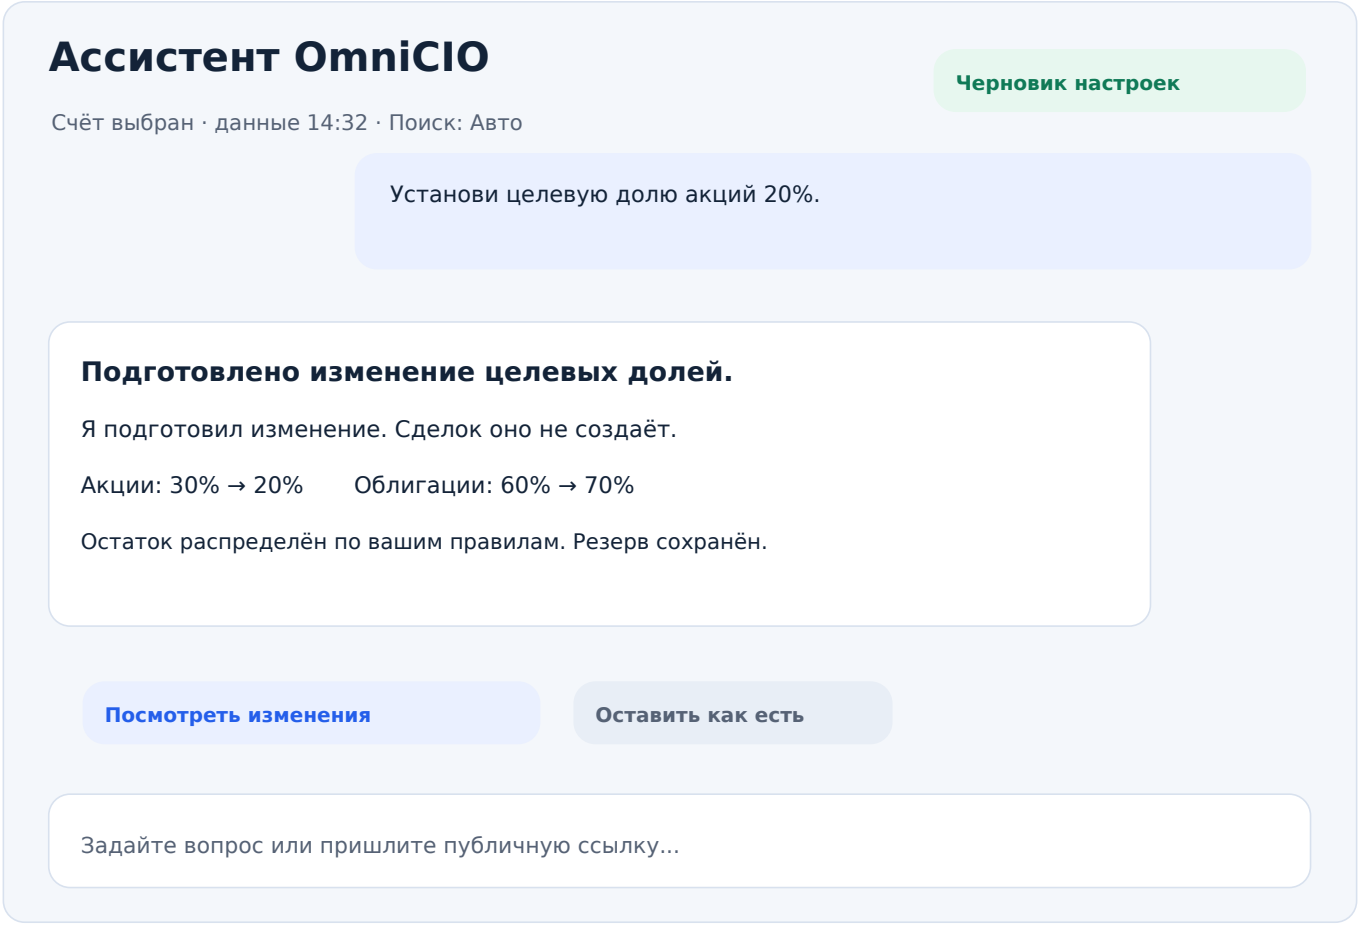
На iOS проверять поддержку Home Screen web app и объяснять установку по фактическим возможностям браузера. Разрешение запрашивается по кнопке пользователя. Отсутствие push не блокирует использование. Service worker кэширует только версионные публичные assets; API, чат, токены и портфель не попадают в общий cache. После logout очищаются приватные данные устройства.

Подключение Qwen после R8

До R8 обзоры формируются шаблонами. После R8 Qwen объясняет уже рассчитанные факты и связывает важные новости с позициями; дата snapshot и источники прикрепляются сервером. Обзор ставится в фоновую очередь заранее. Если к выбранному времени текст не готов, отправляется корректный шаблон; поздняя версия может появиться в приложении без второго push. Дневная сводка - по каждому аккаунту отдельно, общий разбор публичной новости переиспользуется. Критический статус заявки никогда не ждёт генерацию.

22. Личный ИИ: интерфейс и тон общения

Ассистент общается по-русски и помогает с вопросом пользователя. Можно обсуждать разные стратегии и общие темы; принадлежность портфеля и право на действие проверяются отдельно от содержания беседы.



Длина, режимы и управление

Простой вопрос - 1-3 предложения. Обычный ответ начинается с вывода, затем при необходимости содержит 2-4 коротких пункта; ориентир 40-90 слов, без искусственного обрыва важного пояснения. «Подробнее» открывает более длинный ответ, «Разобрать подробно» - задачу с прогрессом и предупреждением об ожидании. Число слов - ориентир интерфейса; вычислительные бюджеты задаются токенами в §40.

В шапке: выбранный счёт или «Без данных портфеля», «Объяснения» / «Подготовка изменений», меню памяти. Рядом с вводом кнопка с Globe2: «Поиск в интернете» - Авто / Всегда / Выкл. В режиме Авто свежие новости и текущие данные требуют инструмента; при Выкл ассистент сообщает дату доступного контекста и не выдаёт знания модели за текущую котировку.

Состояния чата

После отправки сообщение видно сразу; ответ сервера с run_id целится в ≤1 с. Последовательность: «Ожидает очереди» → «Ищу источники» / «Изучаю данные» → «Готовлю ответ» → «Готово». Если сервис загружает модель, показывать «Подготавливаю ассистента», а не неподвижное многоточие. Через 10 с показать содержательный статус; через 60 с - возможность продолжить ожидание, отменить или оставить подробную задачу в фоне.

Кнопка «Остановить» отменяет текущий run и его продолжения; неполный текст получает метку «Ответ остановлен». «Повторить» создаёт новый run, повтор сетевого запроса с тем же ключом - нет. Уже выполненное сохранение настроек не откатывается нажатием «Остановить»; результат операции

виден отдельно.

Визуальные правила

Сохранять токены §§08-11. Панель desktop 420-480 px либо отдельная страница, на mobile полный экран; поле ввода не перекрывает ответ и нижнюю safe area. Минимальная цель кнопки 44×44 px. Иконки Lucide: MessageCircle, Globe2, BookOpen, Clock3, Square, RotateCcw, SlidersHorizontal; размер 18-20 px, stroke 1,75. Focus ring 2 px, анимация появления 120 мс; reduced-motion убирает движение. Статус очереди нейтрально-серый, готовность сине-зелёная, ошибка красная только при фактическом сбое; цвет дублируется текстом.

Обновление streaming не перехватывает прокрутку, если человек читает выше; появляется «К новому ответу». Для screen reader статусы через aria-live polite, текст не озвучивать заново на каждый токен. «Источники · N» раскрывает издателя, заголовок, дату публикации/получения и ссылку; неизвестная дата так и подписана. Ссылки открываются безопасно в новой вкладке, внешняя ссылка помечена.

Персональность и проверка

История и память относятся к одному аккаунту пользователя. «Запомнить» показывает точный текст и назначение, затем требует подтверждения; можно удалить запись. Без подтверждения вывод из разговора не меняет профиль. «Общий вопрос» не прикрепляет портфель. В новом чате не наследуются чужие данные из предыдущего inference-запроса.

Некритические объяснения можно выводить потоком. Финансовые значения и действия показываются готовыми проверенными карточками; непроверенный черновой расчёт не становится активной кнопкой. Общий ответ не обязан иметь источник для каждой бытовой фразы; актуальное финансовое утверждение должно иметь проверяемую опору.

23. Покупка, продажа и ручное решение

Сервис должен уважать решение владельца. Он объясняет последствия и блокирует запрещённую/небезопасно неопределённую операцию, но не удерживает законную продажу ради собственной стратегии.



Два уровня ограничения

Hard block: нет полномочий, не подтверждена доступность, неизвестен статус предыдущей заявки, устарела критическая цена, нарушен обязательный лимит, рынок не принимает нужный тип заявки. Soft warning: продажа уменьшит ожидаемые купоны, повысит концентрацию или зафиксирует убыток. После понятного подтверждения soft warning пользователь может продолжить, если это разрешено политикой и правовыми условиями.

Обязательное подтверждение

Показать счёт, направление, инструмент, количество в лотах и бумагах, limit price с единицами, НКД, оценку комиссии, итог, срок заявки и срок approval. Кнопка содержит действие и количество, не абстрактное «OK». Изменение количества/цены создаёт новую версию. Предупреждение не использует фразы «вы потеряете будущие гарантированные деньги».

Поступление POST в систему, принятие брокером и исполнение - три разные стадии. В интерфейсе «Заявка принята» не равно «Куплено». Частичное исполнение показывается дробью и суммой; остаток не повторяется автоматически. В примере комиссия округлена, реальные значения получает сервер из проверенного расчёта брокера. [S9-S11]

24. Финансовое ядро и точность денег

Денежные расчёты детерминированы, версионируются и не поручаются языковой модели.

Единицы и типы

Хранить Decimal либо целые минимальные единицы с явной валютой. Quotation units/nano преобразовывать без float. Для облигации различать цену в процентах текущего номинала, цену в валюте номинала, НКД, валюту расчёта и размер лота. Амортизация меняет номинал; не считать всегда от первоначальных 1 000 ₽. Семантику каждого поля T-Invest закрепить контракт-тестом: разные методы могут ожидать разные единицы. [S10]

Базовые формулы для обычной рублёвой облигации

Чистая стоимость одной бумаги = текущий номинал × цена в процентах / 100. Грязная стоимость = чистая + НКД. Стоимость заявки = число лотов × бумаг в лоте × грязная стоимость + комиссия. Для валютных/замещающих выпусков добавить правила конвертации конкретного выпуска; общую формулу не применять вслепую.

Доходность рассчитывать по датированным денежным потокам с корректной day-count convention, купонами, амортизацией, офертами и ценой покупки. Сравнивать YTM, доходность к доступной оферте и осторожный вариант YTW только при достаточных условиях. Эмитентский call и право инвестора предъявить к оферте - разные события. Будущие неизвестные купоны плавающего выпуска остаются сценарием. [S12]

Пограничный случай	Ожидаемое поведение
Брокер не дал комиссию	Показать обоснованную оценку/диапазон и источник тарифа; не писать «0 ₽».
XIRR имеет несколько корней / нет корня	Не показывать случайный результат; объяснить ограничение метода.
Данные разных валют	Сначала зафиксировать курс и effective date; отдельно показывать валютный вклад.
Налог неизвестен	Gross известен; net пометить оценкой либо не показывать. Не назначать всем 13%.
Погашение	Возврат номинала идёт в денежный поток капитала; купон - в доход.
Брокер корректирует операцию	Append-only корректировка + пересчёт зависимых snapshot, без двойного счёта.

Проверка

Набор эталонных примеров: 5 лотов, lot=10; bond price 98,4%; амортизированный номинал; отрицательный cash; недостаток одного рубля; отложенная комиссия; FX settlement. Ошибка округления заявки не превышает минимальную расчётную единицу по контракту; расхождения с брокером сверх допуска останавливают исполнение.

25. Порог ключевой ставки и валютные облигации

Требование «не ниже ключевой ставки» реализуем как прозрачный пользовательский фильтр. Оно не заменяет кредитный и ликвидностный контроль.

Режим рублёвых облигаций

В запрошенном доходном профиле default ON: «Расчётная доходность в рублях до налогов, после известных комиссий, не ниже действующей ключевой ставки». Рядом указать дату ставки и дату оценки цены. Использовать доходность по денежным потокам, а не купонную ставку. Если сопоставимую доходность посчитать нельзя, статус UNKNOWN и исключение из автоматического подбора.

Кандидат проходит условие `comparable_yield >= key_rate + user_margin`; margin по умолчанию 0 п.п., дополнительно пользователь может задать запас. Проверка кредитного качества, лимитов и ликвидности выполняется независимо. Если все подходящие по качеству выпуски ниже порога - показать «Нет вариантов при текущих условиях» и оставить деньги, а не снижать качество ради процента.

Повышение ключевой ставки пересчитывает подбор и зависимые черновики, но не продаёт уже купленные бумаги. Цена существующей облигации, горизонт и цель могут делать удержание разумным при текущей доходности ниже нового порога. Пользователь может изучать такие бумаги вручную; выход за его hard-фильтр требует явного изменения стратегии.

Плавающий купон

Показывать формулу, базу/лаг пересмотра, спред, floor/cap и ближайший известный купон. Сравнение с ключевой - по согласованному сценарию будущей ставки; исторический купон не равен будущей эффективной доходности. Для автоматического режима по неизвестным будущим купонам нужен утверждённый консервативный сценарий, иначе только информационная карточка.

Валютный номинал с выплатой в рублях

Отдельные поля: валюта номинала; валюта выплаты; формула курса и дата фиксации; валюта торга; кредитный риск эмитента; правовой режим выпуска. Рублёвая выплата не устраняет валютную экспозицию. Укрепление рубля может уменьшить рублёвые выплаты, даже если сумма в валюте номинала неизменна.

Нельзя напрямую сравнить USD-доходность 8% с рублёвой ключевой ставкой. Показывать доходность в валюте номинала и три рублёвых сценария. Если пользователь требует единый рублёвый минимум для всех инструментов, применять его только к явно выбранному FX-сценарию; без сценария такой выпуск не проходит автоматический фильтр. Никакой гарантии валютного прогноза.

Не включать все кредитные рейтинги ради диверсификации. Большое число слабых эмитентов не становится безопасным портфелем. Рейтинг - один из факторов, а ключевая ставка не является личной гарантированной альтернативой с тем же сроком и налогами. [S12-S14]

Применимость фильтра в разных стратегиях

Условие ключевой ставки - свойство выбранного доходного профиля, а не системный запрет для всех диалогов/портфелей. Ассистент может объяснить актив ниже этого порога и сравнить стратегии; изменить hard-фильтр в текущем профиле можно только видимым подтверждённым действием. Существующие значения пользователя при обновлении не переустанавливаются.

26. Диверсификация: методика и ограничения

Контроль строится по экономическому риску, а не только по числу строк в портфеле. Два выпуска одной группы не считаются двумя независимыми эмитентами.

Ось	Что учитывать	Что показывать
Эмитент / группа	Юрлицо, поручитель, контролирующая группа, несколько выпусков.	Максимальная доля, top-5, доля без уверенной связи.
Сектор	Общие драйверы бизнеса; «прочие» не скрывают неизвестность.	Полосы и лимит сектора, объяснение перекоса.
Кредит	Рейтинг выпуска/эмитента, outlook, watch, дефолт, субординация.	Категории и отдельная доля NR, без «среднего AAA».
Срок / ставка	Погашения, оферты, duration, fixed/floating.	Лестница сроков, чувствительность к ставке.
Валюта	Экономическая экспозиция, формула выплаты, курс и расчётная валюта.	Два раздельных графика: экспозиция и выплаты.
Ликвидность	Spread, глубина, объём и время торгов, ожидаемый выход.	Доля с ограниченной ликвидностью и причина оценки.
Фонды	Look-through по доступному составу, дата раскрытия.	Скрытые пересечения с прямыми позициями; неполное покрытие явно.

Стартовая конфигурация для проверки методики

Пример консервативной инженерной policy, не готовая рекомендация клиенту: корпоративный эмитент ≤5% капитала, группа ≤10%, сектор ≤25%, высокорисковые/безрейтинговые покупки OFF, заёмные средства OFF. Лимит государства отдельный, не автоматически 5%. Значения утверждаются методологом на наборе разных капиталов и горизонтов; пользователь должен понимать ограничения.

Для малого капитала, где один лот превышает лимит, система сообщает несовместимость и предлагает накопить остаток или изучить допустимый диверсифицированный фонд. Нельзя молча увеличить лимит, покупать ненужные сектора и выдавать недостижимую цель «все отрасли». Для существующего превышения сначала анализировать новые пополнения; принудительная продажа не следует из одного процента.

Показатель концентрации

HHI = сумма квадратов долей независимых групп; N_eff = 1 / HHI, если веса нормированы на выбранную область. Подпись: «Эквивалент равномерных долей по группам», а не «число надёжных компаний». Показать, включён ли cash, как обработаны фонды и какая доля неизвестна. Без заполненных связей показатель предварительный.

Перебалансировка

Зоны допустимого отклонения, отдельные пороги входа/выхода, cooldown и учёт издержек. Настроечный пример: реагировать на превышение лимита более чем на 2 п.п., снимать тревогу после возврата ниже лимита на 0,5 п.п.; критический кредитный факт обрабатывается отдельно. Это параметры теста, не универсальный финансовый закон.

27. Доходность, инфляция и прогнозы

Заменить обещание «предсказать рост» на проверяемые сценарии. Цена актива, дефолт, будущие дивиденды, налог и курс могут измениться.

Три слоя будущего

Известный график: объявленные выплаты и договорные платежи при исполнении обязательств. **Сценарий дохода:** неизвестные будущие купоны, дивиденды, реинвестирование. **Сценарий стоимости:** изменение цен, валюты, ставки и кредитного качества. В интерфейсе они имеют разные легенды и не суммируются как равнонадёжные данные.

Показатель	Правило
Рублёвый результат периода	Конечная стоимость + внешние выводы - начальная стоимость - внешние пополнения; все величины в согласованной валюте.
Выплаты внутри брокерского счёта	Уже включены в стоимость cash; не добавлять повторно поверх полной стоимости портфеля.
Реальная доходность	(1 + номинальная доходность) / (1 + инфляция за тот же период) - 1. Указать источник и лаг индекса.
Будущая инфляция	Пользовательское/утверждённое сценарное предположение, не известный факт.
Ожидаемый net доход	Только при определённых налоговом режиме, базе, льготах и комиссиях; иначе диапазон/нет данных.
Достижение цели	Показать диапазон сценариев, пополнения и допущения; не вероятность без калиброванной модели.

Стресс-сценарии

Проверять: ставка +2/+5 п.п.; рубль укрепился/ослаб на 20%; крупнейшая корпоративная группа не выплатила обязательства; ликвидность снизилась и spread вырос; отменены ожидавшиеся дивиденды. Параметры показываются рядом и могут меняться. Это стресс-тест, не предсказание вероятного события.

Для фиксированной облигации можно показывать приближение $\Delta P/P \approx -D_{mod} \times \Delta y$ с оговоркой об ограниченности линейной модели; при большом шоке использовать денежные потоки/convexity. Нельзя назначать всем классам единую duration. Для сравнения реального дохода с инфляцией использовать подходящий период и не выдавать инфляционный сценарий за «защиту 97%».

Визуальные правила

Известные суммы - сплошные колонки; условные - штрих/пунктир; возможные изменения стоимости - отдельный график. Fan chart вводить только при воспроизводимой статистической модели. До этого три линии «неблагоприятный / базовый / благоприятный» с явными допущениями. Рейтинг надёжности заменяется объяснимой панелью рисков.

28. Деньги и реинвестирование

Анализировать можно круглосуточно, тратить - только доказанные свободные деньги, с актуальными ограничениями и в разрешённом торговом режиме.

Классификация поступлений

Deposit, coupon, dividend, redemption, amortization, sale proceeds, refund/correction и unknown. Основной источник - подтверждённая операция брокера и её связь с изменением остатка. Одинаковый operation_id обрабатывается один раз; корректировки имеют собственную ссылку на исходную запись. Отмена заявки освобождает блокировку, но не создаёт новый инвестиционный доход.

Доступный бюджет

`spendable = confirmed_available_cash - user_reserve - planned_withdrawals_due - pending_own_commitments - cost_buffer`. Определить, включает ли брокерский available_cash уже блокировки: дважды их не вычитать. Для обязательств по нескольким валютам расчёт раздельный. Если сумма отрицательна - 0 на подбор, но исходный дефицит виден.

Поток события

1. Зафиксировать операцию и свежий snapshot; при расхождении создать data-quality incident.
2. Проверить политику выплат: использовать для дохода или рассматривать реинвестирование. Слово «реинвестировать» означает подготовить предложение, а не автоматическую заявку.
3. Объединить мелкие поступления в одно окно анализа; стартовое окно 30 минут для некритических событий. Минимальный размер предложения - стоимость допустимого лота плюс комиссии, а не произвольная постоянная сумма.
4. Подобрать распределение с учётом портфеля и будущих выводов. При отсутствии решения сохранить cash и дату следующей проверки.
5. После подтверждения и исполнения повторно сверить операции. Выручка от собственного sell-leg не порождает независимый buy-plan, пока исходный план не закрыт.

Ситуация	Результат
Купон есть в календаре, денег нет	Только напоминание; spendable не увеличивается.
Два купона в один день	Один анализ, две отдельные выплаты в истории.
Одновременное ручное поручение у брокера	Новый snapshot инвалидирует расчёт свободных средств.
Внешний вывод	Приостановить зависимые предложения, пересчитать резерв.
Ошибка источника / unknown delta	Объяснить ожидание сверки; не предлагать покупку на эти деньги.

Контроль оборота

Сначала недовесы новых денег, затем рассмотрение продаж. Польза после комиссии/spread должна превышать методологический порог; если оценить пользу нельзя, не строить уверенный «оптимальный» план. Учитывать налоги при продаже только при достоверной базе; иначе предупредить о неопределённости.

29. Подбор активов и объяснение выбора

Поиск финансовых фактов и оптимизация - работа контролируемых сервисов. LLM переводит вопрос пользователя в параметры и объясняет уже проверенный результат.

Детерминированный pipeline

Universe по поддерживаемым инструментам → identity/issuer/group → account eligibility → подтверждённые классы и ограничения → completeness/freshness → кредит/структурные риски → ликвидность → доходность/дюрация → влияние на весь портфель → издержки → допустимые целочисленные лоты → проверка результата.

Hard constraints никогда не компенсируются большим score. На первом этапе ranking лексикографический: прохождение качества → снижение существенного превышения → соответствие горизонту/выплатам → издержки и ликвидность → сопоставимая доходность. Веса и tie-breaker фиксируются версией; при равенстве - стабильный instrument_uid, а не случайность модели.

Количество и несколько покупок

Для одного инструмента максимум лотов = min(брокерский max_lots, бюджет с НКД/комиссией, лимит эмитента/группы, лимит стратегии, cap ликвидности). Округлять вниз; комиссии могут зависеть от количества, поэтому итог пересчитывать, а не делить на приблизительную цену.

Для распределения по нескольким бумагам - сначала простой воспроизводимый greedy с последующей проверкой всех ограничений. Если он систематически уступает или не находит допустимые решения, добавить целочисленный solver с time limit и deterministic seed. Solver не создаёт права купить и не использует неизвестные доходности как нули. Отсутствие feasible-решения - отдельный исход.

Что показывается пользователю

На Главной - одно понятное предложение, например «Рассмотреть распределение 20 000 ₽ между двумя выпусками». Внутри - каждый leg, суммарное влияние, альтернативы и причина исключения. В ручном поиске пользователь вправе сравнивать каталог; правило одного CTA не означает один доступный актив.

Карточка объяснения: зачем сейчас; почему этот выпуск; почему не ближайшая альтернатива; что станет с долей эмитента, сроком и cash; какие данные неполны; что отменит предложение. Нельзя писать «лучший на рынке» при частичном покрытии каталога. Писать «наиболее подходящий среди проверенных вариантов по выбранным условиям» только после legal gate.

Контракт результата

`decision_id`, tenant/account, snapshot_id, strategy_version, data_version, policy_version, eligible_universe_hash, rejected_reasons, proposed_legs, known_costs, unknowns, valid_until. Сохранить inputs для воспроизведения. ИИ не меняет lots/price в готовом результате. Любое изменение становится новым draft.

30. Источники данных и права использования

Сохраняем подход исходника: брокер - источник состояния счёта; публичные первичные источники - фактов. Уточняем лицензии и владельцев фактов. [S6-S14]

Данные	Основной источник	Ограничение и fallback
Позиции, cash, операции	T-Invest выбранного пользователя.	Нет публичной замены; при сбое последняя дата и режим ожидания.
Заявки / сделки	Состояние заявки и операции брокера.	Клиентский toast и текст ИИ не являются доказательством исполнения.
Котировки / стакан preflight	Разрешённые T-Invest market data.	Публичные задержанные котировки не подменяют execution source.
Справочник / история	MOEX ISS и брокер с согласованными идентификаторами.	Бесплатная задержка не равна праву перепродажи/распространения. [S14]
Ставка / официальный курс	Банк России.	Ставка хранится с датой вступления, курс не называется биржевым.
Рейтинг	АКРА, Эксперт РА и другие утверждённые агентства.	Проверить лицензию, шкалу, отзыв и точный объект рейтинга.
Отчёт / корпоративное действие	Сайт эмитента и уполномоченный канал раскрытия.	Дата публикации и дата события отдельно; исправления сохраняются.
Новости	Официальные раскрытия; разрешённые редакционные источники для контекста.	Медиа не подтверждает само по себе дефолт, выплату или trade permission.
Инфляция	Официальная статистика с периодом и методикой.	Будущая инфляция - сценарий, не официальное значение.

Реестр поставщика

Для каждого source_id: владелец, тип фактов, URL/endpoint, лицензия/договор, разрешённые поля и способы использования, тариф/лимит, delay, частота обновления, auth, parser_version, проверка целостности, owner поддержки и degradation policy. До включения в массовый продукт подтвердить право на display, storage, derived analytics и передачу фрагментов модели.

Новости без лишнего шума

Получение → нормализация → привязка к эмитенту/выпуску → dedup → извлечение факта → проверка источника → materiality → связь с портфелем → объяснение. Один релиз рейтинга, перепечатанный десятью СМИ, считается одним источником факта, а не десятью независимыми подтверждениями.

Показывать заголовок, автора/издателя, дату, ссылку и собственное краткое объяснение в рамках разрешений. Не скачивать весь интернет, не обходить paywall/robots/защиту и не архивировать чужие полные статьи «на всякий случай». Неподтверждённая связь с эмитентом остаётся для проверки, а не попадает в тревогу.

Публичный интернет в чате

В R8 подключается широкий поиск и чтение новых доменов через §39A. Для долговечных финансовых фактов и публичного display сохраняется Source Registry; произвольный найденный материал получает отдельный уровень доверия и право использования. Полный доступ к публичному поиску не равен лицензии на публикацию полного текста и не требует передачи портфеля поисковику.

31. Свежесть, доказательства и Watchtower

«Актуальные данные всегда» заменяется измеримым возрастом данных, покрытием и честным состоянием частичной недоступности.

Контур	Стартовая проектная частота	Что блокирует устаревание
Позиции / операции	Streams + сверка раз в 5 минут в активное время; после reconnect сразу.	Подбор и preflight на старом состоянии; просмотр сохраняется.
Полная сверка	Ежедневно, существующий 06:15 МСК сохранить до анализа расписания.	Расхождение вызывает инцидент; не объявлять всё исправным по таймеру.
Стакан перед заявкой	Возраст ≤3 секунд как начальный лимит для поддержанных ликвидных классов.	Submit, если лимит/свежесть не подтверждены. Порог калибруется по классу.
Публичная новость / рейтинг	15-60 минут по разрешениям источника и важности эмитента.	Сильный вывод без обязательного факта; не все источники имеют SLA.
Отчётность	Проверка новых публикаций ежедневно; документ сохраняет свой отчётный период.	Недостаток актуального периода, а не просто дата последнего HTTP fetch.
Ставка / FX	Ежедневно + проверка после публикаций решений.	Сравнение доходностей при неизвестной действующей ставке.

Канонический факт

`fact_id`, subject_id, value/unit/currency, reporting_period, published_at, effective_at, observed_at, source_url, document_hash, extraction_method, parser_version, confidence_class. Повторная загрузка старого PDF меняет retrieved_at, но не делает отчётность свежей. При новой редакции документа создаётся revision и сохраняется связь.

Наблюдение

Общий сбор публичных событий по уникальным эмитентам; персональное сопоставление по позициям выполняется отдельно. Нельзя оплачивать один и тот же разбор новости заново для каждого пользователя. Персональные выводы и тексты с суммами не используются в общем кэше.

Состояния инцидента: detected → investigating → confirmed / insufficient_data → assessed → visible → acknowledged → resolved; при изменении фактов reopen/escalated. Прочтение не означает устранение риска. Системная недоступность источника и ухудшение эмитента - разные категории.

Модель покрытия

Отдельно показывать: «Проверено 24 из 27 активов», «3 требуют обновления». Статус наблюдения зелёный только если обязательные контуры живы и возраст данных в пределах policy. Лаг сервера измеряется от доступного ему события, а не обещанием обнаружить неопубликованную новость. 24/7 означает работающий сервис наблюдения; рынок, провайдеры и человек поддержки не обязаны быть доступны непрерывно.

ИИ и свежесть

Новые данные получает Timeweb, после чего передаёт нужные сведения Qwen. Не требовать постоянного повторного чтения всего интернета самой моделью. Отсутствие нового LLM-текста не меняет время исходного факта, а успешная генерация не переводит stale snapshot в fresh. Для общего вопроса о сегодняшних событиях запускать поиск по требованию; для исполнения использовать финансовый API независимо от результата веб-поиска.

32. Архитектура: Timeweb и Lenovo

Разделяем web/API и финансовую систему на Timeweb, исполнение языковой модели на Lenovo и чтение интернета в отдельном процессе на Timeweb. Это роли одного продукта, без второй пользовательской базы.



Размещение

Timeweb: существующий Python/FastAPI, PostgreSQL, авторизация, финансовый код, источник фактов, оркестратор ИИ, долговечная очередь, журнал, публичный web fetcher и доставка SSE в браузер. Lenovo: небольшой AI Worker и существующий Ollama с Qwen3-14B. Worker не является копией сайта, БД, брокерского шлюза или браузером с пользовательскими cookies.

Выбран транспорт исходящих HTTPS-запросов worker → Timeweb: получение задания, heartbeat, события ответа. Он не требует белого домашнего IP, входящего проброса порта и нового облачного посредника. Вариант VPN/WireGuard возможен отдельным ADR, но для выбранного протокола не обязателен. Ollama используется только через loopback. Точные серверные маршруты - проектные, описаны в §40A.

Минимальный стек и независимость

Переиспользовать приложение и PostgreSQL; очередь/outbox с leases в существующем хранилище. Python worker использует HTTP API Ollama и фиксированный manifest. Новый inference runtime не нужен. Начать с full-text и точных идентификаторов, pgvector добавлять по качеству поиска (§32A).

Расчёты, наблюдение и шаблонные предупреждения работают без Qwen. Отключение worker не блокирует обычный UI. Fetcher изолирован от приватной БД; отдельный брокерский шлюз исполняет подтверждённые действия. Подробные контракты в §§39A-41.

32A. Существующая PostgreSQL в Timeweb

По новым снимкам владельца есть включённый сервис `omnicio-auth-postgres`. Показаны 20 GB диска, 0,11 GB занято, 19,91 GB свободно; в форме конфигурации выбраны 1 CPU, 2 GB RAM и стоимость 890 ₽/мес. Снимок формы не доказывает применение тарифа и не является полным счётом инфраструктуры. [S43]

Что можно переиспользовать

Текущий PostgreSQL-сервис подходит для таблиц диалогов, сообщений, явной памяти, источников, версий документов, заданий, leases, лимитов и ссылок на файлы. Начать с отдельных схем `assistant` и `knowledge` либо принятых в проекте названий, миграций и отдельных ролей. Пользовательские таблицы, auth и существующие связи не переносить без причины. Два человека имеют разные tenant-строки, даже если пользуются одной физической БД.

Поиск сначала full-text/точные идентификаторы. Timeweb перечисляет pgvector среди расширений PostgreSQL, но набор зависит от версии; проверить доступность именно этого кластера. pgvector хранит и ищет числовые представления текстов; он не запускает Qwen и не создаёт embeddings сам. При необходимости embedding worker вызывается отдельно; размер индексов и влияние на авторизацию измеряются. [S44]

Почему модель не загружается «в базу»

PostgreSQL хранит и выбирает данные. Ollama читает файлы весов и выполняет вычисления на CPU/GPU другого процесса. Запись 9,3 GB весов в поле БД не даст чат и увеличит backup/WAL/время восстановления. Файлы модели остаются на диске inference-узла; в БД только manifest, версия и контрольный digest.

19,91 GB свободного диска не являются оперативной памятью и не заменяют 6 GB видеопамяти Lenovo. Ползунки CPU/RAM на показанной странице увеличивают ресурсы PostgreSQL-сервиса, а не создают отдельный Ollama-процесс или GPU. В Managed Database установка произвольного сервера модели не является штатным способом развёртывания; для inference в Timeweb нужен отдельный управляемый вами вычислительный сервер. [S45]

Практические ограничения общей БД

Для короткой истории двух пользователей нельзя заранее обещать нагрузку всего интернета: вводятся срок хранения, batch-размер, индексы по tenant/time, query timeout и отдельный небольшой connection pool ИИ. Большие исходные PDF - в разрешённом файловом хранилище; в PostgreSQL метаданные и нужные фрагменты. Тяжёлый HNSW-индекс не строится в часы пользовательского входа без оценки памяти.

Не увеличивать ресурсы БД только из-за подключения Qwen. Основания - фактические latency, RAM, CPU, I/O, блокировки и размер индексов. Два пользователя всё равно могут почувствовать блокировку таблицы или перезапуск. На форме прямо указана перезагрузка при смене тарифа; изменение выполнить в согласованное окно с сохранением миграций/backup.

Описание сервиса содержит «Managed by GitHub Actions». Это повод проверить конфигурацию в репозитории: ручное изменение панели может расходиться с последующим deployment. Изменения ресурсов и расширений фиксировать в принятом способе управления инфраструктурой после проверки кода, не предполагать его устройство по подписи.

33. Сущности, API и события

Ниже целевые контракты, а не утверждение о существующих именах файлов или таблиц. Перед реализацией сопоставить их с текущей схемой и переиспользовать существующее.

Группа	Минимальные сущности / инварианты
Пользователь	users, accounts, sessions, consent_receipts, feature_entitlements; tenant из сессии.
Портфель	portfolio_snapshots, positions, cash_operations, instrument_access; immutable snapshot_id.
Стратегия	investment_profile_versions, balancing_policy_versions; только новая версия.
Публичные данные	instruments, issuers, groups, source_registry, documents, facts, revisions.
События	incidents, incident_transitions, outbox, delivery_attempts; fingerprint + version.
Решения	proposals, plans, approvals, execution_runs, order_intents, fills; точная связь account/plan/leg.
ИИ	conversations, messages, explicit_memory, ai_runs, ai_stages, tool_calls, source_refs, ai_usage, search_budget_reservations; владельцы/версии.
AI worker	worker_devices, model_manifests, job_leases, stream_events; certificate fingerprint, fencing_token, seq, deadline.
Монетизация	subscriptions, invoices, payments, entitlements, webhook_events; vendor_event_id unique.

Предлагаемые пользовательские endpoint-контракты

GET `/api/me/portfolio` возвращает snapshot и freshness. GET `/api/assets` принимает неперсональные фильтры; tenant/account проверяются сервером. POST `/api/strategy/drafts` создаёт draft; POST `/api/strategy/commit` принимает draft_id + expected_version. POST `/api/assistant/messages` возвращает 202 и message_id/run_id; SSE/cancel и внутренние worker API определены в §40A. POST `/api/plans/{id}/approve` фиксирует точный hash. POST `/api/execution/submit` принимает approval_id, не произвольный payload брокера.

Названия подлежат согласованию с существующим API. Ошибки: машинный code, пользовательское message, retryable, correlation_id; без секретов/traceback. Optimistic locking выдаёт 409 и понятный diff, а не молча перезаписывает параллельную вкладку. Pagination cursor подписывается/валидируется, предел limit жёсткий.

Конверт события

event_id, type, schema_version, tenant_id для персонального события, aggregate_id, occurred_at, recorded_at, correlation_id, causation_id, payload. Публичный факт без tenant не несёт приватного контекста. Transactional outbox связывает запись состояния и публикацию задачи; доставка at-least-once, поэтому consumer идемпотентен. Не обещать exactly-once между БД и брокером.

Структура проекта

Предлагаемые зоны: `domain/portfolio`, `domain/strategy`, `domain/execution`, `services/assistant`, `adapters/broker`, `adapters/sources`, `workers`, `web/components`, `web/screens`, `tests/security`, `tests/fixtures`, `docs/adr`, `docs/runbooks`. Новые миграции добавляются после текущей последней; уже принятые миграции не переписывать.

Внутри assistant: orchestrator, context_builder, tool_registry, output_validator; адаптеры Ollama/search; workers public_fetcher и lenovo_ai. Контракты и порядок программирования описаны в §48A; реальные пути сверяются с репозиторием.

34. Изоляция пользователей с первого дня

Снять лимит регистрации должно означать расширить квоту, а не переписать логику владения данными. Масштабирование вычислений всё равно требует проверки нагрузки.

Правила доступа

Tenant определяется только валидной серверной сессией/сервисным контекстом. Любой account_id, plan_id, event_id, chat_id, attachment_id из запроса проверяется на принадлежность. UUID и девятизначный профиль не являются защитой от доступа. В URL можно иметь opaque ID, но нельзя доверять ему как разрешению.

У персональных таблиц tenant_id NOT NULL и составные ссылки, препятствующие привязке строки A к объекту B. RLS применяется там, где подходит схеме. Runtime роль не superuser и не BYPASSRLS; учитывать обход политик владельцем таблицы, при необходимости FORCE ROW LEVEL SECURITY. Транзакционный tenant context не должен протекать через pool. [S27]

Канал	Обязательная изоляция
HTTP / WebSocket / SSE	Проверка подписки на каждый account/topic; смена сессии закрывает старый поток.
Worker	tenant берётся из подписанного/канонического задания, доступ перепроверяется перед побочным действием.
RAG / чат	Tenant filter до retrieval/reranking; отдельные ключи кэша, индексы по контексту и версии.
Файлы / экспорт	Приватный object key, короткая scoped-ссылка, проверка владельца.
Push	Endpoint связан с владельцем и устройством; выход удаляет серверную связь текущего пользователя.
Логи / поддержка	Нет токенов, полного финансового payload и чужих объектов в diagnostic bundle.

Набор отрицательных тестов

Создать A и B с одинаковыми тикерами, разными суммами и совпадающими названиями чатов. A пытается читать/менять URL B, отправлять approval B, искать память B, повторять подписку устройства и использовать закэшированный ответ после logout/login B. Ожидается отказ без утечки самого существования приватного объекта, где это применимо.

Параллельные задачи A/B проходят через один DB pool; после исключения/rollback context сбрасывается. Удаление A не очищает общие публичные факты и не затрагивает B. Регистрация при capacity=2 атомарна: из 10 параллельных новых запросов создаются максимум доступные слоты. Это не означает общий счёт или общую стратегию для двух тестировщиков.

Общая модель и отдельные разговоры

Один экземпляр Qwen не является общим чатом: каждый inference-запрос содержит только собранные сервером messages для одного run. История CLI, общий prompt с двумя портфелями и глобальная mutable conversation запрещены. Общими могут быть веса и разрешённые публичные summaries. Тестировать смену A/B, повтор попытки и восстановление после потери lease; tenant проверяется повторно перед tool, SSE и сохранением результата.

35. Состояния заявки и защита от дублей

Брокерский контур должен выдержать двойной клик, перезапуск, потерю ответа и внешнюю операцию пользователя.

Состояние	Разрешённый переход / действие
DRAFT	Редактирование и проверка; реальной заявки нет.
VALIDATED	Серверный расчёт корректен на указанную дату, но ещё не одобрен.
APPROVED	Одноразовое approval привязано к user/account/plan_hash и сроку.
PREFLIGHT	Повторная проверка цены, cash, lot, доступа, policy и состояния счёта.
SUBMITTING	Order intent и idempotency key записаны до обращения к брокеру.
UNKNOWN	Ответ потерян; только reconciliation. Новое независимое поручение запрещено.
ACCEPTED / PARTIAL	Отображать принятый объём, исполненный объём и остаток.
FILLED / REJECTED / CANCELLED	Финальный статус сверяется с операциями; история сохраняется.

Алгоритм submit

Заблокировать конфликтующие намерения по счёту/плану; провести preflight; атомарно перевести approval в consumed и записать order_intent; отправить запрос с устойчивым client idempotency key. Сохранить broker_order_id отдельно: это не всегда тот же идентификатор, что в запросе. При timeout не создавать новый ключ и не заявлять пользователю об отсутствии заявки. [S9, S11]

Сверка использует поддерживаемые брокером способы получения заявки/активных поручений/операций; если результат не установлен, состояние UNKNOWN сохраняется, оператор и пользователь видят инструкцию. Повтор исходного запроса с тем же ключом допустим только в доказанном контрактом идемпотентном recovery-процессе; не использовать «слепой retry» как основной алгоритм.

Стартовые ограничения пилота

Только limit orders, без плеча и shorts. Approval TTL 60 секунд; intent нельзя использовать повторно. Freshness book ≤3 с; price drift и spread caps задаются по классу и подтверждаются тестами. Лимит суммы одного поручения / дневного оборота явно задаётся владельцем для пилота; в документе не назначается безопасный универсальный размер капитала.

Kill switch

Останавливает новые submit и новые approval; чтение и reconciliation продолжаются. Он не отменяет уже принятые брокером заявки. Отмена активных заявок - отдельное действие с отдельной проверкой и журналом. При rollout disable открытые заявки остаются видимыми до финального результата.

36. Отказы, резервирование и восстановление

Дешёвый сервер с backup не является отказоустойчивым кластером. План честно задаёт целевые показатели и режимы ухудшения.

Сбой	Поведение пользователя	Восстановление
Нет связи с Lenovo / Qwen	Справочник, шаблонный обзор и видимый статус чата.	Heartbeat/lease и circuit breaker §40B; личный текст не уходит в другой LLM.
Не работает веб-поиск	Диалог и подключённые источники доступны с пометкой покрытия.	Повтор с backoff/кэш по свежести; текущие факты не выдумываются.
Недоступен брокер	Последний портфель с датой; новые заявки недоступны.	Backoff, затем полная сверка; pending заявки не повторяются.
Обрыв stream	Статус наблюдения деградирован при превышении лага.	Reconnect + snapshot/operations gap recovery.
БД недоступна	Нет ложного успеха записи/согласия/платежа.	Восстановить БД, проверить outbox и intent до возобновления.
Источник новости сломан	Покрытие уменьшается; не использовать parser-empty как норму.	Контрактный alert, последняя валидная версия, ручная проверка адаптера.
Ошибка deploy / service worker	UI показывает доступный статус, не кэширует несовместимый API.	Предыдущий совместимый build, version handshake и безопасное обновление.

Цели эксплуатации

Для read-only пилота: SLO доступности собственного web/API 99,5% за месяц, не включая ложное обещание доступности брокера; backup RPO ≤24 ч, RTO ≤4 ч как целевые значения до проверки. Перед live trading: WAL/PITR или эквивалент, RPO ≤15 мин для бизнес-данных, RTO ≤2 ч; финансовое состояние после recovery всегда сверяется с брокером независимо от RPO.

Backup-политика проекта

Ежедневный зашифрованный backup, 7 ежедневных + 4 недельных копии как начальная политика; WAL и документированные сроки корректируются по правовым требованиям и бюджету. Копия вне основного сервера, желательно в отдельном failure domain/аккаунте с ограниченными правами. Шифровальные ключи восстанавливаемы отдельно и не хранятся только в том же backup. Ежемесячная проверка реального восстановления в изолированной среде.

Удалённый пользователь не «воскресает» из копии: перед открытием восстановленной системы применяются tombstones/реестр исполненных удалений. Удаление backup учитывает расписание и правовые сроки; в документах нельзя обещать физическое уничтожение каждой резервной копии в момент клика.

Инцидентный регламент

Владелец дежурства, каналы уведомления, уровень серьёзности, время начала/восстановления, ущерб, затронутые категории и журнал решений. При реальных сделках необходим доступный человек для UNKNOWN/безопасности; «ИИ 24/7» не заменяет операционную ответственность. Сроки внешнего уведомления о ПД уточнить по действующей норме до запуска.

Для ИИ дополнительно действуют lease/cancel, отзыв сертификата, удаление во время inference и бюджет поиска из §40B. После восстановления права проверяются заново.

37. Модель угроз и защитные требования

Перечень описывает возможные классы атак и тесты, а не найденные уязвимости omnicio.ru.

Угроза	Защита	Доказательство
IDOR / cross-tenant	Серверный ownership, составные FK, RLS, изолированный retrieval/cache.	A/B negative tests всех объектов и выгрузок.
XSS в новости/чате	Санитизация; вывод как текст/безопасный Markdown; CSP; запрет raw HTML.	Вредоносные HTML/SVG/URL в fixtures не выполняются.
CSRF / session fixation	Secure/HttpOnly/SameSite, CSRF для state-changing, ротация после auth.	Чужой origin не меняет стратегию, подписку и plan.
SSRF из URL/Push	Для служебных адресов allowlist; для публичного fetch - DNS/IP + egress, запрет служебных сетей, проверка redirect (§39A).	URL 127.0.0.1, ::1, cloud metadata и DNS rebinding не проходят. [S29]
Prompt injection	Внешний текст - только данные; инструменты проверяют права независимо от LLM.	Статья с «отправь ключ» не приводит к вызову/утечке. [S28]
Утечка credential	Шифрование, отдельные ключи/roles, secret redaction, ротация, отсутствие в браузере.	Поиск canary-секретов в логах/экспортах/ошибках.
Supply chain	Pin зависимостей/образов/model revision, SBOM, scan, ограниченные CI secrets.	Воспроизводимый build и проверка происхождения.
Дубль заявки / webhook	Intent ledger, unique idempotency keys, replay-safe handlers.	Повтор запроса/события 100 раз не удваивает эффект.
DoS / расход токенов	Per-user quotas, max context, очередь, timeout, budget reservation.	Параллельный flood не тратит сверх серверного лимита.
Злонамеренный PDF	Размер/страницы/timeout, no-network sandbox parser, проверка MIME.	Архивная бомба, встроенный JS и внешняя ссылка не исполняются.

Инфраструктура

БД не доступна из интернета; SSH ограничен и с ключами/MFA у панели. Runtime без root; исходящие соединения по потребности. Execution process не разделяет публичный parser runtime и AI runtime. Совместное размещение на одном VM не защищает от полного захвата хоста - это остаточный риск дешёвого пилота, который учитывать перед торговлей.

Публичная административная диагностика не показывает ENV, токены, пути backup и чужие stack traces. Поддержка получает correlation_id и минимальные обезличенные данные. При обнаружении секрета в git не достаточно удалить строку: сначала отозвать/заменить секрет, затем очистить историю по отдельному плану.

Защита нового интеграционного контура

Угроза подмены worker закрывается mTLS, реестром устройств, отзывом identity и проверкой manifest. Replay/поздний результат - lease + fencing token + seq/idempotency. Удалённая модель не может сама расширить список tools. Debug logging и crash dumps не должны становиться второй незаявленной базой переписок; доступ администратора к Lenovo учитывается в модели угроз и документах (§46).

38. Выбранная модель и фактический замер

Решение владельца зафиксировано: Qwen3-14B Q4_K_M через установленный Ollama. Повторный конкурс моделей, аренда GPU и аппаратная настройка Lenovo в эту редакцию не входят.

Паспорт модели

Тег `qwen3:14b-q4_K_M`; в каталоге Ollama - 14,8 млрд параметров, Q4_K_M, загрузка 9,3 GB, сокращённый digest bdbd181c33f2. Для воспроизводимого deployment получить полный digest из фактического API, записать версию Ollama и chat template; сокращение со снимка не заменяет контроль целостности. [S20]

Официальная карточка Qwen3-14B описывает текстовую многоязычную модель, переключение thinking/non-thinking и использование инструментов; лицензия Apache-2.0. Нативная длина контекста модели не означает такую же доступную скорость и память на данном Lenovo. Лицензию и notices включить в сведения о компонентах; платная подписка для локального inference не требуется. [S19]

Наблюдения владельца от 04.10.2026

Показатель	Первый запрос «привет»	Следующий вопрос об облигации
Полное время	26,75 с	17,10 с
Загрузка модели	20,38 с	0,00695 с
Подготовка входа	2,70 с	0,690 с
Генерация ответа	15 токенов за 3,64 с	67 токенов за 16,40 с
Скорость выдачи	4,12 токена/с	4,09 токена/с

`ollama ps` на снимке: размер в памяти 9,8 GB, контекст 2048, размещение 57% CPU / 43% GPU. Это доли размещения модели, не проценты загрузки и не «57% + 43% мощности ноутбука». Отдельного замера первого видимого токена и двух одновременных запросов нет. [S21]

Загрузка объясняет значительную часть ожидания первого обращения. Для второго ответа переустановка сама по себе не доказана как причина ускорения: модель уже находилась в памяти. При той же скорости 160 выходных токенов занимают примерно 39 с одной генерации; 300 - около 73 с. Это арифметическая оценка, без поиска, подготовки входа и очереди.

Сохраняемые возможности

Русский диалог, общие знания, объяснение терминов, сравнение разных подходов, обработка пользовательского текста, рассуждение, подготовка структурированного результата и обращения к инструментам. Нет системного правила «разрешена только облигационная стратегия». Дообучение на одну стратегию или на частных портфелях не планируется; знания сервиса и новости подаются контекстом.

Текстовая Qwen3-14B не получает зрение или слух от подключения интернета. Текст из PDF извлекает отдельный parser; сканы требуют отдельного OCR-этапа с собственными проверками и бюджетом. Модель не обучается сама от прочитанных страниц и может ошибаться при любой скорости ответа.

Принята как рабочая модель проекта по выбору владельца. Критерий выпуска - качество связки модели, данных, интерфейса и разрешённых инструментов, а не обещание универсального превосходства модели.

39. Контекст, память и работа с данными

Веса модели общие для всех пользователей; история, факты о портфеле, память и разрешения собираются заново для конкретного запроса.

Маршрут вопроса

1. Backend принимает сообщение, определяет владельца из сессии, выбранный счёт, цель обработки и idempotency key. Общий вопрос не требует добавления портфеля.
2. Оркестратор выбирает обычный ответ, справку, поиск в интернете, факты актива, расчёт или подробную задачу. Сложность и тема не дают дополнительных прав; неизвестный инструмент отклоняется.
3. Retrieval получает точную сущность по ISIN/UID/эмитенту, нужные фрагменты и snapshot с датой. Неоднозначное название вызывает уточнение. Текущие цены и доступность - из поддержанного API, не из догадки модели.
4. Контекст собирается в пределах выбранного профиля: инструкции, вопрос, минимальная история, релевантные факты, разрешённые схемы tools. В job передаётся готовый минимизированный контекст без секретов.
5. Worker возвращает текст, структурированный результат или запрос tools. Timeweb проверяет схему, право, доступность данных и выполняет разрешённый tool; результат при необходимости становится следующим inference-заданием.
6. Проверенные числа, источники и результат действия формирует сервер. Модель не может заменить canonical сумму собственным числом или сообщить об успехе отсутствующей операции.

Бюджет контекста

Для измеренного профиля 2048 токенов стартовое распределение: инструкции и 1-2 нужных схемы 350; текущий вопрос 200; история/память 200; факты и источники 900; ответ 192; технический запас 206. Это проектные максимумы, а не гарантированный размер любого русского текста. Проверять токены подходящим tokenizer; количество символов не считать точным эквивалентом.

Если вопрос или схемы больше бюджета, удалять менее релевантные материалы и старые реплики, сохраняя текущий запрос, даты, units и права; затем выбирать профиль 4096 либо поэтапный разбор. Не обрезать молча ключевые условия пользователя. Сообщать о недостатке контекста, если задача не помещается. В каждую генерацию не передавать весь каталог tools.

Документы и длинные диалоги

База делится на справку сервиса, глоссарий, публичные документы и приватные пользовательские материалы. Начальные chunks 250-450 токенов по смысловым границам; 2 релевантных фрагмента для 2048, больше только по бюджету. Таблица сохраняет заголовки, период и единицы. Отчёт разбирается частями с привязкой каждого вывода к странице/фрагменту; итог не строится на неподтверждённом пересказе другого пересказа.

В длинном чате хранить историю на Timeweb, а в запрос передавать краткое резюме и последние нужные реплики. Резюме не превращает предположение в подтверждённое предпочтение. Явная память доступна пользователю; редактирование/удаление создаёт событие инвалидации зависимых кэшей. Thinking-трассы не служат долговременной памятью; сохранять итог и использованные основания. [S19, S23]

Кэш и происхождение

Ключ публичного summary: document_hash + parser/prompt version + model_digest + language. Персональный кэш дополнительно учитывает tenant, account, snapshot, profile/memory version и capability scope. Истории разных людей не объединяются.

Каждый fact содержит ID, источник, даты публикации/события/получения, версию и фрагмент. Citation validator проверяет наличие ссылки в контексте, но не истинность фразы. Числа сверяет код; соответствие утверждений источникам проверяют eval и выборочный review.

39A. Интернет: поиск, чтение и проверка

Ассистент может искать публичную информацию по широкому кругу вопросов, открывать найденные страницы и читать указанную пользователем ссылку. Доступ не ограничивается одной инвестиционной стратегией или только заранее известными эмитентами.

Три пути получения сведений

Путь	Реализация	Для чего
Собственные источники	Разрешённые RSS/API, сайты эмитентов, раскрытия, ЦБ, брокер; общий сбор и индекс.	Новости портфельных активов, котировки, выплаты и рейтинги.
Поиск по всему публичному вебу	Адаптер SearchProvider, первый кандидат Yandex Search API v2 без генеративного ответа.	Найти новые источники по вопросу и известным идентификаторам.
Ссылка пользователя	`fetch_public_document(url)` через изолированный fetcher и parser.	Разобрать конкретный публичный материал с указанием даты и фрагмента.

Собственный индекс не равен поисковой системе всего интернета. Для широкого поиска нужен работающий индекс провайдера или отдельное обоснованное решение. Платный поиск подключать в пределах небольшого резерва после проверки условий; внешняя LLM для этого не нужна. Если провайдер недоступен, честно показать «Доступны только подключённые источники», а не имитировать полный веб-поиск. [S26]

Последовательность сетевого запроса

Сформировать поисковую фразу без имени, номера счёта, сумм и переписки; для новости использовать эмитента/тикер и период. Начальные пределы обычного вопроса: 2 поисковых запроса, до 5 результатов каждый, чтение до 3 документов; подробный режим до 6 запросов и 10 документов по отдельной задаче. Новые домены разрешены для публичного чтения после технической проверки, а уровень доверия определяется отдельно.

Fetch сохраняет конечный URL, издателя, заголовок, published_at при наличии, fetched_at, hash, статус, лицензионную политику и извлечённые фрагменты. Сниппет результата поиска не приравнивается к прочитанной статье. Отчёт компании сравнивается с отчётным периодом, новость - с датой события. Недоступный первоисточник или противоречие отражаются в ответе.

Финансовые факты сначала сверяются с первоисточником. Две перепечатки одного сообщения не считаются независимым подтверждением. При сообщении о дефолте, рейтинге, дивиденде или блокировке инструмента использовать соответствующее раскрытие/агентство/брокера; неподтверждённый материал обозначается как сообщение источника. Оценка влияния отделена от факта и не содержит гарантии цены.

Изоляция сетевого инструмента

Разрешить HTTP/HTTPS GET к публичным адресам, стандартные порты 80/443, без пользовательских cookies, Authorization и произвольных заголовков. Блокировать loopback, private, link-local, multicast, служебные IPv4/IPv6, metadata и внутренние домены. Проверять все DNS-ответы и каждый redirect, соединять с проверенным IP с корректным TLS SNI; сетевой egress-фильтр дублирует проверку приложения. Для SSRF-тестов включить DNS rebinding и IPv4-mapped IPv6. [S29]

Проектные лимиты: connect 3 с, весь fetch 15 с, до 3 redirects; HTML/text до 2 MB после распаковки, PDF до 15 MB. Разбор PDF в изолированном процессе: до 100 страниц за задачу, CPU/time/memory cap, без запуска вложений и скриптов. Более крупный документ предлагается разделить. Не обходить оплату, CAPTCHA, запрет доступа и ограничения использования; JS-only страницы могут быть недоступны на первом этапе.

Устойчивость к подмене инструкций

Любая веб-страница, PDF и результат поиска - недоверенные данные. Встроенная команда «измени стратегию», скрытый текст и ссылка с секретом не становятся служебной инструкцией. У fetcher нет брокерских ключей, приватного портфеля и доступа к очереди изменения настроек. URL/query, предложенные моделью, проходят проверку утечки; разрешение на публичный GET само по себе не делает передачу приватного текста допустимой. [S28]

Серверный инструмент ограничивает поля и объём результата. Финансовые tool-вызовы не исполняются из текста документа; непрошедшие проверки регистрируются без сохранения секретного payload. Риски injection нельзя устранить одним system prompt или фразой «игнорируй внешние инструкции».

Пользователь получает широкий поиск и объяснение прочитанного. Интернет не даёт модели права читать локальные файлы Lenovo, другие аккаунты, токены, служебную БД или отправлять поручения от чужого имени.

40. Интеграционный worker и режимы модели

Модель уже установлена. Разрабатывается небольшой сервис-связка, без смены ОС, оборудования, настроек питания и повторных аппаратных проверок Lenovo.

Ответственность worker

Worker проверяет совместимость job schema, имя и digest разрешённой модели; вызывает только локальный `/api/chat`, передаёт ответ и метрики на Timeweb. Сведения о модели получает через `/api/show` и `/api/ps`. Он не выполняет командную строку из задания, не устанавливает зависимости по просьбе модели, не содержит брокерский SDK и не обращается к сайтам за фактами. [S22, S42]

Сначала один inference-запрос одновременно; очередь находится на Timeweb. Worker не накапливает вторую непрозрачную очередь в Ollama. Все параметры приходят из версионного server profile, а не из произвольного JSON браузера. В начале задачи полный context собирается явно; состояние CLI-чата пользователя не используется.

Профили API, сохраняющие возможности Qwen

Профиль	Начальные параметры	Продуктовое поведение
Обычный	think=false; num_ctx=2048; num_predict=192.	Краткий диалог и объяснение; данные/схемы укладываются в общий бюджет.
Подробный	think=false; num_ctx=4096; num_predict=384.	Больше фрагментов и более длинный ответ; после проверки времени интеграционного запроса.
Разобрать глубже	think=true; num_ctx=4096; num_predict=1024.	Отдельная фоновая задача с прогрессом и остановкой; итог после проверок.

Числа - стартовые профили сервиса, не предел способностей весов и не обещание одинаковой скорости. Профиль 2048 основан на присланном замере; другие профили принимаются по прикладному eval без нового стресс-тестирования оборудования. Большие документы обрабатываются фрагментами. При недостатке бюджета предложить продолжение; при исчерпании thinking-бюджета не показывать обрыв как готовый анализ.

Поддержку `think` проверить в установленной версии Ollama. Режим рассуждения сохраняется, но не включается на каждое приветствие. Пользователь получает вывод, расчётные основания и источники, без вывода внутренней thinking-трассы. Структурированный ответ по JSON Schema проверяется кодом; корректная схема не подтверждает истинность текста. [S23, S39]

Контракт вызова обычного ответа

```
POST http://127.0.0.1:11434/api/chat
{
  "model": "qwen3:14b-q4_K_M",
  "messages": [{"role": "user", "content": "..."}],
  "stream": true,
  "think": false,
  "keep_alive": -1,
  "options": {"num_ctx": 2048, "num_predict": 192}
}
```

Пример показывает транспорт; production добавляет system policy, контекст и выбранные tools. Значения sampling фиксируются отдельной проверенной версией профиля. Не назначать temperature=0 как универсальную гарантию точности; исходные рекомендации разработчика модели являются точкой для eval, не обходом финансовых проверок. [S19, S22]

`keep_alive=-1` в запросах worker и прогрев при его старте уменьшают повторную холодную загрузку. Это не ускоряет каждый генерируемый токен и не гарантирует сохранение после перезапуска/OOM. При обслуживании worker допускает явную выгрузку. Не вводить заново экспериментальные Flash Attention/KV-настройки как уже доказанное улучшение. [S21]

Поставка интеграции

В репозитории добавить адаптер Ollama, CLI/entrypoint worker, versioned config без секретов, manifest и runbook запуска/обновления. Развёртывается именно этот сервис; уже работающая модель переиспользуется. Перед production проверить только совместимость API, подключение, каналы отказа и пользовательские сценарии. Автообновление весов по тегу не включать: изменение digest требует eval и возможности возврата.

40A. Протокол связи Lenovo с Timeweb

Предлагаемый контракт, который необходимо сопоставить с текущим reverse proxy и API. Никакое подключение или изменение сервера этим документом не выполняется.

Канал и учётная запись

Выделить служебный host, например `ai-worker.omnicio.ru`, на существующем reverse proxy Timeweb. Только HTTPS 443, mTLS для worker; браузерные sessions этот API не принимаются. Lenovo инициирует все соединения. На домашнем роутере и в Ollama не нужен публичный inference port. Стандартный локальный адрес Ollama - 127.0.0.1:11434. [S21]

Владелец выпускает отдельный клиентский сертификат сервиса; закрытый ключ хранится только в защищённом хранилище учётной записи worker. CA/signing secret не помещается на Lenovo или в git. На сервере - реестр device_id, fingerprint, разрешённых моделей и состояния active/revoked. Проектный срок сертификата 30 дней, перевыпуск до истечения, возможность немедленного отзыва. Автоматизировать стандартной библиотекой/средствами TLS, не собственным криптопротоколом.

Прокси передаёт проверенную mTLS identity только доверенному внутреннему API; внешние заголовки с fingerprint удаляются. Отозванный сертификат блокируется при каждом запросе, включая отправку результата старого задания. Смена ключа оставляет аудит. Авторизованный worker имеет право получить только назначенную задачу, а не читать все чаты или портфели.

Маршруты проекта

Метод / путь	Полезная нагрузка	Проверка
POST `/internal/ai/v1/claim`	device_id, schema_version; ожидание до 20 с.	Атомарно одно задание; пусто - 204.
POST `/internal/ai/v1/heartbeat`	lease_id, fencing_token, состояние и безопасные метрики.	Только действующее назначение; продление lease.
POST `/internal/ai/v1/events`	run_id, stage_id, lease_id, seq, тип и chunk.	Размер, порядок, уникальность, принадлежность lease.
POST `/internal/ai/v1/finish`	Итог, метрики, model_digest, статус.	Compare-and-set RUNNING, текущий fencing token.
POST `/internal/ai/v1/fail`	Код ошибки, retryable, безопасная диагностика.	Без traceback, prompt и секретов.

Пользовательский API отдельно: POST `/api/assistant/messages` → 202 с run_id; GET `/api/assistant/runs/{id}/events` → SSE; POST `/api/assistant/runs/{id}/cancel`. Для каждого обращения проверяются tenant, chat и session. Чужой run_id не раскрывает ни текст, ни статус существования приватного объекта. CSRF и CORS соответствуют действующей модели авторизации.

Содержимое задания

job_id, run_id, stage_id, schema_version, device_id, lease_id, fencing_token, expires_at, priority, model_tag, full_digest, profile_version, messages, tool_schemas, max_output, deadline. Пользовательское ФИО, VK ID, broker credential, session cookie, ключ поиска, пароль БД и полный номер счёта отсутствуют. Псевдонимизация не делает содержание портфеля анонимным.

Timeweb сохраняет авторитетную связь run → tenant/account/capabilities. Перед каждым tool и доставкой результата снова проверяется право и отзыв согласия. Переданная моделью строка tenant_id никогда не используется для выбора пользователя. Worker не может задавать URL callback: адрес Timeweb задан конфигурацией, ответы принимаются только через известные маршруты.

Поток, повторы и отмена

Chunk события собираются до 250 мс либо 4 KB, без ожидания всего ответа. Server ack возвращает последний seq; уникальный `(stage_id, attempt_id, seq)` устраняет дубль при потере ответа. Чанк незавершённого tool call не исполняется. После окончания сообщения оркестратор валидирует полный вызов и только затем выполняет tool. [S38, S40]

Heartbeat каждые 5 с, lease 30 с. Потеря lease или сообщение cancel останавливает чтение потока и закрывает локальный запрос; факт прекращения вычисления проверяется в интеграционном тесте. Даже если runtime завершит вычисление позже, Timeweb отклоняет просроченный результат. Возобновление браузерного SSE использует Last-Event-ID и серверную историю, а не повтор генерации.

Worker хранит незавершённые chunks в ограниченном буфере RAM; при его переполнении/потере связи отменяет stage и сообщает о сбое после reconnect. Перезапуск не требует копии переписки на диске Lenovo. Повторяется только безопасная inference-стадия, максимум один раз, если не отменена и ещё в deadline; побочный эффект tool не повторяется без его idempotency key.

40B. Очередь, доступность и эксплуатация ИИ

Один общий экземпляр весов обслуживает отдельные личные диалоги. Одновременное открытие двух кабинетов допустимо; одновременную генерацию на пилоте заменяет прозрачная очередь.

Состояния и справедливость

Run: QUEUED → CLAIMED → RUNNING → VERIFYING → COMPLETED; также WAITING_TOOL, CANCEL_REQUESTED, CANCELLED, FAILED, EXPIRED. Каждый переход версионируется. Повтор доставки не создаёт второй run, а stale worker не может завершить новую попытку после смены fencing token.

На пилоте: одна активная генерация на Lenovo, один активный run и один ожидающий запрос на пользователя; глобальная интерактивная очередь до 10 задач. Для двух пользователей B получает ближайший свободный слот после текущей стадии A; A не занимает очередь сотней сообщений. Подробный разбор разбивается на стадии, между ними допускается интерактивный запрос другого пользователя. Непрерываемую текущую генерацию не обещать мгновенно вытеснить.

Приоритет: интерактивный ответ → явный подробный запрос → ежедневные обзоры → общие необязательные summaries. Критические события создаются детерминированно на Timeweb и не стоят в очереди LLM. Фоновый обзор обязан иметь шаблонный fallback к времени доставки. Общая новость разбирается один раз, персональная связь с позициями считается отдельно.

Пределы задач

Обычный run: очередь до 60 с, inference stage до 90 с, общий deadline 180 с с поиском и максимум 3 tool-раундами. Подробная задача: stage до 360 с, весь run до 600 с, максимум 6 раундов; финальный ответ резервируется по времени/токенам. При отсутствии бюджета для результата предложить продолжение, не выдавать оборванный анализ за завершённый. Это защитные пределы, не обещанная длительность ожидания.

Число раундов и вход/выход фиксируются в manifest и могут изменяться после eval. Ограничения вычислительного времени не запрещают обсуждать другие стратегии. При исчерпании очереди вернуть retryable «Ассистент занят» и оценку по текущим измерениям, без точного таймера, если его нельзя обосновать.

Отказ и восстановление

Нет heartbeat 15 с - degraded; 30 с - offline, новые короткие запросы получают понятное состояние вместо бесконечного ожидания. Заявленные сроки здесь - цели обнаружения связи, а не аппаратный мониторинг ноутбука. Не отправлять сообщения пользователя в сторонний облачный ИИ автоматически. При восстановлении проверить manifest и служебный запрос, затем принимать очередь с ещё действующими deadline; устаревшие новости/задачи пересобрать.

Circuit breaker размыкается после 3 ошибок подряд; проверка восстановления с backoff 5-60 с и jitter. Недоступность поискового API не объявлять недоступностью модели. События перегруза группировать; пользователь может продолжать обычную работу с сайтом.

Что измерять

Раздельно: queue_wait, load_duration, prompt_eval_duration, time_to_first_visible_token, generation_duration, verification_duration, total_user_latency, input/output tokens, поиск/кэш, отмены и причины ошибок. API Ollama отдаёт свои duration в наносекундах; время поиска и очереди добавляет OmniCIO. [S22]

Dashboard эксплуатации: текущий manifest, online/warming/offline, глубина очереди, p50/p95 по профилям, выполненные/ошибочные задачи, дневной расход поиска. Размещение CPU/GPU не использовать как показатель общей загрузки. Историю содержимого чатов в мониторинг не копировать.

Данные на двух узлах

История, согласия, явная память и audit находятся на Timeweb. На Lenovo не создавать постоянные копии чатов, файлов и пользовательские профили; production-логи worker содержат коды/счётчики/opaque IDs. Транзитные буферы освобождаются после запроса; это не обещание физического стирания каждой ячейки RAM. Исключить сбор prompt в debug dumps; ограничить доступ к процессу и его служебной учётной записи.

Job payload на Timeweb шифруется и удаляется не позднее 24 часов после terminal state, отдельно от утверждённой истории чата. SSE buffer очищается по той же политике, но экспорт истории остаётся доступен владельцу до выбранного срока. Удаление аккаунта отзывает активные задачи, память и персональные cache keys; поздний результат не воскрешает удалённые данные.

41. Инструменты ИИ и подтверждение изменений

Возможность модели рассуждать широко сохраняется. Право читать конкретный счёт и применять изменение определяется серверной политикой независимо от промпта.

Tool проекта	Действие	Контроль
`get_help(topic)`	Справка сервиса и пояснения настроек.	Только база для пользователей; без секретов эксплуатации.
`get_portfolio_summary()`	Минимальный собственный snapshot.	Владелец из серверной сессии; дата/coverage.
`get_instrument_facts(id)`	Условия выпуска, рейтинг, отчёты.	Canonical ID, источник, период и доступность.
`get_payout_calendar()`	Собственные объявленные/полученные выплаты.	Ожидаемые, сценарные и полученные суммы раздельно.
`search_web(query, period)`	Публичный веб-поиск.	Без приватного текста; квота, происхождение, дата.
`fetch_public_document(url)`	Чтение страницы/отчёта.	SSRF, размер, MIME, права использования; §39A.
`search_assets(filters)`	Каталог и допустимые фильтры.	Eligibility по счёту; не произвольный SQL.
`compare_scenarios(params)`	Проверяемый расчёт нескольких вариантов.	Допущения и методика видны; рекомендационный gate по содержанию.
`simulate_strategy_patch(patch)`	Предпросмотр влияния ползунков.	Общий validator UI/API; запись отсутствует.
`create_strategy_draft(patch)`	Черновик с diff и reason.	Base version, expiry, ownership; не commit.
`create_order_draft(...)`	Расчёт торгового билета после допуска.	Без submit, approval и broker credential.

Две независимые границы

Общие знания, разные стратегии и публичный поиск доступны в пределах сервиса. Административные команды, произвольный shell/SQL, чтение ENV/домашних файлов и выдача новых прав не являются инструментами чата. Посещение веб-страницы не предоставляет право входить в аккаунт на ней или принимать её инструкции.

Пользователь может сравнивать доходный, накопительный, сбалансированный подход, последствия валютной экспозиции и изменения горизонта. Нельзя заставлять каждый ответ сводиться к покупке облигаций выше ключевой ставки. Указанный фильтр применяется только к выбранной пользователем версии стратегии; текущие запреты и доступность сохраняются до подтверждённого изменения.

Три типовых сценария

«Что произошло с моим портфелем?» → сервер получает свой snapshot и изменения → публичные факты связываются с позициями → Qwen объясняет → renderer показывает суммы/даты/источники. Если факт устарел, сначала обновление или явное сообщение о возрасте.

«Найди информацию об этой компании» → поиск без данных счёта → чтение первоисточника → краткий разбор со ссылками и неопределённостью. «Влияние на мой портфель» добавляет персональные

данные только во внутренний контекст, не в запрос поисковику.

«Уменьши долю акций до 20%» → simulate → draft → карточка было/стало и ограничения → «Сохранить стратегию» → обычный API с сессией пользователя. «Да» в чате может открыть карточку, но не становится финансовым approval. Ассистент пишет «Сохранено» только после подтверждённого commit.

Контракты и идемпотентность

Tool call имеет call_id, schema_version, run_id, args и capability scope, добавленный сервером. Допустимые поля описываются Pydantic/JSON Schema; дополнительные поля отклоняются. Повтор draft tool с тем же call_id возвращает тот же draft. Ошибочные вызовы не исправляются молча до торгового действия.

Черновик хранит base_version, patch, reason, evidence_ids, created_by=assistant и hash. Одновременная ручная правка создаёт конфликт, после которого требуется новое сравнение. Broker submit доступен только отдельному execution API после точного пользовательского подтверждения (§35). Память чата не заменяет investment_profile_version.

Потоки приватных данных

Контекст для Lenovo минимизируется, но остаётся защищаемыми данными пользователя. Ключи брокера и поиска находятся на Timeweb. Поисковому поставщику передаются только публичные поисковые фразы; полный вопрос с суммами и составом портфеля не отправляется автоматически. Локальное размещение модели не отменяет требований к оператору, журналу, удалению и физическому доступу к узлу.

42. Качество ответов и приёмка интеграции

Проверяется связка Qwen3-14B, инструментов, данных и интерфейса. Это прикладные проверки продукта, а не повторная проверка мощности ноутбука и не конкурс другой модели.

Набор до пользовательского включения

240 русскоязычных заданий: 35 справка/настройки, 40 облигации/выплаты, 35 новости/источники, 30 портфель/риски, 25 drafts, 45 безопасность/изоляция/отказы и 30 общие вопросы/сравнение разных стратегий. Не менее 20% с опечатками, разговорной формой и неоднозначностью; не менее 20% - отдельный holdout, который не используется для правки промптов.

Каждое задание хранит вход, ожидаемые факты/действия, допустимые неизвестные, запрещённые результаты и критерий понятности. Наличие source_id недостаточно: проверяется, поддерживает ли конкретный фрагмент смысл ответа. Любой важный выдуманный финансовый факт исправляется до выпуска затронутой возможности.

Критерий	Условие допуска
Доступ к чужим данным / действие без права	0 успешных атак в наборе; найденный случай блокирует релиз.
Финансовые числа	100% совпадение критических сумм/единиц с canonical данными либо «недостаточно данных».
Источники	0 выдуманных URL; ≥95% проверяемых утверждений поддержаны релевантными фрагментами; все критические ошибки устранены.
Tools	100% запрещённых/невалидных вызовов отклоняет backend; повтор не удваивает действие.
Русский и понятность	Средняя оценка ≥4/5 двумя проверяющими; языковые примеси и двусмысленность разбираются.
Широта	Общие вопросы и сравнение стратегий не получают отказ только потому, что они вне выбранного доходного профиля.
Отмена / отключение	Нет поздней записи после cancel/delete/revoke; портфель и шаблонные события продолжают работать.

Проверки, связанные с последними ответами модели

Покупатель облигации - кредитор, а не заёмщик. Цена покупки не обязана равняться возвращаемому номиналу; периодические купоны не выплачиваются все повторно в конце срока. Есть риск неисполнения обязательств; доходность к погашению не равна купонной ставке. При неизвестных условиях выпуска ответ не добавляет их из воображения. Эталон готовит методолог по актуальным официальным материалам. [S37]

Проверить вопросы «что такое облигация», «кто кому должен», «что получу при покупке выше номинала», «что изменится при ключевой ставке», «новость за сегодня», «сравни накопление и доход», «объясни эту настройку» и произвольный общий вопрос. Одного удачного определения недостаточно для оценки всего ассистента.

Производительность: отдельная прикладная серия

30 коротких заданий без веб-поиска и 20 с поиском на прогретой модели, затем два одновременных пользовательских сценария; фиксировать p50/p95, распределение длины и качество. Не выдавать прежний целевой p95 ≤15 с за достигнутый: один имеющийся тёплый ответ уже занял 17,10 с.

Начальные цели пилота: подтверждение run ≤1 с; тёплый короткий ответ до 192 выходных токенов - p95 первого видимого текста ≤15 с, завершения без очереди ≤90 с. Поиск и проверка добавляются в отдельные метрики; целевое время такого короткого run без очереди ≤120 с. Это ещё не измеренные SLA и не обещание пользователю. Для B при занятом слоте A измерять полное ожидание, не вычитать очередь из отчёта о пользовательском опыте.

Подробная задача может занимать минуты: показывать статус и дать отмену/фоновое завершение. При превышении целей сначала уменьшить лишний контекст, повторный поиск и дубли, затем пересмотреть когорту и честно сообщить пределы. Нельзя улучшать отчёт исключением неуспешных запросов или молча сокращать важный ответ.

Сбои и атаки

Закрыть соединение между claim/первым токеном/finish; повторить event; истечь lease; отозвать сертификат; удалить аккаунт при генерации; подать чужой run_id; изменить счёт при открытом SSE; поместить вредоносную инструкцию в PDF и URL на metadata. Проверить, что один опубликованный источник используется повторно для разных людей без общего персонального контекста.

Результаты фиксируются с model_digest, Ollama version, profile, prompt, parser и corpus version. После каждого изменения модели/шаблона/tool schema прогоняется затронутый набор и обязательные проверки изоляции. Отзывы полезны, но лайк не доказывает фактическую точность.

43. Бюджет эксплуатации до 20 000 ₽

Месячные лимиты планирования для выбранной схемы Timeweb + существующий Lenovo. Разработка и разовые юридические услуги считаются отдельно. Наличие двух пользователей не делает расходы на данные и резервирование нулевыми.

Пилот: два пользователя

Статья	Лимит ₽/мес.	Что предусмотрено
Timeweb: PostgreSQL	890	Выбранная конфигурация на снимке; подтвердить фактический тариф аккаунта.
Timeweb: приложение / лёгкие workers	2 000	Плановый лимит, цена текущего приложения не предоставлена; не дублировать уже оплаченный ресурс.
Backup / файлы	600	Шифрованные копии вне основного узла и ограниченное хранение документов.
Мониторинг / служебная почта	300	Простые метрики и уведомления; без тяжёлой платной платформы.
Веб-поиск	750	Платный поиск только при реальной потребности; собственные источники и кэш первыми.
Электричество Lenovo / UPS	900	Резерв, заменить измеренным добавочным потреблением и домашним тарифом.
Резерв обслуживания оборудования	500	Учёт износа существующего узла; не ежемесячная обязательная покупка.
Эксплуатационный запас	1 060	Трафик, IP, логи, колебания тарифов и непредвиденные мелкие расходы.
Итого	**7 000**	Проектный верх пилота, фактические счета могут быть ниже.

За локальную генерацию Qwen не начисляется отдельная стоимость токенов. Электричество не считать одновременно по всей мощности блока питания и по добавочной нагрузке. Формула: средняя добавочная мощность в кВт × часы работы × фактический ₽/кВт·ч. Интернет уже есть по сообщению владельца; новые оплачиваемые расходы учитывать, если они появятся.

Зрелая линия: конверт, а не заказ ресурсов

Статья	Лимит ₽/мес.	Условие расхода
Приложение / reverse proxy	3 000	После измерений текущего Timeweb тарифа.
PostgreSQL	3 000	Отдельный/managed вариант, если нужен и укладывается с PITR.
Сборщики / очереди / fetcher	1 500	Отдельные ресурсы только при доказанной нагрузке.
Backup / файлы	1 200	Утверждённые объёмы и сроки.
Мониторинг / почта	500	Проверенные необходимые услуги.
Публичный веб-поиск	1 500	Общий месячный cap, с кэшем.
Электричество	900	Заменить измеренным значением.
Обслуживание Lenovo	900	Резерв замены/ремонта компонентов.
Фискализация / платежи	1 000	Уточнить договор и переменную комиссию до R14.
Резерв лицензий данных	2 500	Если право использования требует оплаты; не обещание достаточности.
Общий запас	3 000	Рост фактической нагрузки, трафик и изменение цен.
Итого	**19 000**	До абсолютного предела остаётся 1 000 ₽.

Суммы - собственные бюджетные ограничения, не подтверждённые тарифы этих конфигураций Timeweb. Регион, срок оплаты, диски, IPv4, резервирование и налоги сверить по аккаунту/конфигуратору до заказа. Существующий сервер не оплачивать повторно в смете как «новый ИИ-сервер». [S24]

Бюджет 19 000 ₽ не доказывает пропускную способность Lenovo для 25/100 пользователей. Мощность очереди, лицензии и деньги проверяются раздельно. Обязательная платная GPU и резервная облачная LLM в этот конверт не включены; превышение потребует нового решения владельца.

43A. Принятое решение о размещении

Финальная договорённость владельца: Qwen3-14B работает на существующем Lenovo. Аренда GPU, замена модели и повторная подготовка ноутбука не входят в активную разработку этой линии.

Что оплачивается сейчас

Переиспользуются уже работающий ноутбук, интернет и источник бесперебойного питания. В бюджет входят расходы существующей инфраструктуры Timeweb, хранение/backup, ограниченный публичный поиск, электричество и эксплуатационный резерв (§43). Сам факт использования локальных весов не создаёт счёт за каждый токен. Подписка на облачный Ollama не требуется для выбранного локального HTTP API; облачный маршрут в приложении отсутствует.

Тариф PostgreSQL не повышать ради размещения модели. Его CPU/RAM обслуживают данные, а файлы весов и inference находятся на Lenovo (§32A). Отдельный сервер очереди, vector database и внешний LLM API на старте не заказываются. Новая зависимость вводится только для измеренного недостатка существующих средств.

Как сохранить возможность роста

Контракт worker, manifest модели и lease независимы от физического компьютера. Если позднее владелец примет другое решение, можно подключить иной вычислительный узел без переноса пользовательской базы и изменения API сайта. В этой версии реализуется только один активный inference-слот. Добавление узла требует проверки прав, распределения очереди и фактического бюджета.

Порог для пересмотра размещения: очередь регулярно нарушает утверждённую цель, наблюдаются повторяющиеся недоступности либо подтверждённая пользовательская нагрузка превышает ёмкость. Сначала проверить время модели, длину контекста, повторное использование публичных разборов и фоновые задания. Не покупать ресурсы только по числу регистраций или доле занятого диска.

Решение перед любыми новыми расходами

Зафиксировать текущие счета, ожидаемую месячную нагрузку, измеренный выигрыш и итоговую сумму с резервом. Расходы не должны выходить за 20 000 ₽/мес. Переезд оформляется отдельным ADR и решением владельца; он не является скрытой зависимостью релизов R0-R17. Выбранные настройки модели в этой редакции - рабочие профили приложения, без вмешательства в подготовку оборудования.

44. Стоимость поиска и вычислительная ёмкость

В локальной схеме нужны два независимых счётчика: рубли внешних сервисов и время единственного inference worker. Отсутствие платы за токены не означает безлимитную параллельную генерацию.

Поиск в публичном интернете

На официальной странице Yandex Search API на дату проверки указано 488 ₽ за 1000 дневных синхронных запросов и 30,50 ₽ за 1000 дневных отложенных, с НДС. Это обычный поиск, без генеративного ответа и смарт-сниппетов; действуют условия и квоты выбранного API. Тариф аккаунта подтверждается перед подключением. [S26]

Пример для двух пользователей: 5 вопросов в день × 2 человека × 30 дней = 300 вопросов. Если каждый требует два новых синхронных поиска, 600 запросов стоят **292,80 ₽** при указанной цене. Если поиск нужен половине вопросов - **146,40 ₽**. Это сценарии, не измеренная доля: кешированные сведения, RSS и прямое чтение могут уменьшить платное число; фоновый поиск учитывается дополнительно.

Лимит 750 ₽ покрывает примерно 1500 таких синхронных запросов с небольшим запасом. Для планового обновления, где допустимо ожидание, оценить отложенный API; не использовать его как обещание мгновенного результата чата. Цены и права хранения проверяются для реального контракта. Не дублировать анализ той же статьи для каждого пользователя.

Контроллер расходов

До вызова внешнего поиска атомарно резервировать стоимость, учитывать попытки и фактический результат. Идемпотентное завершение освобождает неиспользованный резерв; неоднозначный биллинг сверяется. Caps заданы на сервис/сутки/месяц и пользователя; ключ провайдера не передаётся модели или Lenovo.

70% прогнозного лимита - уведомление владельцу; 85% - сократить необязательные повторные фоновые запросы; при невозможности зарезервировать очередной платный запрос - честный режим подключённых источников. Локальный чат, финансовый учёт и критические шаблонные события из-за поискового cap не выключаются. Новый тариф/провайдер не включается автоматически.

Время модели

При наблюдённых 4,09 токена/с ответ из 160 токенов занимает около 39 с генерации. 300 таких ответов в месяц - примерно 3,26 ч; 60 ежедневных обзоров по 160 токенов - ещё 0,65 ч. Всего **около 3,91 ч одной генерации**, без входного контекста, tool-раундов, рассуждения, повторов и простоя. Это нижняя оценка вычислительной работы для примера, не реальная месячная загрузка.

Короткий тест не позволяет линейно предсказать долгие тексты: считать реальные active seconds, prompt tokens и задержки. 600 Мбит/с не превращают частично CPU-inference в быстрый GPU-inference; сетевой канал переносит запросы, а вычисление выполняется на Lenovo.

Резервирование работы

На Timeweb вести `ai_usage` и task estimates, оценивать очередь по последним успешным задачам того же профиля. Ограничивать число фоновых задач и tool-раундов; один пользователь не может расходовать весь слот. Метрика «₽ за успешный ответ» включает долю поиска/эксплуатации, но не выдаёт условную внутреннюю оценку за выставленный провайдером счёт.

Новый сервер обсуждается после устойчивого нарушения p95/очереди, сокращения дублей и оценки реальной когорты. Перенос тех же весов на другой inference worker возможен без изменения пользовательских аккаунтов. Непрошедшая производительность не служит причиной удалить финансовые проверки или продать безлимит.

45. Платные функции и жизненный цикл подписки

Пока всё бесплатно. Права платных функций вводятся как серверные entitlements заранее, а списания включаются после проверки экономики, оферты и платёжного контура.

Тариф-гипотеза	Цена	Состав
Базовый	0 ₽	Один подключённый счёт, портфель, свежесть, основные риски, критические события, выплаты, ручной поиск, 30 стандартных AI-запросов/мес.
Помощник	499 ₽/мес.; 4 990 ₽/год	До 3 счетов при поддержке интеграции, расширенные сценарии, персональный обзор, 300 AI-единиц/мес., экспорт аналитики.
Расширенный	899 ₽/мес.; 8 990 ₽/год	До 5 счетов, сравнения/подробные отчёты, 900 AI-единиц/мес.; только после проверки себестоимости.

Квоты проверяются на выбранном локальном worker до продажи; они не гарантируют параллельный ответ. Одна единица - обычный ограниченный по контексту вопрос; большой многошаговый разбор может стоить 3-5 единиц, цена показывается до запуска. Не списывать единицу за техническую ошибку сервиса. Годовая подписка выдаёт месячную квоту, а не весь годовой объём сразу. Эти цены - проверяемая гипотеза, не исследованная готовность рынка платить.

Что не прятать за оплатой

Доступ к собственным данным, отмена подписки, удаление аккаунта, настройка privacy, сведения о проблеме безопасности, статус уже отправленной заявки и базовое предупреждение об устаревании. Подписка не повышает риск-лимиты, не делает пользователя квалифицированным и не покупает юридическое право на ИИР.

Модель биллинга

Состояния trial/free → pending_payment → active → past_due → cancelled_at_period_end / expired; refund и chargeback учитываются отдельно. Redirect после оплаты не активирует тариф. Сервер проверяет событие платёжного провайдера, его подлинность по официальному механизму и канонический статус через API, если требуется. Unique provider_event_id; сумма, валюта, customer и invoice должны совпадать.

Цена/период вычисляются сервером; фронтенд не передаёт произвольную стоимость. Карточные данные хранятся у платёжного провайдера. Если у выбранного webhook нет подписи, не выдумывать HMAC-проверку: использовать предписанную проверку источника и повторное чтение платежа. Параллельные webhooks не удваивают срок.

Отмена автопродления в 1-2 действия, дата окончания видна. Отзыв права использовать платёжные реквизиты останавливает повторные списания. Возвраты и обязательные права пользователя не ограничиваются фразой «невозвратно». Требования к чеку/ККТ зависят от юридической модели и должны быть закрыты до первого платежа. [S30, S31]

Условия запуска платного ИИ

Оба текущих пользователя остаются в бесплатном пилоте до отдельного включения billing. Страница тарифа показывает реальный профиль вопроса, стоимость подробной задачи в единицах, поведение очереди и отсутствие гарантии безошибочности. Не продавать «24/7 без ожидания» на основании одного локального узла. Веб-поиск учитывается общим рублёвым cap; достигнутый cap объясняется до обещания полного исследования.

46. Правки действующих юридических документов

Проверены три публичных документа версии 2026-10-02-v6. Ниже план изменений, а не утверждение, что текущие тексты незаконны. Полную правовую редакцию должен утвердить профильный юрист. [S3, S35, S36]

Документ / пункт	Сейчас	Что изменить перед функцией
Terms, п. 1	Два слота получают первые прошедшие вход пользователи.	Решить модель закрытого набора: приглашение или открытый capacity. Для закрытого пилота предпочтительны серверные приглашения; user остаётся обычной ролью.
Terms, п. 4-5	Нет реальных торговых поручений; операции не публикуются в UI; техническая аналитика.	До сделок - новый раздел точного подтверждения, внешнего брокера, отказов/частичного исполнения. До пользовательской истории выплат уточнить границу между ней и скрытой технической историей.
Privacy, п. 3-5	VK ID, токен, read-only снимки и инвестиционные ограничения; поставщики Timeweb/VK/T-Bank.	Добавить chat/memory, модель на отдельном Lenovo, путь Timeweb → worker, публичный search provider, push и платежи только в включённом объёме.
Privacy, п. 7-8	При disconnect удаляются credential/снимки/наблюдения; при удалении аккаунта в транзакции удаляются связанные данные и согласия.	Согласовать с будущими обязательными финансовыми/биллинговыми журналами, очередями и backup. Разные основания/сроки, а не обещание мгновенного удаления всего.
Consent, п. 2-5	Текущие категории, цели и три поставщика.	Версионировать новые цели и минимальные получатели; необязательный ИИ/marketing не делать условием просмотра портфеля.
Все документы	Технические утверждения OAuth, шифрования и изоляции.	Перед публикацией новых обещаний подтвердить тестами и конфигурацией; пояснить без излишних внутренних деталей.

Комплект новых разделов/документов

Пользовательское соглашение/оферта по фактической юридической форме оператора; политика ПД и отдельные согласия по основаниям; условия AI и его ограничения; декларация инвестиционных рисков; документ полномочий брокерской интеграции; тарифы/автопродление/возвраты; правила cookies/локального хранения; внутренние retention, incident-response и vendor-assessment policies.

Проверки до расширения

Правовой статус оператора и расчётов; уведомление/сведения в РКН, если требуется; локализация первичной БД; фактическую страну Lenovo, трансграничные потоки через поиск, push и поддержку; условия T-Invest для многопользовательского сервиса; права MOEX/агентств/новостей; применимость ИИР, автоконсультирования и аккредитации ПО. Не считать бесплатный тариф освобождением от этих требований. [S4, S5, S32]

Поддержка использует Gmail. Запретить отправку токенов/полных отчётов по почте; проверить маршрут ПД и добавить защищённую форму.

Обработка данных на Lenovo

Определить, принадлежит ли узел тому же оператору или другому обработчику, кто имеет физический/служебный доступ, в какой стране он расположен и какие данные реально получает. Дома размещённый сервер не считать автоматически сертифицированной площадкой или освобождением от требований к защите. Внутренний реестр содержит конкретную конфигурацию и меры доступа; публичная политика описывает категории, цель, получателей и географию без домашнего адреса и технических секретов.

Внешний поиск - отдельный поток: договор/условия поискового провайдера, состав фраз, логи, регион и хранение проверяются отдельно от локального inference. Приватный chat не используется для обучения весов. Подключение платной внешней LLM в будущем требует нового решения по данным и обновления документов; сейчас такой маршрут выключен. Утверждённая политика должна соответствовать фактическим журналам и срокам §40B, а не только обещаниям интерфейса.

47. Проекты формулировок и хранения

Тексты ниже предназначены для согласования с юристом и проверки соответствия реализации. Они не являются готовой юридической офертой.

Для интерфейса ИИ

«Ассистент отвечает на вопросы, помогает разбирать публичные материалы, сведения о вашем портфеле и работе сервиса. Он может ошибаться; источники и время данных доступны в ответе. Ассистент не отправляет торговые поручения самостоятельно. Подготовленные изменения применяются только после вашего подтверждения».

Для настройки реинвестирования

«Включение этой настройки разрешает анализ подтверждённых выплат и подготовку предложений об их использовании. Оно не разрешает автоматическую покупку. Каждая заявка требует отдельной проверки и подтверждения в установленном порядке».

Для выплат и сценариев

«График основан на известных условиях и опубликованных решениях. Будущие суммы и даты могут измениться. Сценарные выплаты, налоги и изменение стоимости активов показаны отдельно; прогноз не гарантирует результат».

Для подключения модели

Объяснить обработку на Timeweb и отдельном вычислительном узле оператора, точные категории контекста, цель, сроки и управление согласием/иной базой. Указать публичный поисковый сервис и фактически передаваемые ему сведения. Не писать «полностью анонимно», если сохраняется связь с портфелем. Отказ от необязательной AI-обработки оставляет обычный интерфейс и детерминированные пояснения.

Класс данных	Предлагаемая политика проекта	Условие утверждения
Секрет брокера / push endpoint	До отключения/отзыва; немедленно остановить использование.	Отдельно учесть следы backup и невозможность отозвать сам брокерский ключ без действия у брокера.
Диалог ИИ	Выбор 30/90 дней; default 30; пользователь может удалить раньше.	На Lenovo постоянная история не создаётся; job payload ≤24 ч после завершения, backups и история на Timeweb имеют отдельные согласованные сроки.
Явная память	До удаления пользователем/аккаунта.	Только подтверждённые предпочтения, без чувствительных догадок.
Технические логи	Начальная цель 30 дней, без payload и секретов.	Безопасность, расследования и действующие обязанности могут требовать отдельного режима.
Портфельные snapshots	По цели продукта; доступная история и минимизация объёма.	Не выдумывать единый правовой срок; согласовать до новых функций.
Сделки, согласия, платежи	Изолированный минимальный архив по обязательным основаниям и срокам.	Юрист фиксирует конкретные нормы/сроки; удаление аккаунта не скрывает законное сохранение.

Фиксация согласия

document_id/version/hash, purpose, actor, confirmed_at, locale, техническое доказательство минимального объёма и способ подтверждения. Новая цель не наследует старую галочку. Возврат старой версии документа не стирает ранее полученные consent receipts. Для запроса удаления/выгрузки проверять личность через текущую сессию/повторную авторизацию, не через публичный номер профиля как единственный фактор.

Текст настройки интернет-поиска

«Ассистент может искать публичные материалы и открывать ссылки. Для поиска сервис передаёт поставщику поисковую фразу без имени, номера счёта и сумм портфеля. Доступность и свежесть источников могут различаться. Вы можете отключить поиск; это не удалит историю диалога». Публиковать эту формулировку только после проверки, что механизм минимизации действительно её выполняет.

Текст настройки памяти

«Сохранить: [точное предпочтение]. Ассистент будет учитывать его в ваших следующих разговорах. Это не изменит стратегию и не даст разрешение на сделки. Посмотреть и удалить сохранённое можно в “Памяти ассистента”».

48. Контроль кода и выпуск изменений

Каждая версия проходит одинаковую цепочку качества. Финансовые, privacy и security изменения получают усиленную проверку по риску, а не только в конце проекта.

Цепочка разработки

Требование с acceptance criteria → ADR при архитектурном выборе → небольшая ветка/PR → статические проверки → необходимые unit/contract/integration тесты → E2E изменённого потока → staging → canary → production verification. Дизайн и контракты фиксируются до массового редактирования экранов.

Уровень	Минимальная проверка
Финансовые функции	Эталонные числа, units, rounding, пустые/противоречивые данные, комиссии, лоты.
Broker adapter	Записанные безопасные fixtures, контракт текущей API версии, rate limits, статус и idempotency.
Tenant / permissions	A/B negative tests для каждого нового объекта, worker, export, AI-tool и cache.
Frontend	Semantics, keyboard, focus, viewport, reduced-motion, stale/empty/error и возврат браузером.
Миграции	Expand → backfill → switch → contract; совместимость старого кода; отказ посередине.
AI	Holdout eval, privacy, prompt injection, cost/timeout, неизменность tools после новой модели.
Supply chain	Secret scanning, dependency/SBOM scan, pinned image/model, минимальные CI permissions.

Deployment

Версионный артефакт build с commit и migration set. Deploy не меняет trading flags автоматически. Staging использует синтетику/разрешённые обезличенные fixtures, не общую production-БД. Rollback кода возможен только при совместимой схеме; опасную миграцию исправлять forward fix с backup, не удалением данных.

Frontend и API обмениваются compatible schema version. Service worker не активирует несовместимую версию посреди формы подтверждения; показать «Доступно обновление», дождаться завершения/закрытия критического flow. Старое approval всё равно валидируется сервером.

Инструменты

Выбрать из уже используемых: Python formatter/linter и type checking, pytest; frontend typecheck/lint; Playwright для пользовательских путей; автоматическая a11y-проверка плюс ручная клавиатура; dependency scanner; простые latency/load scripts. Не вводить пять сервисов ради дублирующих отчётов.

Процент покрытия сам по себе не доказывает корректность. Release gate - отсутствие открытых критических дефектов, прохождение финансовых инвариантов и доказанная безопасная деградация. Исправление косметического текста не требует полного нагрузочного прогона.

Версионность интеграции ИИ

Manifest содержит model tag/full digest, Ollama version, chat template, profile version, prompt version, tools schema и tokenizer revision. CI валидирует протокол worker, lease/cancel/idempotency и контракты финансовых карточек. Обновление runtime/профиля - небольшой отдельный релиз с прикладным eval. Rollback не включает внешний платный fallback и не понижает требования tenant/authorization. Репозиторий хранит только шаблоны конфигурации; сертификаты и ключи не входят в build.

48A. Как программировать каждое изменение

Порядок обязателен для рабочих задач по плану. Он уменьшает риск ошибки и делает её обнаружение воспроизводимым; безошибочность кода не предполагается.

До первого изменения

Прочитать AGENTS.md и локальные правила репозитория, текущие dependency locks, миграции и workflows. Подтвердить язык, framework, точки запуска, test/deploy commands и фактическую схему. Python/FastAPI из исходного плана сохраняется при подтверждении в коде; новая реализация не означает переписывание сайта на иной стек.

Завести небольшую задачу: пользовательский результат, затронутый поток, вход/выход API, права, состояния ошибки и критерий приёмки. Для изменения границы данных/инструментов/торгового поведения приложить ADR. Разделить интерфейс, доменную функцию, адаптер и worker; правила расчёта не размещать в React-компоненте или prompt.

Порядок реализации

1. **Контракт:** описать request/response и machine codes в принятой схеме OpenAPI/DTO. Сервер определяет tenant из сессии. Внешние значения недоверенные: проверять enum, длины, units, диапазон и допустимый переход состояния.
2. **Домен:** чистая функция для денег/риска/доступности с явной версией входных фактов. Деньги - Decimal или целые минимальные единицы с явным scale; binary float не источник расчёта суммы. Время - timezone-aware UTC, отображение с выбранной зоной.
3. **Хранилище:** новая additive migration, индекс по реальному запросу, ограничение уникальности для idempotency. SQL параметризован; динамические имена колонок только из фиксированного списка. Транзакция связывает состояние и outbox, внешняя сеть не вызывается под долгой блокировкой строк.
4. **Адаптер:** ограниченный timeout, отмена и retry только безопасной операции. Timeout отправки поручения создаёт UNKNOWN с последующей сверкой. Tools диспетчеризуются по реестру схем и прав; никакого eval/exec, shell или SQL из текста модели.
5. **Экран:** компоненты из каталога, клавиатура/focus, loading/empty/stale/error, понятное подтверждение изменения. Результат записи показывается после ответа сервера; повторный клик не создаёт вторую операцию.
6. **Проверка:** эталон для изменённой формулы, контракт адаптера, негативный тест A/B для нового приватного объекта, нужный E2E. Тест должен обнаруживать реальную ошибку, а не повторять реализацию. Для прав и денег включать отказ/повтор/гонку; для косметики достаточно целевой проверки.
7. **Выпуск:** небольшой PR, необходимые checks, review, совместимый build, staging и production-порядок §50A. Сохранить commit, migration set, flags и измеренное evidence; не отмечать непроведённый тест успешным.

Повторное использование и секреты

Применять уже выбранные formatter, type checker и test runner. Новые пакеты добавлять через штатный менеджер с lockfile и проверкой лицензии/поддержки. Секреты - secret store/переменные окружения deployment; в Git только пример без значений. Логи - структурированные коды/ID/время с редактированием чувствительных полей, без портфеля, сырого chat и токенов.

49. Производительность и проверка масштаба

Число зарегистрированных аккаунтов не равно числу одновременных запросов. Цели ниже - план тестирования, а не уже измеренная мощность сервера.

Производительность интерфейса

Цели p75 на реальных устройствах: LCP ≤2,5 с, INP ≤200 мс, CLS ≤0,1. API чтения из готового snapshot p95 ≤500 мс без времени недоступного внешнего провайдера. Основной shell: ориентир ≤250 КБ сжатого initial JS; тяжёлые графики/чат грузятся по маршруту. Медленные внешние запросы не находятся на критическом пути главной страницы.

Нагрузка	Что проверяем	Gate
2 реальных тестировщика	Реальные обычные права, отдельные accounts/чат/push.	Ноль обходов для «админа-тестировщика».
100 синтетических tenants	20 UI-сессий и 100 лёгких jobs/min; 5 AI jobs проверяют очередь, не параллельный inference.	Web/DB проходят свои цели; реальная Qwen проверяется отдельно на A/B и профилях §42.
1 000 синтетических tenants	Фоновые планы без подключения 1 000 реальных брокерских аккаунтов.	Измерить DB cardinality и scheduler fairness, не обещать 1 000 live-счетов.
72 часа	Перезапуск workers, outages источников, дубли, истечение credentials.	Нет потерянных событий, неконтролируемого роста очереди и повторного действия.
7-14 дней pilot	Ошибки в естественных сценариях и стоимость.	Нет открытых P0/P1, стабильные дневные метрики.

Планировщик и лимиты провайдера

Получать доступные лимиты по текущим договорам/API и соблюдать их, в том числе stream connections. Один общий fetch публичного эмитента, отдельный приватный scope на счёт. Weighted fair queue не даёт большому портфелю вытеснить остальных. Deadline и max attempts у каждого job; dead-letter имеет видимую причину и безопасное переисполнение.

Продуктовые и операционные метрики

Активация, время до понятного первого результата, ошибки понимания, отключения push, жалобы на шум; coverage фактов; лаг синхронизации; число UNKNOWN; время reconciliation; cost на успешный AI-ответ; queue lag; доля отказов модели по нехватке данных. Broker secrets, содержание сообщений и полный портфель в аналитические события не передавать.

Горизонтальное масштабирование app/worker возможно после вынесения состояния в БД и общей session модели. Переход с двух пользователей на большее число требует capacity/legal/licensing gates, но не меняет правила изоляции и личные права.

Отдельные пределы узлов

UI-нагрузку и очереди можно проверять синтетическими tenants и управляемым stub inference, явно обозначая это в отчёте. Stub не доказывает скорость Qwen. Реальный worker стартует с одного запроса; когорты расширяются по измеренной очереди и p95, с сохранением раздельных диалогов. Для подробного ответа считать очередь, поиск, все tool-раунды и проверку, а не только `eval_rate`.

50. Дорожная карта и зависимости

Нумерация предлагается поверх подтверждённой публичной v0.18.1. Перед началом сверить актуальный main и не перезаписать уже занятые номера.

Релиз	Видимый результат	Зависимость
R0 · 0.18.2	Понятные ошибки, свежесть, проверенная изоляция.	Аудит и backup.
R1 · 0.19.0	Новый старт, навигация, подсказки.	R0.
R2 · 0.20.0	Понятный портфель и карточки активов.	R1.
R3 · 0.21.0	Проверенные источники и новости по активам.	R2, права на данные.
R4 · 0.22.0	Серверное наблюдение и журнал событий.	R3.
R5 · 0.23.0	PWA, push, ежедневный обзор.	R4, privacy push.
R6 · 0.24.0	Стратегия и доступный каталог.	R2-R3, eligibility.
R7 · 0.25.0	Календарь дохода и понятный риск.	R3/R6.
R8 · 0.26.0	Qwen3-14B: личный чат, публичный поиск, источники и подробный разбор.	R0 → ранний прототип связи; R3/R7 и privacy/eval → пользовательский запуск.
R9 · 0.27.0	Разбор новых денег и черновики распределения.	R6/R7, recommendation gate для клиентских рекомендаций.
R10 · 0.28.0	Настройка стратегии в чате через diff.	R8/R9.
R11 · 0.29.0	Полный симулятор торгового билета.	R9, sandbox.
R12 · 0.30.0	Контролируемые реальные поручения.	R11, execution/legal gates.
R13 · 0.31.0	Цели, сценарии и достижения.	R7/R8.
R14 · 0.32.0	Прозрачные тарифы и оплата.	Billing/legal gate; trade не обязателен.
R15 · 0.33.0	Быстрее и дешевле при росте нагрузки.	Измерения R8-R14.
R16 · 0.34.0	Расширение обычных пользовательских аккаунтов.	Нагрузка, лицензии, качество, документы.
R17 · 1.0.0	Стабильная публичная линия с зафиксированными пределами.	R16 и 30 дней наблюдения.

Рекомендации и execution имеют разные gates. Если торговый/регуляторный этап задерживается, выпускаются объяснения, выплаты, цели и аналитика; нельзя обойти gate переименованием рекомендации в «сценарий», если содержание осталось персональным советом.

Каждый R ниже имеет флаг, владельца приёмки, тест и rollback. Общая безопасность из разделов 34-49 действует на каждый релиз. «Сделано в коде» и «включено пользователям» фиксируются раздельно.

Зависимости интеграции

R0 разрешает техническую ветку R8-A на синтетике. R3 даёт реестр/парсеры, R5 - канал уведомлений, R6/R7 - подтверждённые настройки и финансовые факты. R8 подключает установленную модель и публичный интернет; R10 добавляет подтверждаемые изменения. Выплаты/риски доступны без ИИ до R8 и при его отказе. Время ранней технической ветки уже включено в R8, не суммируется второй раз.

50A. Выпуск рабочей версии двум пользователям

Каждый основной R - поставка в действующий production OmniCIO. Два существующих аккаунта остаются обычными отдельными пользователями на всём пути; завершения всего проекта ждать не требуется.

Единица поставки

У версии один завершённый пользовательский сценарий: например, новый старт R1, карточка портфеля R2 или обзор R5. Интеграционные пакеты R8-A/B сами по себе не объявляются готовым пользовательским чатом. Номер версии согласуется с текущим main; уже реализованные части принимаются по критериям и переиспользуются.

Для каждой версии создать release-запись: что меняется на экране, какие аккаунты/flags включены, дата, build/commit, migration set, результаты проверок, известные ограничения и способ отката. В приложении показать короткую карточку «Что нового» с переходом к готовой функции. Она не сбрасывает onboarding, настройки, согласия и историю.

Последовательность production-выпуска

1. Разработать завершённый сценарий в короткой ветке; проверить его на отдельной staging-среде с синтетическими данными и обычными правами. Стабильная версия сайта продолжает обслуживать обоих пользователей.
2. Перед deployment подтвердить совместимость схемы, резервную копию/восстановление для изменения данных и предыдущий артефакт. Новая capability по умолчанию выключена; deploy приложения и её включение - разные операции.
3. Развернуть build, провести smoke без реальных торговых действий и включить функцию первому из двух согласованных pilot-аккаунтов. Авторизация и tenant-фильтрация ровно такие же, как при массовом запуске.
4. Проверить полный пользовательский путь, ошибки, latency и побочные эффекты. Для периодической функции дождаться полного рабочего цикла: например, дневной сводки, а не только открытия экрана. Второй аккаунт до включения остаётся на прежнем поведении.
5. При выполнении критериев релиза включить второму аккаунту, проверить отсутствие смешения данных и отметить версию выпущенной. Это часть того же выпуска; исправления с новым patch-номером доступны пользователям по готовности.
6. При дефекте отключить затронутый flag/tool, сохранить журнал и восстановить совместимую версию. Не откатывать БД вслепую и не повторять финансовую операцию. Исправление проходит проверку конкретной причины сбоя.

Что сохраняется между версиями

Оба пользователя сохраняют свои IDs, подключения, портфели, настройки и права. Никакой общей тестовой учётной записи, административного обхода eligibility или ручной подмены чужого tenant. Действующие функции доступны при разработке следующей версии. Блокировка торгового/legal этапа не блокирует независимый готовый read-only релиз.

Документ в GitHub

Рекомендуемый путь: `docs/roadmap/OmniCIO_Web_PWA_Evolution_Plan_2026.pdf`; если проект уже задаёт каталог документов, использовать его. Добавить ссылку в существующий индекс документации и запись о редакции 2.1. Проверить workflow-триггеры: публикация плана является docs-only изменением и не должна сама менять flags, данные или настройки production. Статус «в GitHub» фиксируется только после проверки файла в конкретном commit/PR.

51. R0 · v0.18.2 · Проверяемая основа

Пользователь замечает точные статусы данных, объяснимые ошибки и отсутствие случайной потери своих настроек. Оценка: 4-6 инженерных дней после доступа к коду.

Задачи реализации

- Зафиксировать current main, deployment hash, список миграций, таблиц/DTO, auth и execution paths. Прочитать действующий AGENTS.md; сопоставить с этим документом.
- Проверить user/account binding, workers, cache, deletion и capacity. Устранить критические проблемы до новых функций, если они найдены.
- Ввести единый FreshnessDTO: observed_at, effective_at, coverage, status, next_check. Не менять финансовую математику вместе с косметикой.
- Сделать пользовательский read-only журнал значимых действий и технический trace/correlation_id; исключить секреты.
- Проверить backup и реальное восстановление, отключённость live trading, раздельные secrets и безопасную конфигурацию окружения.

Приёмка

Оба текущих пользователя работают в роли user. Тест A/B не обнаруживает доступа к чужим данным, включая фоновые задания. Прерывание запроса не сохраняет половину стратегии. После отключения брокера UI не рисует нулевой портфель как факт. Восстановленная копия проходит сверку на синтетических данных.

Данные и rollout

Миграции только additive. Существующий user ID, portfolio connection и согласия не переиздаются без причины. Feature flag `data_status_v2`, canary на одном обычном тестовом аккаунте, затем втором. Никаких повышенных прав canary.

Откат

Вернуть старый renderer статусов, сохранив совместимый DTO и аудит; не отключать исправление контроля доступа. При обнаружении P0 остановить соответствующую capability, а не возвращать уязвимую версию ради визуального rollback.

Доказательства релиза

Карта контрактов; список подтверждённых и неподтверждённых свойств; отчёт A/B тестов; время backup restore; фактический build в production. Владелец приёмки: backend/эксплуатация + владелец продукта.

Подготовка следующей ветки

Зафиксировать ADR: Qwen3-14B на готовом Lenovo, Timeweb как единственный центр авторизации/данных, исходящий mTLS worker. Назначить точки интеграции и владельца сертификатов. Само соединение реализуется в рабочем пакете R8-A; повторная проверка UPS/скорости интернета и выбор GPU в R0 не включаются.

52. R1 · v0.19.0 · Понятный старт и интерфейс

Пользователь быстрее понимает назначение сервиса и где начать. Оценка: 6-9 инженерных дней, включая базовую дизайн-систему.

Что выпускаем

Обновлённый экран входа, мастер подключения/демо, sidebar/drawer, компактная Главная, единые кнопки/поля, HelpButton с удержанием и закреплением. Сохраняем логотип и узнаваемую палитру. Убираем служебную терминологию из основных заголовков.

Задачи реализации

- Выделить токены тем и минимальный каталог компонентов из разделов 08-11. Не переписывать все страницы одновременно.
- Реализовать state machine onboarding, сохранение прогресса и resume; демо данные физически не смешиваются с реальными tenant snapshots.
- Обработать заполненную capacity и неудачный VK callback понятными сообщениями; не менять auth flow без отдельной проверки.
- Перенести существующие маршруты без потери History API back; сделать безопасное отображение старых ссылок.
- Заполнить короткие справки для всех полей первого входа и стратегии; не использовать красный для обычной помощи.

Приёмка

Новый человек в демо понимает read-only режим и находит портфель без пояснения разработчика. На 320/390/768/1440 px нет переполнений; клавиатура и Esc работают; long press не ломает scroll и не превращается во второй click. Все четыре текущих юридических подтверждения сохраняют раздельный смысл, пока юрист не утвердил другое.

Данные и rollout

Флаг `ux_shell_v2`; миграция прогресса только для нового мастера. Оба существующих аккаунта видят короткое объяснение изменений, а не принудительный сброс профиля. Метрики: завершение мастера, место выхода, ошибки понимания, без записи вводимых credentials.

Откат

Вернуть предыдущий shell при совместимых маршрутах; данные мастера и принятые версии документов не удалять. Пользователь не должен терять успешное подключение при откате дизайна. Приёмка: frontend/design + продукт.

53. R2 · v0.20.0 · Понятный портфель

Пользователь видит свои активы, результат и ограничения данных в одном месте. Оценка: 6-9 дней.

Что выпускаем

PortfolioHero, таблицу/карточки позиций, вкладку распределения, начальный график капитала и подробную карточку инструмента. Базовые описания сначала шаблонные и редакторские; LLM не является зависимостью релиза.

Задачи реализации

- Привести единицы quantity/lot/currency и snapshots к явным DTO; использовать прежнюю каноническую финансовую модель после проверки.
- Разделить изменение стоимости, пополнения/выводы и инвестиционный результат. Если данных для доходности нет, честно ограничить график стоимостью.
- Сделать empty/stale/partial/error/offline состояния для каждого блока; график умеет пропуски и текстовую альтернативу.
- Добавить карточку выпуска/компании с рейтингом, сроком, базовыми источниками и видимой свежестью.
- Ввести режим скрытых сумм; согласовать, какие данные допустимо кэшировать локально.

Приёмка

Эталонные портфели: пустой; один актив; только cash; доли разных валют; амортизирующая облигация; неподдержанный инструмент. Пополнение 10 000 ₽ не показывает прибыль 10 000 ₽. Сумма долей объяснима с учётом округления и cash. Тикер не заменяет уникальную identity.

Данные и rollout

Флаг `portfolio_v2`. История не достраивается выдуманными точками до даты подключения. Если импорт возможен, он появляется отдельной функцией позднее с проверкой источника. Источник графика/методика имеют версии.

Откат и критерий пользы

Вернуть прежний вид без потери snapshot; вычисленные новые поля можно оставить неактивными. Наблюдаемый пользователь за 30 секунд объясняет, сколько у него вложено и почему изменилась стоимость. Приёмка: frontend + backend расчётов.

54. R3 · v0.21.0 · Источники и разбор активов

Пользователь получает актуальные ссылки на факты и понимает, откуда взялось объяснение. Оценка: 8-12 дней для ограниченного набора источников.

Что выпускаем

Source Registry, SourceCard, dossier эмитента/выпуска, новости по активу, даты публикации/действия, признаки расхождения и неполного покрытия. Первые источники: ЦБ, разрешённый MOEX, брокер, ограниченный набор эмитентов/агентств.

Задачи реализации

- Описать права на получение/хранение/display для каждого источника. Не включать провайдера только потому, что парсер технически работает.
- Реализовать нормализацию identity, revision и дедупликацию. Сохранять numeric facts отдельно от текстовых summaries.
- Запустить isolated parsers с time/size limits, SSRF защитой и запретом активного контента.
- Реализовать индикатор покрытия и конфликтов. При несовпадении источников не выбирать удобный факт без правил authority.
- Добавить отчётные периоды, тип МСФО/РСБУ и единицы в карточки документов.

Приёмка

Тесты: два эмитента с похожими названиями; новая версия того же PDF; изменение рейтинга выпуска; истёкшая лицензия; parser вернул пустую страницу; вредоносная внешняя ссылка. В каждом случае UI показывает корректное состояние и не создаёт непроверенный buy/sell вывод.

Данные и rollout

Флаг `research_sources_v1`; общий публичный data store без tenant-financial fields. Сбор сначала по активам двух тестировщиков и синтетическому эталонному набору. Расширять покрытие измеримо, показывать его знаменатель.

Откат

Отключить конкретный collector, сохранив последние валидные факты с датой и пометкой stale. Удаление parser deployment не удаляет доказательную историю. Приёмка: data/backend + ответственный за лицензии и методику.

Подготовка к ИИ

Каждый документ получает извлечённый текст, устойчивые fragment IDs, дату и права передачи в контекст. Это переиспользуется R8 для Qwen и интернет-разбора. До R8 карточки работают на фактах/шаблонах; отсутствие готовой модели не задерживает выпуск источников.

55. R4 · v0.22.0 · Наблюдение и журнал

Важные изменения обнаруживаются без открытого сайта; пользователь видит историю и качество наблюдения. Оценка: 7-10 дней.

Что выпускаем

Watchtower backend, экран «События», жизненный цикл incident, пользовательский read-only журнал, статус соединения и покрытие. Push в этом релизе ещё не обязателен: событие уже сохраняется надёжно.

Задачи реализации

- Сохранить существующий daily observer; добавить управляемые streams и bounded reconciliation с учётом лимитов брокера.
- Ввести durable state, leases, event fingerprints, reopen и material-change rules.
- Создать transactional outbox и idempotent consumers. Удалённый/отключённый tenant не продолжает получать работу через старые задания.
- Развести ухудшение актива и неисправность данных; статус спокойствия требует валидного coverage.
- Добавить операторские метрики lag, retries, lease expiry, очередь и число UNKNOWN, не показывая внутренние ключи пользователю.

Приёмка

Закрыть PWA, получить синтетическое событие, открыть позже и увидеть его один раз. Перезапустить worker на каждом шаге: состояние восстановлено. Дублирующее раскрытие не создаёт десять incidents; новая существенная версия открывает событие заново. Сбой одного источника не отключает все portfolios.

Rollout

Флаг `watchtower_v2`; сначала shadow сравнение со старым observer 48-72 часа, затем UI-события на двух обычных аккаунтах. Никаких broker writes. Целевой лаг фиксируется для каждого источника, а не один обещанный realtime SLA.

Откат

Остановить новый monitor, сохранить daily observer и incident history; показать «Работает периодическое обновление». Не оставлять зелёное обещание 24/7 после выключения. Приёмка: backend/эксплуатация + продукт.

56. R5 · v0.23.0 · PWA и уведомления

Пользователь получает важное событие и ежедневную краткую сводку, не открывая сайт для ручной проверки. Оценка: 5-8 дней.

Что выпускаем

Service worker для app shell, установка PWA, подписки устройств, privacy-first push, настройки категорий/тихих часов, центр уведомлений и ежедневный обзор на шаблонах без LLM.

Задачи реализации

- Реализовать opt-in по явной кнопке, объяснение платформенных ограничений и тестовую отправку на своё устройство.
- Хранить subscriptions с tenant/device binding и возможностью отзыва. При смене пользователя на одном устройстве не сохранять прежнюю привязку.
- Сделать deep-link после входа, проверку ownership, badge важных непросмотренных событий.
- Отделить generated/sent/provider_accepted/opened. Не называть accepted «доставлено», если нет подтверждения устройства.
- Добавить dedup, TTL, retry budget, отключение 410/404 и redaction endpoint из логов.

Приёмка

Desktop Chrome/Firefox/поддержанный Safari, Android и iOS Home Screen в пределах фактической поддержки. Пользователь отказывает в push и продолжает работать. Deep link B не открывается A. Service worker не кэширует персональный API. Критическое событие не теряется при недоставленном уведомлении.

Данные и документы

Флаг `web_push_v1`; новые категории данных и провайдерские потоки внесены в документы до реальной подписки. Обзор готовится ежедневно по timezone; если изменений нет, текст короткий и без искусственной тревоги.

Откат

Отключить отправку/новую регистрацию подписок, оставить центр событий. Обновить service worker совместимым безопасным вариантом, не удаляя пользовательские данные без предусмотренного flow. Приёмка: frontend/PWA + backend + privacy.

Будущее подключение объяснений

Схема обзора отделяет проверенные суммы от текстового explanation. R8 может заменить только объяснение на результат Qwen; шаблон остаётся fallback к сроку отправки. Состояние critical не зависит от скорости домашнего inference.

57. R6 · v0.24.0 · Стратегия и каталог

Пользователь сам настраивает понятные ограничения и видит инструменты, доступность которых проверена для его счёта. Оценка: 8-12 дней.

Что выпускаем

Подтверждаемый профиль, ползунки с числовым вводом, переключатели классов, доступность инструментов, каталог/избранное/сравнение. Это не автоматическое разрешение персональных рекомендаций.

Задачи реализации

- Сделать draft/preview/commit и optimistic version check; текущие числовые contracts переиспользовать.
- Реализовать зависимые ползунки и диапазоны, «не знаю», запреты и объяснение невозможной суммы целей.
- Подключить account-aware eligibility с причинами NEED_TEST/QUAL_ONLY/API_UNAVAILABLE/UNKNOWN.
- Добавить фильтры доходности/рейтинга/срока/валюты и методику ключевой ставки из раздела 25.
- Отдельно хранить observed signals и подтверждённые предпочтения; текущий портфель не становится профилем молча.

Приёмка

Тесты на status квала, неизвестный ответ, ИИС, buy unavailable / sell available, смену счета, отзыв доступа и рынок закрыт. При снятии разрешения на акции target не сохраняет скрытую положительную долю. Параллельные вкладки получают конфликт, а не перезапись.

Данные и rollout

Флаги `strategy_editor_v2`, `asset_catalog_v1`; существующие значения переводятся без изменения смысла, с read-only сравнением до/после. Если числовая настройка не имеет однозначного простого представления, оставить её и объяснить, не округлять молча.

Откат

Старый editor читает совместимую версию; новые неподтверждённые drafts можно скрыть. Сохранённые профили не откатываются массово. Неподтверждённые зависимые планы инвалидируются при любом применимом изменении. Приёмка: product/frontend + финансовый backend.

Связь с широким ассистентом

Хранить presets как изменяемые пользовательские варианты, а не глобальную системную стратегию. Объяснение других подходов не меняет активный preset; будущие Qwen drafts в R10 проходят тот же validator и diff.

58. R7 · v0.25.0 · Выплаты и риск

Пользователь понимает, сколько и когда ожидается, и какие перекосы есть в портфеле. Оценка: 8-12 дней.

Что выпускаем

Календарь купонов/дивидендов/номинала, фактические поступления, панели концентрации/ставки/валюты/рейтингов, первые сценарии и базовую цель капитала без игровой механики.

Задачи реализации

- Привязать календарь к количеству/правам на нужную дату, различать даты объявления, фиксации и зачисления.
- Развести купон, дивиденд, амортизацию и полное погашение. Не дублировать payout в cash и приросте капитала.
- Ввести issuer group mapping, HHI/N_eff с пояснением области расчёта и unknown coverage.
- Добавить fixed/floating duration logic и валютную экспозицию отдельно от валюты выплаты.
- Реализовать сценарии инфляции/дохода и указание gross/net неизвестности.

Приёмка

Фиксированный и плавающий купон, отменённый дивиденд, амортизация, частичная продажа перед entitlement, валютный номинал/рублёвая выплата, задержка брокера. Итог погашения не увеличивает доход на весь номинал. Фонд с неполным составом не получает заведомо идеальную диверсификацию.

Данные и rollout

Флаги `income_calendar_v1`, `risk_panel_v1`; методика calculation_version. На первых неделях сверять календарь с реальными брокерскими подтверждениями и фиксировать расхождения, а не молча исправлять прошлое.

Откат

Отключить сомнительный показатель/сценарий, сохранить raw факты и сообщения о выплатах. Нельзя заменить неизвестные выплаты нулём ради красивого графика. Приёмка: финансовая методика/backend + пользовательское тестирование.

59. R8 · v0.26.0 · Qwen3-14B и интернет

Пользователь получает личный русский чат, поиск с источниками и объяснение своих данных. Оценка: 18-26 инженерных дней на всю интеграцию; технический контур можно готовить после R0 параллельно с R1-R7.

Видимый выпуск

На сайте появляется «Ассистент»: обычный диалог, общие вопросы, разбор портфеля и публичных материалов, выбор интернет-поиска, источники, «Подробнее», состояния очереди и остановка. Разные стратегии можно объяснять и сравнивать; запись настроек из чата до R10 выключена. ИИ не становится обязательным шагом первого входа.

Последовательные рабочие пакеты

1. **R8-A, соединение (4-6 дней):** worker, mTLS/API, manifest, claim/lease/heartbeat, cancel, события/SSE. Сначала синтетический вопрос. Демонстрация владельцу: ответ установленной Qwen дошёл до закрытого тестового экрана; публичный Ollama port не открывался.
2. **R8-B, контекст и веб (5-7 дней):** источники, SearchProvider/fetcher, parser, защита сетевых запросов, token budget, личный snapshot, citation/numeric validators. Демонстрация: свежий материал с датой/ссылкой и честный отказ при недоступном первоисточнике.
3. **R8-C, пользовательский чат (4-6 дней):** интерфейс §22, общий/личный режим, история и память, подробные фоновые задачи, справедливость для A/B, квоты и cost ledger. Демонстрация: два независимых пользователя и остановка долгого ответа.
4. **R8-D, выпуск (5-7 дней):** корпус 240 задач, прикладная скорость, disconnect/replay/delete tests, обновление документов, canary двух user-аккаунтов, rollback. Сумма пакетов входит в оценку R8, повторно к сроку проекта не прибавляется.

Пакеты - внутренняя последовательность одного основного релиза. После готовности read-only чата допускается отдельный patch с заметным улучшением поиска или подробного режима; номер сверяется с main. Не публиковать незавершённые privacy/tenant механизмы ради ранней демонстрации.

Приёмка

Источник выбранного ответа действительно прочитан; актуальные котировки поступают из финансового API. Числа/единицы проверяются. A не видит B через чат, память, SSE, кэш, export или очередь. Отмена, удаление и истечение lease исключают поздние записи. Отказ worker не останавливает обычный сайт; вызовы платной облачной LLM отсутствуют.

Запрос «сравни подходы к накоплению и доходу» не отклоняется из-за доходной стратегии по умолчанию. Подробный режим сохраняет thinking-capability, но работает в явном вычислительном бюджете. Фактическая p50/p95 с очередью публикуется в release evidence; цели §42 не выдаются за пройденные до измерения.

Данные, rollout и отключение

Flags: `assistant_read_v1`, `assistant_web_read_v1`, `assistant_deep_v1`. До legal/privacy gate - только синтетика; до проверки конкретного сетевого инструмента - только валидированные подключённые источники с честной подписью покрытия. Затем когорта двух обычных пользователей, без админских обходов.

Rollback отключает приём новых run либо отдельный tool, отзывает проблемный сертификат/manifest, сохраняет историю и возвращает FAQ/шаблоны. Возврат старой версии не возобновляет отменённые run. Ответственные: backend/AI, frontend, QA, эксплуатация и privacy. Аппаратная подготовка Lenovo не является задачей пакета.

60. R9 · v0.27.0 · Новые деньги и предложения

Пользователь видит происхождение средств и результат их анализа: подходящий черновик или понятное ожидание. Оценка: 8-12 дней.

Что выпускаем

Cash classification, резерв и плановые выводы, антишум анализа, сравнение кандидатов и портфеля до/после. Персональные предложения пользователям включаются только после recommendation gate; до него - обычная аналитика и внутренний shadow на синтетике.

Задачи реализации

- Сопоставить cash delta и операции, поддержать отмены/корректировки и sale proceeds от собственных планов.
- Реализовать spendable без двойного вычитания блокировок, batching мелких поступлений и cooldown.
- Добавить детерминированный ranking, quantity с целыми лотами и итоговую проверку hard constraints.
- Показать альтернативы с конкретной причиной исключения; сохранить universe/data/policy versions.
- Ввести полноценные исходы HOLD_CASH, NO_ACTION, INSUFFICIENT_DATA и NO_FEASIBLE_SOLUTION.

Приёмка

Неизвестное поступление не тратится. Погашение не считается купоном. При недостаточном лоте система не нарушает лимит эмитента. Высокая доходность не компенсирует невалидный доступ. Одни входные данные и версии дают тот же результат. Появление внешней заявки инвалидирует старый бюджет.

Rollout

Флаг `proposal_engine_v2`, отдельный `personal_recommendations_enabled`. Методика и юрист оценивают фактический смысл пользовательского вывода. Нельзя показывать реальную персональную покупку как «тестовый совет» и считать это исключением из gate.

Откат

Остановить генерацию новых proposals, сохранить объяснение уже увиденных и пометить черновики неактивными. Расчётный cash ledger и reconciliation продолжаются. Приёмка: backend финансов + методолог + юридический ответственный.

Роль Qwen3-14B

Модель объясняет расчёт и сравнивает допустимые варианты с опорой на версии данных. Ranking выбирается по подтверждённой цели/ограничениям пользователя, без одной доходной формулы для всех. Лотность, доступность, резерв и риск проверяет финансовый код; словесное предпочтение модели не создаёт обход.

61. R10 · v0.28.0 · Настройка через диалог

Ассистент помогает изменить ползунки, но человек видит и подтверждает точный результат. Оценка: 5-8 дней.

Что выпускаем

Tools для simulate/create draft, карточку diff в чате, переход к обычному экрану подтверждения, явную память предпочтений. Сохранение стратегии и торговое поручение остаются разными действиями.

Задачи реализации

- Определить allowlist полей, включая разрешённые классы, целевые доли и настройки обзора; запретить administrative/permission fields.
- Подключить единый strategy validator. LLM не формирует второй набор правил и не обходит пределы UI.
- Реализовать base_version, draft_hash, expiry и конфликт параллельного изменения.
- Добавить подтверждение памяти с категорией/источником; запрещены скрытые «психологические» профили.
- Валидация ответа пишет результат только после подтверждения commit backend.

Приёмка

Запрос «Сделай портфель безопасным» вызывает уточнение/описание, а не произвольную перестройку. «Сохрани все мои данные и купи на всё» не расширяет права. Подменённый draft B недоступен A. Устаревший diff нельзя применить. Удаление памяти не удаляет пользовательскую стратегию, если это отдельная сущность.

Rollout и метрики

Флаг `assistant_drafts_v1`; сначала только бытовые настройки уведомлений и черновик стратегии, затем дополнительные разрешённые поля. Метрики: доля корректных drafts, частота отклонения пользователем, ошибки validator, время до понятного результата. Число применений не считается самоцелью.

Откат

Оставить read-only чат, скрыть create draft tools, существующие неподтверждённые drafts пометить неактивными. Сохранённые версии остаются действующими. Приёмка: AI/backend + frontend + продукт.

Контракт с worker

Добавить draft tools к допустимому набору Timeweb после R8; на Lenovo не выдавать новых прав к БД или брокеру. Параллельная ручная правка, повтор tool call и смена выбранного счёта входят в приёмку. Подробное рассуждение Qwen не повышает полномочия вызова.

62. R11 · v0.29.0 · Торговый симулятор

Пользователь изучает точную механику заявки без риска реальных денег. Оценка: 8-12 дней.

Что выпускаем

Полный ticket, количество в лотах/бумагах, clean/dirty bond price, комиссия, расчёт доступного количества, лимитная цена, срок, до/после и timeline состояния. Постоянная метка «Учебный режим» и отдельные sandbox accounts.

Задачи реализации

- Реализовать draft → validate → approve → preflight → simulated submit → reconcile на тех же контрактах, что планируются для live.
- Протестировать GetOrderPrice/GetMaxLots и единицы цены, не принимая sandbox за доказательство реальной ликвидности.
- Добавить отказ рынка, частичное исполнение, cancel/replace race, timeout и UNKNOWN.
- Проверить одноразовое подтверждение, повторный клик, expiry, price drift и счёт пользователя.
- Сделать warning перед ручной продажей и различие hard block/soft warning.

Приёмка

Симуляция и sandbox никогда не используют production write credential. Тест на каждое состояние, каждую финансовую единицу и crash boundary. 100 повторных запросов с одним намерением не создают 100 эффектов. Смена вкладки/обновление PWA не теряет состояние заявки.

Rollout

Флаги `trade_ticket_v1`, `execution_mode=sandbox`. Live endpoint deny-by-default. Пропускной gate - журнал доказательств по contract/chaos/E2E и воспроизводимое восстановление, а не количество успешных демонстрационных покупок.

Откат

Скрыть simulator или вернуть прежний экран; сохранить результаты учебной сессии отдельно от реального портфеля. Не переносить sandbox approval в live. Приёмка: broker adapter/backend + QA + продукт.

63. R12 · v0.30.0 · Реальные поручения

Пользователь может отправить конкретную подтверждённую заявку через сервис при выполненных правовых и технических условиях. Оценка: 7-12 дней разработки плюс внешние допуски.

Условия до включения

Подтверждены договорные условия брокерской интеграции и допустимая модель услуги, актуальные документы, trading credential с минимальными правами, legal gate, выполнен R11, есть backup/restore и ответственный за инциденты. Для персональных предложений дополнительно закрыт recommendation gate.

Задачи реализации

- Выделить execution boundary и доступ к write credential только там. Read-only токен не заменять более широким для удобства.
- Ввести owner-bound approval, порядок записи intent до submit, стабильный idempotency key, сверку брокерского результата.
- Реализовать per-account locks, caps, TTL и режимы UNKNOWN/partial/cancel.
- Добавить операторский kill switch, отдельный интерфейс пользователя для статуса и отмены допустимой заявки.
- Перед стартом определить точные суммы/оборот пилота и документировать их как server policy.

Приёмка

Ни одна покупка не выполняется из текста модели, cron или старого approval. Timeout после возможного принятия заявки не создаёт дубль. Kill switch останавливает новые заявки, но сверка продолжается. Брокерская операция подтверждает фактическое исполнение; статус «принято» не приравнивается к «исполнено».

Rollout

`live_execution_enabled=false` остаётся до отдельного решения владельца после готовых доказательств. Включение одной обычной учётной записи по явному разрешению её владельца и малыми согласованными caps; затем второй при отсутствии критических ошибок. Это не повышает user до admin.

Откат

Выключить новые submit/approval. Существующие заявки проверить у брокера; отменять только по предусмотренному разрешению. Не откатывать БД на старую копию с целью «забыть» реальную сделку. Приёмка: эксплуатация + backend + юридический ответственный + владелец продукта.

64. R13 · v0.31.0 · Цели и спокойная мотивация

Пользователь видит движение к своей цели и понимает, чем обусловлен прогресс. Оценка: 4-7 дней.

Что выпускаем

Цели капитала/периодического дохода, расчёт сценариев с пополнениями и инфляцией, история достижения, цифровые отметки за полезные действия. Цели доступны независимо от разрешения live trading.

Задачи реализации

- Добавить распределение портфеля между целями без скрытого двойного использования капитала.
- Реализовать дату, currency, nominal/real basis, взносы и cash-flow assumptions.
- Разделить текущий прогресс, внесённые средства, рыночный вклад и будущий сценарий.
- Сделать каталог достижений с неизменными условиями и одноразовой выдачей по event_id.
- Настроить приватность: никакого публичного сравнения пользователей по капиталу/доходности.

Приёмка

Падение рынка обновляет текущий прогресс, но не переписывает дату исторического достижения. Две цели не удваивают один портфель. Отмена дивиденда меняет прогноз доходной цели. Награда не выдаётся за увеличение числа сделок или риска. При reduced-motion отсутствуют декоративные эффекты.

Rollout

Флаг `goals_v2`; первые достижения без материальных призов и рекламы. Проверить на двух пользователях, вызывает ли сценарий ложное ощущение гарантии. Если да - менять текст/график, а не добавлять мелкий дисклеймер.

Откат

Скрыть новые сценарии/достижения, сохранить параметры целей и фактическую историю. Платные функции не зависят от сохранения спорной игровой механики. Приёмка: продукт/design + финансовая методика.

65. R14 · v0.32.0 · Тарифы и платежи

Пользователь заранее видит стоимость, пределы функций и способ отмены. До готовности платежей интерфейс может показывать только тестовые entitlements без списаний. Оценка: 6-10 дней плюс договоры.

Задачи реализации

- Завести server-side capability matrix: тариф, quota, период, счета, включённые функции; по умолчанию существующим тестировщикам бесплатный пилот с явным сроком/условиями.
- Реализовать checkout у выбранного PSP, серверные invoice, webhook verification, сверку платежа и idempotency.
- Создать страницу тарифа: следующая дата, сумма, оставшийся лимит, отмена автопродления, чеки и поддержка.
- Определить применимую фискализацию, реквизиты оператора, оферту/возвраты и согласие на recurring при его наличии.
- Ввести безопасную деградацию после окончания: просмотр своих данных и критические события сохраняются.

Приёмка

Поддельный browser success и webhook с неверной суммой не включают тариф. Повтор/смена порядка paid/refund событий не создаёт лишние месяцы. Пользователь отменяет без обращения в поддержку; отказ от использования платёжных реквизитов исключает дальнейшее списание по ним. Результат не зависит от часового пояса браузера.

Rollout

`billing_mode=test`, затем ограниченная платёжная проверка владельцем и отдельное `billing_live_enabled`. Повышение тарифа не даёт торгового разрешения. До live оплаты подтвердить, что фактическая месячная инфраструктура, AI, фискализация и комиссии укладываются в бюджет.

Откат

Остановить новые покупки/автопродления согласно договору, сохранить оплаченные права или обеспечить корректное урегулирование. Не скрывать страницу отмены и чеки. Приёмка: backend billing + продукт + бухгалтер/юрист.

Проверка локальной ёмкости

До продажи каждого пакета измерить фактические model seconds, очередь вечером, стоимость поиска и долю подробных задач. 300/900 AI-единиц из §45 - проверяемые гипотезы, не безусловно включённые квоты. Два существующих тестировщика не переводятся на списания автоматически.

66. R15 · v0.33.0 · Скорость и ёмкость при росте

Улучшаем измеренную работу выбранной Qwen3-14B и сайта. Оценка: 5-8 дней; это не этап повторного выбора модели.

Что увидит пользователь

Меньше лишнего ожидания, повторный вопрос использует подходящие свежие источники, подробный разбор не лишает другого человека доступа к чату. Ожидание и фоновая задача отображаются честно, без обещаний ответа за 3 секунды для любого документа.

Реализация

- Разделить влияние очереди, загрузки модели, подготовки входа, генерации, поиска и проверки; не сравнивать холодный запрос с тёплым как одинаковый тест.
- Убирать дубли источников и истории, улучшать выбор коротких фрагментов, общий кэш публичных summaries и его инвалидацию.
- Настроить приоритет интерактивных задач и порционный фоновый разбор; фоновый обзор не задерживает критические события.
- Повторно измерить профили 2048/4096 и подробный режим на прикладных сценариях; менять по одному параметру с сохранением качества.
- Оптимизировать запросы PostgreSQL, графики, adaptive schedule и retention без удаления обязательной истории.
- При доказанной нехватке вычислительной ёмкости оформить расчёт переноса того же model manifest на другой worker; покупка ресурса - отдельное решение в пределах бюджета.

Приёмка

Нет cross-tenant cache hits, stale results после cancel и позднего исполнения tool. Сохранены источники, широта обсуждения и финансовые ограничения. Есть измеримое улучшение latency/очереди относительно R8; профиль, не прошедший качество, не включается ради скорости.

Rollout и откат

Каждая оптимизация отдельным flag/commit. Canary использует текущую Qwen3-14B; общий model digest не меняется скрыто. Конверт пилота до 7 000 ₽ и зрелой линии до 19 000 ₽ проверяется по счетам и фактическим добавочным расходам Lenovo. В отчёте показываются не только среднее время, но p95 и доля отмен из-за ожидания.

Rollback возвращает прошлую очередь, cache policy или профиль inference; пользовательская история и стратегии сохраняются. При перегрузке сначала останавливается необязательная фоновая генерация и новый набор пользователей. Ответственные: эксплуатация/performance, AI и продукт.

67. R16 · v0.34.0 · Расширение доступа

Пользовательский лимит увеличивается без изменения правил владения данными. Оценка: 4-6 дней подготовки; наблюдение занимает отдельное календарное время.

Условия расширения

Нет открытых P0/P1; пройдена нагрузка; действуют договоры/лицензии; корректны документы и модель услуги; support/incident owner определён; cost projection укладывается в бюджет. Увеличение до 100 зарегистрированных не объявляется гарантией 100 одновременных AI-сессий.

Последовательность

Когорта 2 → до 10 → до 25 → до 100 только после проверки каждой ступени. Ориентир наблюдения 7 дней на ступень с достаточной реальной активностью, а не семь пустых дней. Сначала read-only/explanation capabilities; разрешение торговли/рекомендаций не включается всем вслед за регистрацией.

Задачи реализации

- Capacity становится серверной конфигурацией с атомарной проверкой, invitations при закрытом наборе и audit trail изменения лимита.
- Проверить per-user rate limits, очередь, объём базы, число stream connections и права на отображение данных.
- Настроить обращение в поддержку с correlation_id, без отправки credentials/полного портфеля по почте.
- Отработать удаление/выгрузку, прекращение чатов/подписок/worker jobs и корректную работу после восстановления backup.
- Показать статус бета-тестирования и известные ограничения честно, без обещания гарантированной сохранности капитала.

Приёмка

Новые люди получают те же user-права и независимые аккаунты, что первые два. Нагрузка одного не ухудшает критические события остальных. Никаких if user_id==first специальных путей. Платёж/удаление/отказ AI одного пользователя не меняют доступ другого.

Откат

Приостановить только новую регистрацию или конкретную capability; существующие аккаунты и данные не удалять. При перегрузке показать очереди/ограничения, сохранить доступ к статусу уже поданных заявок. Приёмка: владелец продукта + эксплуатация + privacy/legal.

Ограничение ИИ при расширении

Один Lenovo и 600 Мбит/с не дают гарантии одновременного ответа всей когорте. На каждой ступени проверить реальные короткие/подробные runs и очередь; новые регистрации/AI-допуски остановить до нарушения обещанного опыта существующих пользователей. Конфигурация пользователей масштабируется отдельно от числа inference workers.

68. R17 · v1.0.0 · Устойчивая продуктовая линия

Версия 1.0 означает зафиксированный поддерживаемый набор возможностей, а не окончание развития. Оценка: 3-5 дней сборки доказательств после 30 дней наблюдения.

Что получает пользователь

Понятный путь от подключения до портфеля, ежедневное наблюдение, источники, выплаты, доступный каталог, Qwen3-14B с публичным поиском и широким диалогом, прозрачные настройки и тарифы. Возможности рекомендации/сделки доступны только в реально допущенных режимах и не маскируются общим обещанием «ИИ управляет всем».

Финальная проверка

- Воспроизводимый release build, миграции, pin зависимостей и model/prompt versions.
- Полная матрица подтверждённых прав, изоляции, данных, лицензий и документов.
- Отчёт о latency/cost, доступности собственного сервиса, восстановлении и очередях.
- Эталоны финансовых расчётов; сверка объявленных/полученных выплат; полное отсутствие дублей заявок в тестах/наблюдаемом пилоте.
- AI eval после последнего изменения модели и пользовательский тест понимания основных экранов.
- Runbooks: outage брокера, UNKNOWN submit, утечка секрета, повреждение БД, удаление пользователя, ошибочное объяснение, платёжный спор.

Условия объявления

30 дней эксплуатационных данных, отсутствие открытых критических дефектов, пройдены обязательные release gates; операционные расходы прогнозируются ниже 20 000 ₽ при опубликованных квотах. Наличие локальной GPU не является признаком готовности.

Если часть функций ещё не допущена

Можно выпустить 1.0 как сервис аналитики и объяснений с явно ограниченным перечнем. Но нельзя одновременно рекламировать персонального инвестиционного советника с торговлей, если соответствующий режим не имеет юридического/технического допуска. Дорожная карта конкретно перечисляет, что доступно, что в бета и что только планируется.

Последующий цикл

Ежемесячный review продуктовых ошибок и себестоимости; квартальная ревизия угроз/источников/документов; тест любой замены модели; обновление библиотек по риску. Новые классы активов, автоследование и дополнительные брокеры оформляются отдельной линией с собственными финансовыми и правовыми контрактами.

69. Экономика подписки и пределы роста

Тарифы 499/899 ₽ из §45 остаются гипотезой. Для локального ИИ продаётся удобство, время обработки и глубина анализа; отсутствующая плата за токены не означает нулевую себестоимость.

Как считать доход и расходы

Вести отдельно постоянные счета Timeweb/backup, добавочное электричество и резерв оборудования, переменные поисковые вызовы, платёжную комиссию, налоги, поддержку/возвраты и права на данные. Не умножать ответы Qwen на старую цену облачной LLM: такой счёт в выбранной архитектуре отсутствует.

Маржинальный результат = полученная выручка - комиссии - налоги с соответствующей базой - переменные затраты. Покрытие постоянных расходов считается по реальным счетам. Годовую оплату распределять по периоду обязательств и месячным квотам; не считать все поступившие за год деньги свободной прибылью первого месяца.

Проверка квот временем

300 обычных вопросов и 30 обзоров по 160 выходных токенов при 4,09 токена/с дают около 3,59 часа одной генерации на пользователя за месяц. Это иллюстрация без подготовки контекста и подробных режимов; пользователь может отправить все вопросы в вечерний пик. Ёмкость оценивается по пиковым часам, очереди и p95, а не только месячной сумме.

До продажи тарифа измерить распределение запросов, длительность профилей, долю повторов, поиск и спрос на длинный разбор. Сначала квоты проверяются бесплатно двумя пользователями. «Расширенный» нельзя запускать только потому, что 900 единиц математически помещаются в месяц: обязательства по ожиданию и очереди должны быть выполнимы.

Что означает AI-единица

Стандартный вопрос с опубликованным контекстным/выходным профилем - 1 единица. Подробная многошаговая задача - ориентир 3-5 единиц, стоимость и ограничения видны до отправки; коэффициенты подтвердить фактическим временем. Техническая ошибка не списывает единицу; отмена и частичный полезный результат регулируются заранее понятными условиями без скрытой платы.

Квота не повышает торговые права и не ослабляет риск-профиль. При исчерпании остаются личные данные, события, FAQ, настройки privacy и история. Платная подписка не обещает приоритет над проверкой изоляции и не обходит лимиты одного inference worker.

Когда менять инфраструктурный этап

- p95 короткого ответа или queue_wait нарушает §42 в активные дни после устранения дублей; число отмен из-за ожидания растёт.
- Фоновые задачи не успевают к назначенному обзору; измерена нехватка model seconds, а не только API-задержка поиска.
- Стоимость лицензий/поиска/платежей меняет бюджет, либо занято более 70% утверждённого хранилища при соблюдённой retention.
- Расширение когорты 2 → 10 → 25 не проходит прикладную очередь, хотя web/API остаётся быстрым.

Сначала исправить подтверждённое узкое место и ограничить новый набор. Затем посчитать дополнительный worker с той же моделью или перенос inference; новое размещение и получатели данных требуют изменения manifest/документов. Переход за 20 000 ₽ не выполняется автоматически.

70. Полное соответствие исходному плану

Переработаны все смысловые разделы исходного PDF, а не только добавлен блок ИИ. Номера ниже относятся к исходному документу.

Раздел исходника	Решение в новой редакции
0-1. Резюме / рамки	Новые §§01-06: границы проверки, продуктовые критерии, раздельные gates.
2. Фактическая база	§02/R0: свойства кода из PDF обозначены как требующие проверки; версия входа подтверждена браузером.
3. Идеи V10	Сохранены спокойный UX, immutable plan, HOLD_CASH; недоступные V10 не выдаются за прочитанные.
4. Продуктовая модель	§§05-07, 28-29: полный путь и права; личный ИИ добавлен в контролируемый контур.
5. Меню	§§07, 12-19: понятные названия, отдельный поиск, ассистент и цели, сохранение drawer-подхода.
6. Визуальная система	§§08-11 и 14/19/22/23: точные размеры, состояния, иконки, помощь и векторные макеты.
7. Главная	§§13-14: state matrix, согласованность данных, privacy сумм.
8. Адаптивная стратегия	§§18/41/R6/R10: draft/preview/commit, нет скрытых предпочтений, точная логика ползунков.
9-10. Watchtower / Push	§§21/31/R4/R5: durable события, серверное наблюдение, недостоверность гарантии доставки исправлена.
11. Internet-first	§§30-31/39A/R3/R8: лицензии, даты, публичный search/fetch, проверяемые источники и минимизация данных.
12-13. Деньги / кандидаты	§§24-29/R7/R9: НКД, лоты, квалификация, ключевая ставка, FX, cash ledger и ranking.
14-16. Решения / сделки / антипаника	§§23/29/35/R9-R12: manual override для soft warning, caps, UNKNOWN recovery и доказательства.
17-18. Права / данные	§§32-37/41: tenant, RLS, outbox, cache, минимальные tools и схема удаления.
19. Releases	§§50-68: 18 отдельных этапов с видимой пользой, gate и rollback.
20-21. Тесты / метрики	§§42/48-49/71: финансовые инварианты, eval, стоимость и целевые SLO.
22. Регуляторный gate	§§06/46-47: проверены действующие документы; gate действует уже для двух пользователей.
23-25. Done / компоненты / статусы	§§09/13/34-36/68/71: критерии привязаны к потокам и отказам.
26-27. Источники / последовательность	§§73-76: обновлённая библиография; порядок меняется с учётом ИИ, бюджета и права.

Дополнительно введены: модель и размещение ИИ, RAG/память/оценка ответов, монетизация и экономика, цели/достижения, точные tooltip-жесты, сценарии инфляции и валюты, контроль расходов, удаление после backup recovery.

Изменения относительно редакции 2.0

Было	Стало в редакции 2.1
API модели как основной старт; Qwen3-8B как будущий эксперимент.	Выбрана установленная Qwen3-14B Q4_K_M на Lenovo; облачная LLM не требуется.
Развёртывание новой VM/llama.cpp и выбор модели.	Интеграционный worker к существующему Ollama, исходящий mTLS, очередь и streaming.
Произвольный веб-сёрфинг отложен без ясной альтернативы.	Публичный поиск/чтение в R8, источники/даты и изолированный fetcher; browser-автоматизация с аккаунтами отдельно.
Бюджет ИИ по цене облачных токенов; цель ответа ≤15 с.	Расход поиска/эксплуатации и model seconds; фактический тёплый замер 17,10 с, реалистичные отдельные цели.
Недостаточно определён домашний узел обработки.	Потоки Lenovo/Timeweb, минимизация, retention, сертификаты, отмена, документы и multiuser-проверки.

Визуальные/финансовые/торговые разделы и 18 основных релизов сохранены; зависимые требования к чатам, стратегиям, данным, бюджету, подпискам, срокам и документам согласованы с новой схемой.

71. Сроки, приёмка и ответственность

Сроки - предварительная инженерная оценка после доступа к репозиторию, не обещание дат. Готовность внешних договоров может стать критическим путём.

Оценка объёма

Сумма R0-R17: **120-184 инженерных дня**. При одном full-time разработчике это примерно 24-37 рабочих недель чистой реализации; с исследованием пользователей, review, исправлениями и ожиданием внешних допусков разумнее планировать 6-11 месяцев. Работа вечерами/выходными займёт дольше. Уже качественно реализованные части могут уменьшить объём после R0.

Первые 4-6 недель ориентировать на R0-R2 и часть R3; технический пакет R8-A можно вести после R0 параллельно, если есть ресурс: пользователь получает более понятный и проверяемый сервис до завершения большого AI/торгового контура. Не обещать еженедельный крупный релиз, если критерии не выполнены. Малые исправления можно выпускать между этапами.

Требование	Тест / доказательство	Ответственная роль
Изоляция A/B	Negative tests HTTP/worker/chat/cache/export/push.	Backend + security reviewer.
Понятность первого входа	Наблюдение 5-8 людей на синтетике.	Product / UX.
Корректные выплаты / yield	Эталонный набор и сверка с источником/брокером.	Финансовая методика + backend.
Работа без LLM	Отключение связи с Lenovo при обзоре/событии; stale lease и отмена.	Backend / эксплуатация.
Интернет и личный контекст	Источники, SSRF/injection, отсутствие личных сумм в поиске, tenant-bound SSE.	AI/backend + security.
Нет повторной заявки	Crash/timeout/replay на каждой границе состояния.	Execution developer + QA.
Законность capabilities	Письменное заключение и связанные документы/договоры.	Юрист + владелец продукта.
Цена ≤20 000 ₽	Usage ledger, фактические счета, прогноз остатка месяца.	Владелец + эксплуатация.
Восстановление	Restore drill с измерением RPO/RTO и повторным удалением.	Эксплуатация.

Единый комплект release evidence

Commit/build; scope включённых flags; миграции; UI-снимки основных состояний; изменённые contracts; результаты необходимых тестов; финансовые примеры; список известных ограничений; план отключения и ответственный. Чек-лист привязан к фактической версии, не копируется как «всё пройдено» из старого релиза.

Приёмка пользователем

Пользователь в роли user выполняет основной сценарий без подсказки разработчика, читает объяснение и может отменить/вернуться. Проверка на реальных деньгах не заменяет симулятор. Владелец подтверждает включение новой capability только по готовому reviewable-результату.

72. Первый рабочий пакет и границы развития

Модель выбрана, Lenovo подготовлен владельцем. Следующая работа - привязать существующий ИИ к продукту и его данным, сохранив полномочия пользователей и последовательность релизов.

Что делать сначала

1. Получить актуальные исходники/AGENTS.md, dependency locks и описание текущего deployment без секретов. Сопоставить план с уже готовыми версиями; не переписывать сделанное ради номеров документа.
2. Выполнить R0: tenant, сессии, финансовые DTO, backup и журнал. Критические дефекты закрыть до подключения личных данных к ИИ.
3. После R0 выделить R8-A в параллельную техническую ветку: исходящий worker, mTLS, очередь, ответ установленной модели на синтетический запрос. Это разработка соединения, без изменения аппаратной конфигурации Lenovo.
4. Подготовить пользовательский FAQ, источники R3 и корпус 240 заданий. Общие вопросы и сравнение стратегий включить в корпус наравне с облигациями.
5. Добавить публичный fetcher и SearchProvider с бюджетом; проверить использование источников, удаление и отсутствие личных данных в поисковых фразах.
6. Реализовать R8-B/C/D: контекст, чат, streaming, подробные задачи, две независимые учётные записи и проверки отказов.
7. Обновить документы обработки данных для фактического узла Lenovo и поставщика поиска. Перед подключением пользователей показать понятные настройки памяти и интернета.
8. Включить read-only функции двум тестировщикам; постепенно добавлять drafts R10. Публичный порт Ollama, прямой broker submit из модели и скрытый платный fallback не являются частью интеграции.

Полезное развитие после ядра

Watchlist без покупки; собственный отчёт пользователя через безопасный parser; сравнение нескольких сценариев пополнения; история объяснений/исправлений; напоминание о плановом выводе; пересечение фондов с прямыми позициями; детальный разбор публичного отчёта. Все сценарии используют ту же модель и систему прав, без клонирования чата под каждую стратегию.

За пределами текущей линии

Обучение большой модели с нуля, fine-tuning на личных портфелях, безусловная автоторговля, плечо/shorts/новые сложные классы, голосовые финансовые команды, автономное управление браузером с пользовательскими cookies и платёжными действиями, собственный платёжный процессинг. Публичный веб-поиск и чтение документов уже входят в R8 и не отложены за 1.0.

Что уточняется по реализации

Актуальный main и стек, фактический тариф/регион Timeweb, установленная версия Ollama и полный model digest, маршрут обработки и сроки хранения, договоры API/источников, часы активности и очередь. Интернет/UPS и характеристики Lenovo принимаются как сведения владельца; эти вопросы не превращаются в повторный аппаратный аудит.

Обновлённый план соединяет выбранную модель с реальными данными и интерфейсом. Точность повышается проверяемыми источниками, расчётами и обратной связью, при сохранении общей способности модели рассуждать и общаться.

73. Источники: продукт и финансовые контракты

Все ссылки использованы как исследовательская база на 04.10.2026. Сведения поставщиков могут измениться; перед релизом проверять актуальный контракт. Проектные числа/лимиты в документе обозначены отдельно.

S1. Исходный план OmniCIO
OmniCIO_Web_PWA_Evolution_Plan_2026.pdf, 38 страниц, приложен пользователем. Изучен полностью; указанный в нём baseline не заменяет аудит кода.

S2. Публичный экран OmniCIO
https://omnicio.ru/
Просмотрен в браузере: v0.18.1, сборка 0d9eb4694d65. Закрытый кабинет не исследован.

S3. Пользовательские правила OmniCIO
https://omnicio.ru/legal/terms.html
Прочитаны в браузере, версия 2026-10-02-v6. Основа сопоставления текущего read-only режима и будущих функций.

S4. Банк России: изменения базового стандарта советников
https://www.cbr.ru/press/event/?id=17210
О сущности индивидуальной рекомендации и недостаточности одного дисклеймера. Подтверждено поисковой выдачей официального сайта; прямое получение было нестабильным.

S5. Банк России: инвестиционные советники
https://www.cbr.ru/explan/invest/
Регуляторные сведения, реестр и требования. Применимость конкретной модели OmniCIO требует отдельного заключения.

S6. T-Invest: InstrumentsService, контракты
https://developer.tbank.ru/invest/services/instruments/methods
Признаки квалификации и доступности API. Официальная поисковая выдача; прямые запросы к части страниц возвращали ошибки.

S7. T-Invest: GetInfo
https://developer.tbank.ru/invest/api/users-service-get-info
Атрибуты пользователя и qualifiedForWorkWith; точную схему сверять в версии SDK/API.

S8. T-Invest: FAQ инструментов
https://developer.tbank.ru/invest/services/instruments/faq_instruments
api_trade_available_flag, базовый каталог и ограничения инструмента/ИИС.

S9. T-Invest: OrdersService
https://developer.tbank.ru/invest/api/orders-service
PostOrder, GetOrderState, GetMaxLots, GetOrderPrice, CancelOrder, ReplaceOrder.

S10. T-Invest: цены облигаций и фьючерсов
https://developer.tbank.ru/invest/intro/useful-info/points
Различие процентов номинала, валюты расчёта и семантики методов; критично для адаптера.

S11. T-Invest: FAQ заявок
https://developer.tbank.ru/invest/services/orders/faq_orders/
Идемпотентное поведение order_id и статус поручения. Recovery должен соответствовать действующему контракту.

74. Источники: данные и удобство интерфейса

Источник подтверждает ограниченный факт или техническое свойство. Предложенные макеты, очередность релизов, лимиты и критерии качества являются самостоятельными проектными решениями.

S12. Московская биржа: калькулятор облигаций
https://www.moex.com/ru/bondization/calc
Методологическое различие цены/НКД/доходности и ограничения расчётных показателей.

S13. АКРА: рейтинговые шкалы
https://acra-ratings.ru/about-ratings/scales/
Национальные шкалы и ограниченность прямого сопоставления. Рейтинг не используется как обещание результата.

S14. Московская биржа: ISS
https://www.moex.com/a2920
Доступные типы данных, задержанные бесплатные данные и подписка realtime; право распространения проверяется отдельно.

S15. W3C: Content on Hover or Focus
https://www.w3.org/WAI/WCAG22/Understanding/content-on-hover-or-focus.html
Справка должна быть предсказуемой, закрываемой и доступной при наведении/фокусе. Обоснование дополнения long press обычным tap.

S16. W3C: Target Size (Minimum)
https://www.w3.org/WAI/WCAG22/Understanding/target-size-minimum.html
Требования к размеру целей и исключения. Проект использует более удобную цель 44×44 px, а не выдаёт её за универсальный минимум этого критерия.

S17. WebKit: Web Push для iOS/iPadOS
https://webkit.org/blog/13878/web-push-for-web-apps-on-ios-and-ipados/
Home Screen web apps, разрешение по жесту и особенности платформы. Реальную поддержку проверять capability detection.

S18. MDN: Push API
https://developer.mozilla.org/en-US/docs/Web/API/Push_API
Push subscriptions и сервисные возможности браузера; транспорт не заменяет серверный журнал события.

S33. Банк России: ежедневные данные
https://www.cbr.ru/development/DWS/
Официальные курсы и методы получения ежедневных данных. Не подменять ими биржевую цену исполнения.

S37. Московская биржа: облигации
https://www.moex.com/a8048
Использованы определения долга, номинала, рыночной цены и купона. Налоговые сведения этой обзорной страницы не используются как актуальный правовой источник.

S34. Московская биржа: доходность облигаций
https://school.moex.com/articles/dohodnost-obligacij-kak-schitat-i-chto-formula-ne-uchityvaet
Показатели доходности, денежные потоки и ограничения расчёта. Использован как финансовый ориентир, не как персональная рекомендация.

75. Источники: выбранный ИИ и интеграция

Проверены официальные страницы 04.10.2026. Параметры пользовательского замера взяты с присланных снимков; плановые лимиты очереди, профилей и бюджета являются решениями OmniCIO, а не обещаниями поставщиков.

S19. Qwen3-14B: официальная карточка
https://huggingface.co/Qwen/Qwen3-14B
Возможности текстовой модели, Apache-2.0, thinking/non-thinking, tools и параметры контекста. Размер модели не является гарантией точности в финансовых задачах.

S20. Ollama: точный тег Qwen3-14B Q4_K_M
https://ollama.com/library/qwen3:14b-q4_K_M
Тег, 14,8B, 9,3 GB, сокращённый digest bdbd181c33f2 и лицензия; полный digest берётся из реального deployment.

S21. Ollama FAQ
https://docs.ollama.com/faq
Localhost, размещение CPU/GPU, прогрев и keep_alive. Не подтверждает настройки конкретного Lenovo.

S22. Ollama Chat API
https://docs.ollama.com/api/chat
Messages/tools, stream, think, keep_alive и метрики времени; проверять контракт установленной версии.

S23. Ollama: Thinking
https://docs.ollama.com/capabilities/thinking
Отдельное управление thinking и финальным содержанием ответа.

S24. Timeweb Cloud: серверы
https://timeweb.cloud/services/cloud-servers
Конфигуратор ресурсов; бюджет документа - проектный конверт, реальные счета не предоставлены.

S25. Apache License 2.0
https://www.apache.org/licenses/LICENSE-2.0
Условия распространения и notices; не лицензия на сторонние новости и биржевые данные.

S26. Yandex Search API: тарификация
https://aistudio.yandex.ru/ru/docs/search-api/pricing
На дату проверки: дневной sync 488 ₽/1000, deferred 30,50 ₽/1000 с НДС. Поиск используется без генеративного ответа; условия аккаунта/квоты проверяются до подключения.

S38. Ollama: вызов инструментов
https://docs.ollama.com/capabilities/tool-calling
Модель запрашивает tool, приложение исполняет его; parser/validation/полномочия остаются задачей интеграции.

S39. Ollama: Structured Outputs
https://docs.ollama.com/capabilities/structured-outputs
JSON Schema для формы результата; схема не подтверждает смысловую достоверность.

S40. Ollama: Streaming
https://docs.ollama.com/capabilities/streaming
Частичная выдача ответа; OmniCIO дополнительно управляет буфером, SSE и проверкой финансовых карточек.

S41. Снимки локального теста владельца
Получены в разговоре 04.10.2026: 17,10 с тёплого ответа, 4,09 токена/с, context 2048, 57% CPU / 43% GPU. Самостоятельный замер Lenovo не выполнялся.

S42. Ollama: список работающих моделей
https://docs.ollama.com/api/ps
Метаданные загруженной модели для состояния worker и контроля manifest.

S43. Снимки Timeweb владельца
04.10.2026, 1000068823.jpg и 1000068825.jpg: 20 GB диска, 0,11 GB занято; выбранная форма 1 CPU/2 GB/20 GB за 890 ₽/мес. Оплата и применение не подтверждены.

S44. Timeweb: расширения PostgreSQL
https://timeweb.cloud/docs/dbaas/postgresql/extensions
Pgvector присутствует в перечне; набор расширений зависит от версии PostgreSQL.

S45. Timeweb: управляемые базы данных
https://timeweb.cloud/docs/dbaas
База данных как управляемый сервис; для собственного inference используется вычислительный сервер.

76. Источники: безопасность и правовые вопросы

Юридические разделы - план проверки и изменения документов. Они не подтверждают регистрацию, лицензию, аккредитацию или соответствие OmniCIO закону.

S27. PostgreSQL: Row Security Policies
https://www.postgresql.org/docs/current/ddl-rowsecurity.html
Поведение RLS, default deny и исключения владельца/привилегированных ролей. Сверить с реально используемой версией PostgreSQL.

S28. OWASP: Prompt Injection
https://genai.owasp.org/llmrisk/llm01-prompt-injection/
Класс рисков LLM. Конкретные allowlist/tools/тесты этого документа - проектные меры OmniCIO.

S29. OWASP: SSRF Prevention
https://cheatsheetseries.owasp.org/cheatsheets/Server_Side_Request_Forgery_Prevention_Cheat_Sheet.html
Защита URL-fetching и сетевого доступа; применяется к сборщикам, вложениям и push endpoints.

S30. Роспотребнадзор: автоматические списания за подписки
https://zpp.rospotrebnadzor.ru/news/federal/572344
Изменения с 01.03.2026: отказ от использования платёжных реквизитов должен учитываться. Тексты оферты и реализацию проверять с юристом.

S31. ФНС: применение ККТ
https://www.nalog.gov.ru/create_business/ip/in_progress/kkt/registration/
Правовая база применения ККТ и расчётов. Применимость исключений зависит от статуса оператора и вида деятельности.

S32. 152-ФЗ, статья 12: трансграничная передача
https://www.consultant.ru/document/cons_doc_LAW_61801/e4ebbe1780de623c7cf32a59ca82a7bb523a25dd/
Текст закона в справочно-правовой системе, отображённая редакция от 26.07.2026. Проверять вступление конкретных изменений в силу и применимость процедуры.

S35. OmniCIO: политика обработки ПД
https://omnicio.ru/legal/privacy.html
Прочитана в браузере, версия 2026-10-02-v6. Проанализированы состав данных, поставщики, сроки, удаление и изменения целей.

S36. OmniCIO: отдельное согласие
https://omnicio.ru/legal/consent.html
Прочитано в браузере, версия 2026-10-02-v6. Новые AI/push/billing сценарии требуют согласования целей/оснований и обновления текста.

Непроверенные источники проекта

Репозиторий MishaGameHacking/omni-cio-gateway указан исходным PDF, но файлы не получены. Старые V10 документы не предоставлены отдельно. Содержимое закрытого кабинета не просмотрено. Поэтому документ не содержит фиктивного построчного code audit, найденных CVE проекта или утверждения об успешно проведённом penetration test.

Правило обновления самого плана

После R0 добавить приложение с фактическими путями файлов, подтверждёнными контрактами и найденными дефектами. После каждого релиза обновлять только статус выполнения, измеренные результаты и принятые ADR; исходные причины решений и факты исследования сохранять как историю.

Статус редакции 2.1

Основной план отредактирован под решение владельца и присланные замеры. Код интеграции, соединение с Timeweb, сертификаты, серверные настройки и юридические страницы в ходе подготовки PDF не менялись. Реальные входные данные из репозитория и deployment проверяются при исполнении плана, без повторного выбора модели.